«Ақпараттық жүйелер» кафедрасы

№1 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Машиналық оқыту әдісі дегеніміз не?

Машиналық оқыту әдісі-бұл компьютерлік жүйелер нақты бағдарламалаусыз мәліметтер негізінде автоматты түрде оқытылатын жасанды интеллект бөлімі. Олар жүйелерге үлгілерді анықтауға, болжам жасауға немесе оқу деректерінен алынған тәжірибе негізінде шешім қабылдауға мүмкіндік беретін алгоритмдерді пайдаланады.

2. Машиналық оқыту әдісіндегі мұғаліммен оқыту әдісін қалай түсінесіз?

Машиналық оқытудағы мұғаліммен оқыту әдісі әр мысал үшін кіріс параметрлері және тиісті дұрыс жауаптар немесе белгілер бар белгіленген деректерді пайдаланады. Жүйе осы мәліметтер негізінде оқытылады, болжам жасауға немесе жаңа деректерді жіктеуге қабілетті модель жасайды. Негізгі мақсат-модельді белгілі мысалдармен оқыту арқылы жаңа, бұрын кездеспеген мәліметтерге дұрыс жауап беруге үйрету.

3. Ақпараттық жүйені «интеллектуалды» ететін негізгі сипаттамалар қандай?

Интеллектуалды ақпараттық жүйе бірнеше негізгі сипаттамаларға ие:
Оқу және бейімделу қабілеті: жүйе тәжірибе, деректер және кері байланыс негізінде өнімділігін жақсартуға қабілетті.
Шешім қабылдау қабілеті: жүйе алынған білімді пайдалана отырып, болжам жасауға, деректерді жіктеуге немесе шешім қабылдауға қабілетті.
Автоматтандыру және оңтайландыру: жүйе тапсырмаларды автоматты түрде орындай алады және жаңа ақпарат негізінде өз қызметін оңтайландырады.
Белгісіздікпен жұмыс істей білу: жүйе әртүрлі көздерден деректерді жинау арқылы шектеулі немесе белгісіз ақпарат жағдайында қорытынды жасауға және шешім қабылдауға қабілетті.
Бұл сипаттамалар бірге ақпараттық жүйенің "интеллектуалды" болуына мүмкіндік береді, бұл оған өздігінен білім алуға, шешім қабылдауға және жаңа ақпарат пен жағдайларға бейімделуге мүмкіндік береді

«Ақпараттық жүйелер» кафедрасы

№2 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Модельді қайта оқытудың алдын алу үшін қандай әдістер қолданылады?

Модельді қайта оқытудың алдын алу үшін келесі әдістер қолданылады:

Кросс-валидация: модельдің өнімділігін бағалау үшін деректерді оқыту және сынақ қосалқы үлгілеріне бөлу.
Реттеу: қайта оқытудың алдын алу үшін модельдің күрделілігі үшін айыппұл қосу.
Модельдің күрделілігін азайту: күрделі емес модельдерді қолдану немесе қайта даярлау қаупін азайту үшін белгілер санын азайту.
Белгілерді жою: маңызды емес белгілерді анықтау және жою, бұл модельге ең маңыздыларына назар аударуға көмектеседі.

2. Машиналық оқытуда қандай тапсырмалар бар?

Классификация тапсырмалары: объектілерді белгілі бір санаттарға немесе сыныптарға бөлу.
Регрессия тапсырмалары: қолда бар мәліметтер негізінде сандық мәндерді болжау.
Кластерлеу тапсырмалары: объектілерді олардың ұқсастығына немесе заңдылықтарына қарай топтастыру.
Күшейту жаттығуларының тапсырмалары: агенттерді мінез-құлқын оңтайландыру үшін қоршаған ортамен өзара әрекеттесуге үйрету.
Өлшемді азайту тапсырмалары: маңызды ақпаратты сақтай отырып, белгілер санын азайту.

3. Мұғаліммен оқыту мен мұғалімсіз оқытудың айырмашылығы неде?

Мұғаліммен оқыту белгіленген деректерді пайдаланады, мұнда әрбір мысал үшін кіріс белгілері және оларға сәйкес келетін мақсатты белгілер белгілі. Модель белгілі мәліметтер негізінде белгілерді болжауға үйретіледі. Мұғалімсіз оқыту нақты мақсатты белгілер жоқ белгіленбеген деректермен жұмыс істейді. Мұнда жүйе мұғалімнің нақты кері байланысынсыз деректердегі құрылымды немесе үлгілерді анықтауға тырысады.

«Ақпараттық жүйелер» кафедрасы

№3 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. K-жақын көршілер әдісінің мысалында жіктеу алгоритмі қалай жұмыс істейді?

K-жақын көршілер (kNN) әдісі объектілерді белгілер кеңістігіндегі басқа объектілерге жақындығына қарай жіктейді. Ол келесідей жұмыс істейді:

1-қадам: жаңа нысанды жіктеу үшін қолданылатын көршілер саны (k) анықталады.
2-қадам: жаңа нысан үшін оқу жинағындағы барлық басқа нысандарға дейінгі қашықтық есептеледі.
3-қадам: жаңа нысанға ең жақын объектілердің k таңдалады.
4-қадам: жаңа объектінің класы оның жақын көршілерінің k сыныптары негізінде анықталады (мысалы, көршілердің көпшілігінің дауыс беруі арқылы).

2. Машиналық оқыту моделін құру процесінің негізгі қадамдары қандай?

Машиналық оқыту моделін құрудың негізгі кезеңдеріне мыналар жатады:

Тапсырманы түсіну: деректердің мақсаттары мен ерекшеліктерін анықтау.
Деректерді дайындау: деректерді тазарту, түрлендіру, оқыту және сынақ үлгілеріне бөлу.
Модельді таңдау: есепті шешу үшін қолайлы алгоритм мен модель түрін таңдау.
Модельді оқыту: оқу деректерінде модельді оқыту процесі.
Модельді бағалау: дәл болжау жасау қабілетін бағалау үшін сынақ деректеріндегі модель өнімділігін бағалау.
Реттеу және жақсарту: гиперпараметрлерді реттеу немесе оның өнімділігін арттыру үшін алгоритмдерді өзгерту арқылы модельді оңтайландыру.

3. Кросс-валидация дегеніміз не және ол модельдерді бағалауға қалай көмектеседі?

Кросс-валидация - бұл модельді оқыту және тестілеу үшін барлық қолда бар деректерді пайдалануға мүмкіндік беретін модельдің өнімділігін бағалау әдісі. Ол келесідей жұмыс істейді:

1-қадам: деректер тең бөліктерге бөлінеді.
2-қадам: Модель K-1 қатпарларында k рет оқытылады және қалған қатпарда сыналады.
3-қадам: оқу және тестілеу процесі әр уақытта әр түрлі тестілеу қорларын қолдана отырып, k рет қайталанады.

4-қадам: нәтижелер барлық деректер бойынша модель өнімділігінің сенімді бағасын алу үшін орташаланады.
Кросс-валидация модельдерді бағалауға көмектеседі, өйткені ол қайта оқыту ықтималдығын азайтады немесе модельді оқытуға дейін емес, сонымен қатар жаңа деректерде модельдің өнімділігін объективті бағалауды қамтамасыз етеді.

«Ақпараттық жүйелер» кафедрасы

№4 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Классификация моделінің сапасын бағалау үшін қандай көрсеткіштер қолданылады?

Классификация моделінің сапасын бағалау үшін келесі көрсеткіштер қолданылады:

Дәлдік (Accuracy): дұрыс жіктелген объектілердің барлық объектілерге қатынасы.
Толықтығы(Recall): осы сыныптағы объектілердің жалпы санынан дұрыс анықталған оң класс объектілерінің үлесі.
F1-Өлшем (F1-Score): дәлдік пен толықтық арасындағы орташа гармоникалық, екі метриканы бір уақытта есепке алуға мүмкіндік береді.
ROC-AUC: ROC қисығының астындағы аймақ, модельдің сыныптарды бөлу қабілетін бағалайды.

2. Классификация тапсырмасындағы жоғалту функциясы дегеніміз не және ол модельді бағалау үшін қалай қолданылады?

Классификация тапсырмасындағы жоғалту функциясы болжамды мәндерді нақты белгілермен салыстыру арқылы модель қатесін өлшейді. Ол модельдің өз болжамдарында қаншалықты қате екенін анықтайды. Мысалы, логистикалық регрессия үшін бұл low loss функциясы (немесе екілік кросс-энтропия), ал SVM үшін hinge loss жоғалту функциясы болуы мүмкін. Мақсаты-модельді оқыту процесінде осы шығын функциясын азайту.

3. Классификация есептері үшін логистикалық регрессия мен анықтамалық векторлық әдіс (SVM) арасындағы айырмашылықтар қандай?

Классификация есептері үшін логистикалық регрессия мен анықтамалық векторлық әдіс (SVM) арасындағы негізгі айырмашылықтар:

Мақсаты: логистикалық регрессия классификация қатесін азайту арқылы сызықтық бөлгіш гиперпланды іздеуге тырысады, ал SVM сыныптар арасындағы ең үлкен саңылауы бар оңтайлы бөлгіш гиперпланды іздейді.
Шығын функциясы: логистикалық регрессия үшін logloss, ал SVM үшін hinge loss қолданылады.
Шығарындыларды өңдеу: SVM саңылауды пайдалану арқылы шығарындыларға төзімді, ал логистикалық регрессия шығарындыларға сезімтал.
Екі модель де классификация есептерінде кеңінен қолданылады, бірақ олардың арасындағы таңдау деректердің сипаттамаларына және нақты тапсырмаларға байланысты.

«Ақпараттық жүйелер» кафедрасы

№5 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Кластерлеу сапасын бағалау үшін қандай көрсеткіштер қолданылады?

Кластерлеу сапасын бағалау үшін келесі көрсеткіштер қолданылады:

Силуэт индексі (Silhouette Score): кластерлер арасындағы және кластерлер ішіндегі қашықтыққа негізделген кластерлердің бөліну сапасын бағалайды.
Дэвис-Болдин индексі (Davies-Bouldin Index): кластерішілік қашықтықты азайтады және кластераралық қашықтықты барынша арттырады.
Хопкинс индексі (Hopkins Statistic): нақты деректерді кездейсоқ жасалған деректермен салыстыру арқылы деректердің кластерлеуге бейімділігін бағалайды.
Силуэт графиктері (Silhouette Plots): әр объект үшін силуэт көрсеткішін визуализациялау.

2. Кластерлеу алгоритмдеріндегі кластерлердің оңтайлы санын қалай таңдауға болады?

Кластерлердің оңтайлы санын анықтаудың бірнеше әдістері бар:

Шынтақ әдісі (Elbow Method): объектілер мен олардың центроидтары арасындағы қашықтық квадраттарының қосындысының өзгеруі күрт төмендейтін графиктен нүкте табу.
Силуэт әдісі (Silhouette Method): кластерлер санының әртүрлі мәндері үшін силуэт мәнін максимизациялау.
Негізгі компоненттер әдісі (PCA Method): деректерді визуализациялау және мәліметтер нақты бөлінген кластерлер санын анықтау үшін негізгі компоненттер әдісін қолдану.

3. Сіз кластерлеудің қандай әдістерін білесіз және олардың айырмашылығы неде?

K-орташа (K-Means): кластер ішіндегі орташа қашықтықты азайту арқылы деректерді k кластерлеріне бөледі.
Иерархиялық кластерлеу (Hierarchical Clustering): кластерлердің бірігуін немесе бөлінуін жасау арқылы кластер ағашын салады.
DBSCAN: деректер тығыздығына негізделген және ерекшелік кеңістігіндегі тығыз аймақтарға негізделген кластерлерді бөледі.
OPTICS: Dbscan аналогы, бірақ әртүрлі тығыздықтағы кластерлерді анықтауға мүмкіндік береді.
Әдістер арасындағы айырмашылық олардың кластерлерді бөлу тәсілдерінде және олар үшін қолданатын Критерийлерде. Мысалы, K-орташа мәндер деректерді орта нүктелер негізінде бөледі, ал DBSCAN деректер тығыздығына негізделген кластерлерді анықтайды.

«Ақпараттық жүйелер» кафедрасы

№6 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Шешім ағаштарының қандай артықшылықтары мен кемшіліктері бар?

Артықшылықтары:
Түсіндірудің қарапайымдылығы: шешім қабылдау процесін түсіну және елестету оңай.
Әмбебаптық: жіктеу және регрессия мәселелерін шешу үшін пайдалануға болады.
Шығарындыларға төзімділік: шу немесе белгілі бір белгілердің болмауы бар деректермен жақсы жұмыс істей алады.
Сандық және категориялық деректермен жұмыс істей алады: деректерді масштабтауды немесе алдын ала өңдеуді қажет етпейді.

Кемшіліктері:
Қайта оқыту үрдісі: оқу деректерінде қайта оқытылатын тым күрделі үлгілерді жасай алады.
Деректердің өзгеруіне тұрақсыздық: шешім ағаштары деректердегі кішігірім өзгерістермен айтарлықтай өзгеруі мүмкін.
Өткізіп алған мәндерді өңдеудегі қиындықтар: шешім ағаштары өткізіп алған деректерді өңдеуде қиындықтарға тап болуы мүмкін.

2. Шешім ағаштарында қайта оқытудың алдын алатын әдістер қандай?

Қайта оқытудың алдын алу әдістері:

Ағаштың максималды тереңдігін анықтау: ағаштың тереңдігін шектеу қажетсіз күрделілікті болдырмауға көмектеседі.
Парақтағы нысандардың ең аз санын пайдалану (min_samples_leaf): парақтағы нысандардың ең аз санын орнату одан әрі бөлуді шектейді.
Кросс-валидацияны қолдану: кешіктірілген үлгідегі модельді тексеру немесе оның жалпылау қабілетін бағалау үшін кросс-валидацияны қолдану.
Регуляризацияны қолдану: кейбір әдістер қайта оқытуды азайту үшін регуляризация параметрлерін қосады.

3. Шешім ағашын құру алгоритмі қалай жұмыс істейді?

Шешім ағашын құру алгоритмі:

1-қадам: деректерді әртүрлі сыныптарға немесе мақсатты айнымалы мәндерге жақсы бөлетін белгіні таңдау.
2-қадам: Таңдалған белгіге негізделген деректерді бөлу.
3-қадам: бұл процесті тоқтату шарттары орындалғанға дейін жасалған әрбір деректер жиынтығы үшін рекурсивті түрде жалғастыру, мысалы, парақтағы объектілердің максималды тереңдігіне немесе минималды санына жету.

4-қадам: әрбір деректер тобы үшін соңғы болжамдарды білдіретін ағаш жапырақтарын жасау.
Шешім ағаштары бұл қадамдарды белгілердің мәндеріне негізделген шешімдер қабылдау арқылы деректерді кіші топтарға бөлу үшін пайдаланады.

«Ақпараттық жүйелер» кафедрасы

№7 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Градиентті бустинг пен адаптивті бустингтің айырмашылығы неде?

Градиентті бустинг (Gradient Boosting): бұл модель қатесін азайту үшін градиентті төмендетуді қолданатын модельдер ансамблін құру әдісі. Ол жаңа модельдерді алдыңғы модельдің қалдықтарына (болжанған және нақты мәндер арасындағы айырмашылық) бейімдеу арқылы қосады.
Адаптивті бустинг (AdaBoost): бұл алдыңғы модельдер дұрыс жіктемеген объектілерге бағытталған модельдер ансамблін құру алгоритмі. Ол келесі модель алдыңғы модельдер дұрыс жіктелмеген нысандарға назар аударуы үшін оқу үлгісіндегі нысандардың салмағын өзгертеді.

2. Бустингте қандай негізгі алгоритмдер жиі қолданылады?

Бустингте қолданылатын негізгі алгоритмдер:

Градиентті бустинг (Gradient Boosting Machine, GUN): шешім ағаштары ансамблін құру үшін градиентті түсіруді қолданады.
AdaBoost (Adaptive Boosting): қате жіктелген нысандарға назар аудара отырып, әлсіз модельдерді дәйекті түрде құрастыратын алгоритм.
XGBoost (Extreme Gradient Boosting): жоғары өнімділік пен тиімділікке ие градиентті бустингтің оңтайландырылған нұсқасы.
LightGBM: XGBoost-қа қарағанда жылдамырақ және үлкен көлемдегі деректермен жұмыс істей алатын градиентті бустингтің тағы бір оңтайландырылған іске асырылуы.

3. Бустинг процесіне қандай негізгі параметрлер әсер етеді?

Оқу жылдамдығы (Learning Rate): әр модельдің ансамбльге қосқан үлесін анықтайды. Кішкентай мәндер әдетте көбірек ағаштарды қажет етеді, бірақ модельдің жалпылау қабілетін арттыруы мүмкін.
Ағаштардың тереңдігі: ансамбльдегі әрбір ағаштың тереңдігін анықтайды. Тереңірек ағаштар қайта оқытуға әкелуі мүмкін.
Ағаштар саны: ансамбльге қосылатын модельдер саны. Көбірек ағаштар дәлдікті жақсарта алады, бірақ сонымен бірге оқу уақытын арттыра алады.
Реттеу параметрлері (Regularization Parameters): модельдің күрделілігін шектеу арқылы қайта оқытуды басқару үшін қолданылады.

«Ақпараттық жүйелер» кафедрасы

№8 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Машиналық оқыту әдісі ретінде шешім ағаштарының артықшылықтары мен кемшіліктері қандай?

Артықшылықтары:
Интерпретация: шешім қабылдауды түсіндіруге мүмкіндік беретін оңай түсінілетін және көрнекі нәтижелер.
Әр түрлі деректерді өңдеу: сандық және категориялық деректерді алдын-ала өңдеусіз қолдайды.
Шығарындыларға төзімділік: Модель шуды немесе өткізіп жіберуді қамтитын деректермен жұмыс істей алады.

Кемшіліктері:
Қайта оқыту үрдісі: жаттығу деректерінде қайта оқытылатын тым күрделі модельдерді құра алады.
Деректердің өзгеруіне тұрақсыздық: деректердегі кішігірім өзгерістер ағаш құрылымына қатты әсер етуі мүмкін.
Параметрлерді конфигурациялаудың қиындығы: қайта оқытудың алдын алу үшін параметрлерді дұрыс реттеу қажеттілігі.

2. CatBoost-тың басқа градиентті бустинг алгоритмдерінен қандай артықшылықтары бар?

CatBoost Артықшылықтары:

Категориялық деректерді автоматты түрде өңдеу: алдын ала өңдеуді немесе кодтауды қажет етпестен категориялық белгілерді өңдеу мүмкіндігі.
Қайта оқытуға төзімділік: қайта оқытуды азайту үшін кірістірілген реттеу механизмдері бар.
Тиімділік және жылдамдық: деректердің үлкен көлемінде тиімді болуы мүмкін және жоғары жылдамдыққа ие.

3. XGBoost-тың қандай ерекшеліктері оны үлкен деректер жиынтығы үшін тиімді етеді?

Сирек деректермен жұмыс: сирек деректер матрицаларымен тиімді жұмыс істеуді қолдайды.
Параллельді өңдеу: деректерді параллель өңдей алады және есептеулерді орындай алады, бұл процесті жылдамдатады.
Оңтайландырылған алгоритмдер: жұмыс тиімділігін арттыра отырып, оңтайландырылған ағаш құру және есептеу алгоритмдерін қолданады.

«Ақпараттық жүйелер» кафедрасы

№9 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Машиналық оқытудағы регрессия дегеніміз не және регрессияның қандай түрлерін білесіз?

Машиналық оқытудағы Регрессия-кіріс деректеріне негізделген баға, температура және т.б. сияқты үздіксіз мәндерді болжау әдісі. Бұл тәуелсіз және тәуелді айнымалылар арасындағы байланысты анықтайтын модельдер құруға мүмкіндік береді.

Регрессияның кейбір түрлері:

Сызықтық регрессия: тәуелді айнымалыны тәуелсіз айнымалылардың сызықтық тіркесімі арқылы болжайтын Модель.
Лассо регрессиясы: сызықтық регрессия сияқты, бірақ белгілерді реттеу және таңдау үшін L1 айыппұлы қосылған.
Ridge регрессиясы: сызықтық регрессияға ұқсас, бірақ реттеу үшін L2 айыппұлы қосылған.
Көпмүшелік регрессия: көпмүшелік белгілерді қамтитын сызықтық регрессияның кеңеюі.
Анықтамалық векторлық регрессия (SVM): регрессия үшін анықтамалық векторлық әдісті қолданады.

2. Машиналық оқытуда деректерді азайтудың қандай әдістері қолданылады?

Деректерді азайту әдістері ең маңызды сипаттамаларды сақтай отырып, деректердің өлшемін азайтуға көмектеседі:

Негізгі компонент әдісі (PCA): деректердің ең үлкен дисперсиясын сақтай отырып, деректерді кішірек өлшемдегі жаңа кеңістікке түрлендіреді.
Белгілерді таңдау арқылы өлшемді азайту: ең маңызды белгілерді таңдау үшін статистикалық әдістерді немесе алгоритмдерді қолданады.
t-SNE (t-distributed Stochastic Neighbor Embedding): нысандар арасындағы құрылым мен қашықтықты сақтай отырып, деректерді визуализациялауға және қысуға мүмкіндік береді.

3. Python-да машиналық оқытудың негізгі кітапханалары қандай және олар не үшін қолданылады?

Scikit-learn (sklearn): классификация, регрессия, кластерлеу және т. б. қоса алғанда, Машиналық оқыту тапсырмаларының кең ауқымы үшін пайдаланылады.
TensorFlow және Keras: нейрондық желілерді құру және терең оқыту үшін қолданылады.

PyTorch: нейрондық желілерді құруға арналған тағы бір кітапхана, жақсы икемділік пен өнімділікке ие.
Pandas және NumPy: олар тек машиналық оқытуға маманданбағанымен, олар машиналық оқытуда деректермен жұмыс істеудің маңызды құралдары болып табылады.

«Ақпараттық жүйелер» кафедрасы

№10 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Классификация тапсырмаларында теңгерімсіз сыныптармен жұмыс істеу кезінде қандай проблемалар туындауы мүмкін?

Модельді ауыстыру: модельді аз ұсынылған сынып елемей, үлкен сыныпқа қарай жылжытуға болады.
Төмен дәлдік: теңгерімсіз деректермен оқытылған Модель аз ұсынылған сыныпты болжауда төмен дәлдікке ие болуы мүмкін.
Қате тұжырымдар: Модель басқа сыныптарды елемей, тек басым сыныпты болжауға бейім болуы мүмкін.

2. Классификация модельдерін құру кезінде категориялық деректерді өңдеу үшін қандай әдістерді қолдануға болады?

One-Hot Encoding: категориялық деректерді екілік мәндерге түрлендіреді, әр санат үшін жаңа белгі жасайды.
Label Encoding: категорияларды сандық белгілерге түрлендіреді.
Мақсатты Кодтау: санатты сол санаттағы мақсатты айнымалының орташа мәнімен ауыстырады.
Frequency Encoding: олардың санаттарын dataset жиілігімен ауыстырады.

3. Бір өлшемді және көп өлшемді классификация дегеніміз не? Олар бір-бірінен қалай ерекшеленеді?

Бір өлшемді классификация: бір белгілер жиынтығына негізделген бірнеше сыныптардың бірін болжау жүзеге асырылады.
Көпөлшемді классификация: бірнеше белгілер жиынтығын немесе олардың комбинациясын қолдана отырып, бірнеше сыныптардың бірін болжау.
Олардың арасындағы негізгі айырмашылық-болжау үшін қолданылатын сыныптар саны және/немесе белгілер жиынтығы. Бір өлшемді классификация бір белгілер жиынтығымен жұмыс істейді және бірнеше класты болжайды, ал көп өлшемді классификация бірнеше кластарды болжау үшін бірнеше белгілер жиынтығын немесе белгілер комбинациясын қолдана алады.

«Ақпараттық жүйелер» кафедрасы

№11 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Үлкен көлемдегі деректермен жұмыс істеу үшін қандай кластерлік алгоритмдер қолайлы?

K-Means: үлкен көлемдегі деректерде жақсы масштабталған және тиімді.
DBSCAN: үлкен деректерге қолданылатын айнымалы пішін мен өлшем кластерлерін анықтауда тиімді.
Иерархиялық кластерлеу әдістері: агломеративті кластерлеу сияқты кейбір иерархиялық кластерлеу әдістерін үлкен деректерге қолдануға болады.

2. Нақты әлемде кластерлеудің қандай негізгі қолданыстарын білесіз?

Маркетингтік зерттеулер: дәлірек маркетингтік стратегияларды құру үшін клиенттерді мінез-құлық сипаттамалары бойынша топтастыру.
Медициналық диагностика: тиісті емдеуді анықтау үшін симптомдарға негізделген пациенттерді кластерлеу.
Қаржылық талдау: инвестициялық портфельді талдау және ұқсас қаржылық трендтерді анықтау.
Кескінді өңдеу: нысандарды немесе қызығушылық аймақтарын анықтау үшін кескіндерді сегменттеу.
Мәтіндік аналитика: тақырыптарды немесе ұқсас мазмұнды анықтау үшін мәтіндік деректерді кластерлеу.

3. Модельді жақсарту үшін CatBoost қолданған кезде қандай негізгі параметрлерді реттеуге болады?

Оқу жылдамдығы (Learning Rate): әр ағаштың ансамбльге қосқан үлесін анықтайды.
Ағаштардың тереңдігі: ағаштардың қаншалықты терең болуы мүмкін екенін анықтайды.
Реттеу: қайта оқытуды болдырмау үшін L2-реттеу немесе белгілерді таңдау сияқты параметрлерді реттеу.
Ансамбльдегі ағаштардың саны: ансамбльге қосылатын ағаштардың санын бақылайды.
Бұл параметрлерді CatBoost моделін оңтайландыру үшін кросс-валидация немесе гиперпараметрлерді таңдау әдістері арқылы реттеуге болады.

«Ақпараттық жүйелер» кафедрасы

№12 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Шешім ағаштарын визуализациялау үшін қандай әдістерді қолдануға болады?

Graphviz: графиктерді визуализациялауға арналған кітапхана. Graphviz көмегімен шешім ағашының графикалық көрінісін құруға болады.
matplotlib: қарапайым шешім ағашының диаграммаларын құру үшін пайдалануға болатын деректерді визуализациялауға арналған Python кітапханасы.
sklearn-дегі plot_tree: scikit-learn кітапханасындағы scikit-learn көмегімен жасалған модельден шешім ағашын визуализациялауға мүмкіндік беретін мүмкіндік.

2. Шешім ағаштарымен қандай белгілер жақсы жұмыс істейді?

Шешім ағаштары әртүрлі деректер түрлерімен, соның ішінде сандық және категориялық айнымалылармен жақсы жұмыс істей алады. Олар әсіресе тиімді:
Көптеген айнымалылар бар, олардың көпшілігі мақсатты айнымалымен байланысты.
Деректерді шешім қабылдау ағашы түрінде ұсынуға болады.

3. Шешім ағаштарының үстіндегі градиентті күшейту дегеніміз не және оның классикалық әдістермен салыстырғанда қандай ерекшеліктері бар?

Шешім ағаштарының үстіндегі градиентті бустинг (Gradient Boosting Decision Trees, GBDT) - бұл алдыңғы модельдегі қатені азайта отырып, шешім ағаштары ансамблін дәйекті түрде құратын Машиналық оқыту алгоритмі. Ол алдыңғы модельдердің қателерін түзететін жаңа модельдер құру арқылы жұмыс істейді.
Классикалық әдістермен салыстырғанда шешім ағаштарының үстіндегі градиентті бустинг ерекшеліктері:
Модельдердің дәйекті құрылысы: модельдер дәйекті түрде құрастырылған, олардың әрқайсысы алдыңғы қателерді түзетеді.
Қуатты алгоритм: GBDT жоғары дәлдікке қол жеткізе алады, әсіресе гиперпараметрлерді дұрыс орнатқан кезде.
Шығарындыларға төзімділік: ол деректердегі шығарындылар мен шуларға салыстырмалы түрде төзімді.
Дегенмен, ол қайта оқытуға сезімтал болуы мүмкін және жақсы нәтижеге қол жеткізу үшін гиперпараметрлерді мұқият конфигурациялауды қажет етеді.

«Ақпараттық жүйелер» кафедрасы

№13 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Модельдерді ансамбльдеу дегеніміз не? Ол машиналық оқытуда қандай артықшылықтар береді?

Модельдер ансамблі-бұл бір мәселені шешу үшін бірнеше модельдерді біріктіретін Машиналық оқыту әдісі. Ол бірнеше модельдердің болжамдарын біріктіру әр модельдің жеке нәтижесіне қарағанда дәлірек және тұрақты нәтиже береді деген идеяға негізделген. Оның негізгі 3 түрі бар. Яғни олар бэггинг, бустинг және стекинг.

Машиналық оқытудың артықшылықтары:
Дәлдік және болжау қабілеті: Машиналық оқыту модельдері деректерге негізделген нақты болжамдар жасай алады.
Автоматтандыру және жылдамдық: Машиналық оқыту процестерді автоматтандыруға және үлкен көлемдегі деректерді жылдам өңдеуге мүмкіндік береді.
Бейімделу және жалпылау: Машиналық оқыту модельдері жаңа деректерге бейімделіп, білімдерін жаңа жағдайларға жалпылай алады.

2. Бустинг алгоритмдерінде қайта оқытуды қалай азайтуға болады?

Бустинг алгоритмдерінде қайта оқытуды азайту үшін келесі тәсілдерді қолдануға болады:

Параметрлерді реттеу: ағаштардың тереңдігі немесе оқу жылдамдығы (оқу жылдамдығы) сияқты гиперпараметрлерді мұқият реттеу қайта оқытуды азайтуға көмектеседі.
Реттеу: ағаштардың тереңдігін шектеу немесе модельдің күрделілігі үшін айыппұлдарды пайдалану сияқты реттеу әдістерін қолдану қайта оқытудың алдын алуға көмектеседі.
Қайта оқытуды бақылау: оқытуды ерте тоқтату (early stopping) сияқты қайта оқытуды бақылау әдістерін қолдану валидация үлгісіндегі сапа жақсаруды тоқтатқан кезде оқуды тоқтатуы мүмкін.

3. Датасет пен DataFrame айырмашылығы неде?

DataFrame–бұл Pandas кітапханасында қолданылатын нақты деректер құрылымы, ал Датасет (Dataset) – бұл әртүрлі форматтарда ұсынылатын мәліметтер жиынтығын білдіретін жалпы түсінік (мысалы, кесте, уақыт қатары және т.б.).

«Ақпараттық жүйелер» кафедрасы

№14 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Мәтіндік деректермен жұмыс істеу үшін ең жақсы Машиналық оқыту алгоритмдері қандай?

Анықтамалық векторлық әдіс (Support Vector Machines, SVM): мәтіндік деректерді жіктеу және регрессиялау үшін қолданылады.
Қайталанатын нейрондық желілер (Recurrent Neural Networks, RNN): мәтін сияқты дәйекті деректерді талдауда тиімді.

2. Уақыт сериялары (time series) дегеніміз не және бұл жағдайда қандай болжау әдістері қолданылады?

Уақыт қатарлары (Time Series) - уақыттың дәйекті сәттерінде жиналған, өлшенген немесе бақыланатын деректер тізбегі. Уақыт қатарлары жағдайында қолданылатын болжау әдістері:

ARIMA (Autoregressive Integrated Moving Average): авторегрессия, біріктірілген жылжымалы орташа және бақылаулар арасындағы айырмашылықтардың тіркесіміне негізделген Модель.
Регрессияны қолдану арқылы болжау: уақыт қатарларын болжау үшін сызықтық регрессия сияқты регрессиялық әдістерді қолдану.
Экспоненциалды тегістеу (экспоненциалды тегістеу): деректер деңгейі мен трендінің өзгеруін ескере отырып, уақыт қатарларын болжауға арналған әдіс.

3. Ауытқуларды (аномалий) анықтау тапсырмалары үшін қандай Машиналық оқыту әдістерін қолдануға болады?

Кластерлеу әдісі (мысалы, DBSCAN): деректердегі қалыптан тыс топтарды анықтау үшін қолданылады.
Мұғалімсіз оқыту әдістері (мысалы, isolation Forest): аномальды нүктелерді олардың қалған деректерден оқшауланuына қарай анықтайды.
One-Class SVM (Support Vector Machine): қалыпты мысалдармен оқытылады және ауытқуларды қалыпты деректерден ерекшеленетін нысандар ретінде анықтайды.

«Ақпараттық жүйелер» кафедрасы

№15 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Кескіндермен жұмыс істеу үшін қандай классификация алгоритмдері қолайлы?

Конволюциялық нейрондық желілер (Convolutional Neural Networks, CNN): CNN кескіндерді талдауға, белгілерді автоматты түрде шығаруға мамандандырылған және кескіндерді жіктеу тапсырмаларында жоғары тиімділікті көрсетеді.
Оқытуды тасымалдау (Transfer Learning): белгілі бір тапсырмаға бейімделген үлкен деректер жиынында оқытылған алдын ала дайындалған CNN үлгілерін пайдалану.

2. Көп класты классификация тапсырмаларында модельдің сапасын жақсарту үшін қандай әдістерді қолдануға болады?

Оңтайлы алгоритмді таңдау: белгілі бір тапсырма мен деректер үшін ең қолайлы жіктеу алгоритмін таңдау.
Атрибуттық инженерия (Feature Engineering): модельдің сапасын жақсарту үшін жаңа атрибуттар жасау немесе бұрыннан барларын түрлендіру.
Сыныпты теңестіру: сыныптарды теңестіру әдістерін қолдану, әсіресе сыныптар теңгерімсіз болса.
Гиперпараметрлерді теңшеу: болжау сапасын жақсарту үшін кросс-валидация арқылы модельдің гиперпараметрлерін оңтайландыру.
Ансамбльдік оқыту (Ensemble Learning): бірнеше модельдерді біріктіру және жіктеудің жалпы сапасын жақсарту үшін кездейсоқ орман немесе градиентті күшейту сияқты ансамбльдік әдістерді қолдану.

3. Мәтіндік деректермен жұмыс істеу кезінде қандай кластерлік алгоритмдер тиімді?

k-Means: мәтіндік құжаттарды ұқсастығы бойынша топтастыру үшін қолдануға болатын қарапайым және кеңінен қолданылатын кластерлеу алгоритмі.
Агломеративті кластерлеу (Agglomerative Clustering): мәтіндік деректер үшін тиімді болуы мүмкін иерархиялық кластерлеу әдісі, мұнда кластерлер ең ұқсас объектілерді біріктіру арқылы қалыптасады.
DBSCAN: бұл алгоритм кластерлердің тығыздығы немесе пішіні өзгерген кезде жақсы жұмыс істейді және мәтіндегі ауытқуларды анықтауда пайдалы болуы мүмкін.
Бұл алгоритмдер мәтіндік деректерді кластерлеуде тиімді болуы мүмкін, бірақ нақты алгоритмді таңдау деректер құрылымына және сіздің тапсырмаңыздың талаптарына байланысты.

«Ақпараттық жүйелер» кафедрасы

№16 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Шынайы сынып белгілері болмаған кезде кластерлеу сапасын қалай бағалауға болады?

Шынайы класс белгілері болмаған жағдайда кластерлеу сапасын бағалау үшін кластерлердің ішкі және сыртқы жарамдылығын бағалау әдістері қолданылады:

Ішкі бағалау:
Силуэт индексі (Silhouette Score): кластерлердіңактамдылығын және олардың бөлінуін ескере отырып, кластерлеу сапасын бағалайды.
Дэвис-Болдуин индексі (Davies-Bouldin Index): кластерлер арасындағы орташа қашықтықты олардың кластерішілік қашықтығын пайдаланып өлшейді.
B-Өлшем индексі (V-Measure Score): кластерлеудің дәлдігі мен толықтығын біріктіреді.

Сыртқы бағалау (егер кейбір априорлық білім болса):
Adjusted Rand Index (ARI): алынған кластерлерді белгілі сыныптармен салыстыру үшін қолданылады (егер бар болса).
Adjusted Mutual Information (AMI): кездейсоқ сәйкестікті ескере отырып, екі кластер арасындағы ұқсастық өлшемі.

2. Шешім ағаштарын құруда оңтайлы бөлуді таңдаудың қандай әдістері қолданылады?

Шешім ағаштарын құру кезінде түйіндерді бөлу үшін оңтайлы бөлуді таңдаудың әртүрлі әдістері қолданылады:
Джини критерийі (Gini Impurity): кездейсоқ таңдалған элементтің қате жіктелу ықтималдығын өлшейді, егер ол сынып белгілерінің таралуы бойынша кездейсоқ жіктелген болса.
Энтропиялық критерий(Entropy): деректер жиынындағы хаос немесе белгісіздік дәрежесін өлшейді.
Жіктеу қатесі (Classification Error): түйіндегі ең көп таралған сыныпқа жатпайтын элементтердің үлесін өлшейді.
Бұл критерийлер шешім ағашында әрбір түйінді салу кезінде оңтайлы үлестіруді таңдау үшін қолданылады.

3. Шешім ағаштарын оқытуда өткізіп алған мәндерді жоюдың қандай жолдарын қолдануға болады?

Шешім ағаштарын оқыту кезінде өткізіп алған мәндерді өңдеудің келесі әдістерін қолдануға болады:

Өткізіп алған мәндер үшін арнайы түйінді пайдалану: ағаштарда өткізіп алған мәндер үшін бөлек түйін болуы мүмкін, бұл өткізіп алған нысандарды бөлек бұтаққа бағыттайды.
Импутация: өткізіп алған мәндерді бағандағы орташа, медианалық немесе ең көп кездесетін мәнмен толтыру.
Өткізіп алған мәндерді өңдеу әдісін таңдау деректердің сипатына және нақты тапсырмаға байланысты.

«Ақпараттық жүйелер» кафедрасы

№17 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Градиентті бустинг алгоритмдерін пайдалану кезінде қандай негізгі параметрлерді реттеу керек?

Оқу жылдамдығы (learning rate): әр ағаштың қорытынды модельге қосқан үлесін анықтайды. Төмен оқу жылдамдығы жақсы нәтижеге қол жеткізу үшін көбірек ағаштарды қажет етуі мүмкін, бірақ қайта оқу мүмкіндігін азайтуы мүмкін.
Ағаш тереңдігі(tree depth): ансамбльдегі әрбір ағаштың максималды тереңдігі. Терең ағаштар қайта оқытуға әкелуі мүмкін, сондықтан тереңдікті бақылау маңызды.
Ағаштар саны (number of trees): ансамбльдегі ағаштар саны. Ағаштардың көп болуы модельдің дәлдігін жақсарта алады, бірақ сонымен бірге оқу уақытын арттыра алады.
Үлгі өлшемі(subsample): әрбір ағашты оқыту үшін пайдаланылатын деректердің үлесін анықтайды. Кіші үлгі қайта оқытуды азайтуы мүмкін.
Реттеудің гиперпараметрлері: модельдің күрделілігін айыппұл салу арқылы қайта оқытудың алдын алуға көмектесетін L1 және L2 (сәйкесінше XGBoost-та альфа және ламбда) реттеу параметрлері сияқты.

2. Болжамдардың сапасын жақсарту үшін модельдік ансамбльдерді қолданудың негізінде қандай принциптер жатыр?

Модельдік ансамбльдердің принциптері болжамдардың сапасын жақсарту үшін бірнеше модельдердің болжамдарын біріктіруге негізделген:

Модельдерді әртараптандыру: әр түрлі алгоритмдерді немесе модельдерді қолдану, осылайша әр модель деректерді әр түрлі бұрыштардан "көреді" және әр түрлі болжамдар жасайды.
Болжамдарды біріктіру: дәлірек және тұрақты болжамдар алу үшін көбінесе орташалау немесе дауыс беру арқылы әртүрлі модельдердің болжамдарын біріктіру.
Қайта оқытуды азайту: егер әртүрлі модельдер деректердің әртүрлі аспектілері бойынша қайта оқытылса, олардың комбинациясы жалпы қайта оқыту деңгейін төмендетуі мүмкін.

3. XGBoost пайдалану кезінде қайта оқытумен күресудің қандай әдістерін қолдануға болады?

XGBoost пайдалану кезінде қайта оқытумен күресу үшін келесі әдістерді қолдануға болады:

Оқу жылдамдығын төмендету (learning rate): оқу жылдамдығын төмендету арқылы әр ағаштың қорытынды модельге қосқан үлесін азайту.

Ағаш тереңдігін бақылау (tree depth): тым күрделі үлгілердің алдын алу үшін әр ағаштың максималды тереңдігін шектеу.
Реттеуді қолдану: модельдің күрделілігіне айыппұл салу үшін alpha және lambda сияқты реттеу параметрлерін реттеу.
Кросс-валидация және ерте тоқтату (early stopping): қайталанудың оңтайлы санын анықтау үшін кросс-валидацияны қолдану және қайта оқытудың алдын алу үшін оқуды ерте тоқтату.

«Ақпараттық жүйелер» кафедрасы

№18 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Нейрондық желілерді оқытуда жоғалту функцияларын оңтайландырудың қандай әдістері қолданылады?

Градиенттің түсуі (Gradient Descent): жоғалту функциясының градиентіне кері бағытта желі салмағын жаңарту. Стохастикалық градиенттің түсуі (SGD), шағын пакеттік градиенттің түсуі (mini-batch GD) және адаптивті оқу жылдамдығының әдістері (мысалы, Adam, RMSProp) сияқты әртүрлі нұсқалар бар.
Momentum: бұл әдіс оқуды дұрыс бағытта жылдамдату және тербелістерді азайту үшін градиенттің өзгеру жылдамдығын ескереді.
AdaGrad, RMSProp: градиент тарихына негізделген әрбір параметр үшін оқу жылдамдығын өзгертетін бейімделу әдістері.
Adam (Adaptive Moment Estimation): momentum және RMSProp әдістерінің тіркесімі, ол сирек деректермен және үлкен көлемдегі параметрлері бар тапсырмаларда тиімді жұмыс істейді.

2. Машиналық оқытуда регуляризация дегеніміз не және сіз регуляризацияның қандай түрлерін білесіз?

Машиналық оқытудағы регуляризация-бұл қайта оқытудың алдын алу үшін модельдің күрделілігін басқару әдісі. Ол модель параметрлеріне негізделген шығындар функциясына қосымша шектеулер немесе айыппұлдар қосады.

Реттеудің кейбір түрлері:
L1 регуляризация (Lasso): параметрлер салмағының абсолютті мәндерінің қосындысына пропорционалды шығын функциясына айыппұл қосады. Белгілерді таңдау үшін қолдануға болады, өйткені ол кейбір белгілердің салмағын нөлге дейін төмендетуі мүмкін.
L2 регуляризация (Ridge): шығын функциясына параметрлердің салмақ мәндерінің қосындысының квадратына пропорционалды айыппұл қосады. Барлық салмақтарды біркелкі азайтуға тырысады.
Dropout: оқыту кезінде кездейсоқ таңдалған нейрондарды елемейтін немесе "өшіретін" әдіс. Бұл қайта оқытудың алдын алуға көмектеседі, өйткені желі нақты мүмкіндіктерге толықтай сене алмайды.

3. Үлкен көлемдегі деректерді (үлкен деректерді оқыту) пайдалану арқылы оқыту үшін қандай Алгоритмдер қолданылады?

Үлкен көлемдегі мәліметтермен оқыту үшін арнайы әдістер мен құралдар қолданылады:

Шағын пакеттермен градиентті түсіру (Mini-batch Gradient Descent): модельдің салмағын жаңарту үшін үлкен көлемдегі деректерді шағын ішкі жиындарға (шағын пакеттерге) бөлу арқылы тиімді өңдеуге мүмкіндік береді.

Ағындық алгоритмдер (Streaming Algorithms): бүкіл деректер жиынтығын жадқа жүктемей-ақ, деректерді бөліктермен немесе ағындармен өңдей алатын Алгоритмдер.
Үлестірілген оқыту алгоритмдері: мысалы, Apache Spark MLlib, компьютер кластерлерінде модельдерді оқытуға мүмкіндік беретін үлестірілген есептеулерді қолданатын TensorFlow.
Бұл әдістер мен құралдар жад пен есептеу ресурстарының шектеулерін ескере отырып, үлкен көлемдегі деректерде модельдерді тиімді өңдеуге және үйретуге көмектеседі.

«Ақпараттық жүйелер» кафедрасы

№19 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Классификация есептерінде теңгерімсіз сыныптармен жұмыс істеу үшін қандай әдістерді қолдануға болады?

Классификация шегін өзгерту: болжамның қай сыныпқа жататынын анықтайтын шекті өзгерту. Бұл теңгерімсіз сыныптармен жұмыс істеу кезінде пайдалы болуы мүмкін.
Апсамплинг және даунсамплинг: сыныптар арасындағы тепе-теңдікке жету үшін кіші класс элементтерінің санын көбейту (апсамплинг) немесе үлкен класс элементтерінің санын азайту (даунсамплинг).
Сынып салмағын пайдалану: кейбір Машиналық оқыту алгоритмдері сынып салмағын орнатуға мүмкіндік береді, бұл модельге аз ұсынылған сыныптарға көбірек көңіл бөлуге мүмкіндік береді.
Ансамбльдерді пайдалану: кездейсоқ орман немесе градиентті күшейту сияқты модельдік ансамбльдерді құру теңгерімсіз сыныптар үшін болжамдарды жақсартуға көмектеседі.

2. Мәтіндік деректермен қандай классификация алгоритмдері жұмыс істей алады?

Нейрондық желілер: қайталанатын нейрондық желілер (RNN), конволюциялық нейрондық желілер (CNN) және трансформаторлар көбінесе мәтіндік деректерді өңдеу және классификация үшін қолданылады.
Анықтамалық векторлық әдіс (SVM): SVM жол ядросы (string kernels) сияқты мәтіндермен жұмыс істеу үшін арнайы жасалған ядролармен бірге қолдана алады.
Аңғал Байес классификаторы: мәтіндік деректер үшін тиімді, әсіресе сөз векторларын (Bag-of-Words) немесе TF-IDF қолданған кезде.
Градиентті күшейту: XGBoost, CatBoost және Light GSM сияқты кейбір градиентті күшейту кітапханалары дұрыс өңделген кезде мәтіндік деректермен жұмыс істей алады.

3. CatBoost-та категориялық деректерді автоматты түрде өңдеудің ерекшеліктері қандай?

Автоматты санатты кодтау: CatBoost алдын ала кодтауды қажет етпестен категориялық белгілерді автоматты түрде өңдейді. Ол категориялық деректермен тікелей жұмыс істейтін кодтау әдістерін қолданады.
Өткізіп алған мәндерді өңдеу: CatBoost алдын ала өңдеуді қажет етпестен категориялық белгілердегі өткізіп алған мәндермен жұмыс істей алады.
Қайта оқытуға төзімділік: CatBoost категориялық деректермен жұмыс істеу кезінде қайта оқыту қаупін азайту үшін кірістірілген әдістерге ие.

«Ақпараттық жүйелер» кафедрасы

№20 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Қандай кластерлік алгоритмдер жоғары өлшемді деректерді өңдей алады?

Оқу жылдамдығы (learning rate): әр ағаштың қорытынды модельге қосқан үлесін анықтайды. Төмен оқу жылдамдығы жақсы нәтижеге қол жеткізу үшін көбірек ағаштарды қажет етуі мүмкін, бірақ қайта оқу мүмкіндігін азайтуы мүмкін.
Ағаш тереңдігі (tree depth): ансамбльдегі әрбір ағаштың максималды тереңдігі. Терең ағаштар қайта оқытуға әкелуі мүмкін, сондықтан тереңдікті бақылау маңызды.
Ағаштар саны (number of trees): ансамбльдегі ағаштар саны. Ағаштардың көп болуы модельдің дәлдігін жақсарта алады, бірақ сонымен бірге оқу уақытын арттыра алады.
Үлгі өлшемі (subsample): әрбір ағашты оқыту үшін пайдаланылатын деректердің үлесін анықтайды. Кіші үлгі қайта оқытуды азайтуы мүмкін.
Реттеудің гиперпараметрлері: модельдің күрделілігін айыппұл салу арқылы қайта оқытудың алдын алуға көмектесетін L1 және L2 (сәйкесінше XGBoost-та альфа және ламбда) реттеу параметрлері сияқты.

2. Кластерлеу алгоритмдерін қолданар алдында өлшемділікті төмендетудің қандай әдістерін қолдануға болады?

Модельдік ансамбльдердің принциптері болжамдардың сапасын жақсарту үшін бірнеше модельдердің болжамдарын біріктіруге негізделген:

Модельдерді әртараптандыру: әр түрлі алгоритмдерді немесе модельдерді қолдану, осылайша әр модель деректерді әр түрлі бұрыштардан "көреді" және әр түрлі болжамдар жасайды.
Болжамдарды біріктіру: дәлірек және тұрақты болжамдар алу үшін көбінесе орташалау немесе дауыс беру арқылы әртүрлі модельдердің болжамдарын біріктіру.
Қайта оқытуды азайту: егер әртүрлі модельдер деректердің әртүрлі аспектілері бойынша қайта оқытылса, олардың комбинациясы жалпы қайта оқыту деңгейін төмендетуі мүмкін.

3. Шешім ағаштарын құру кезінде категориялық айнымалыларды өңдеудің қандай әдістерін қолдануға болады?

XGBoost пайдалану кезінде қайта оқытумен күресу үшін келесі әдістерді қолдануға болады:

Оқу жылдамдығын төмендету (learning rate): оқу жылдамдығын төмендету арқылы әр ағаштың қорытынды модельге қосқан үлесін азайту.

Ағаш тереңдігін бақылау (tree depth): тым күрделі үлгілердің алдын алу үшін әр ағаштың максималды тереңдігін шектеу.
Реттеуді қолдану: модельдің күрделілігіне айыппұл салу үшін alpha және lambda сияқты реттеу параметрлерін реттеу.
Кросс-валидация және ерте тоқтату (early stopping): қайталанудың оңтайлы санын анықтау үшін кросс-валидацияны қолдану және қайта оқытудың алдын алу үшін оқуды ерте тоқтату.

«Ақпараттық жүйелер» кафедрасы

№21 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Шешім ағаштарын құру үшін қандай критерийлерді қолдануға болады?

Джини критерийі (Gini Impurity): кездейсоқ таңдалған элементтің қате жіктелу ықтималдығын өлшейді, егер ол сынып белгілерінің таралуы бойынша кездейсоқ жіктелген болса.
Энтропиялық критерий(Entropy): деректер жиынындағы хаос немесе белгісіздік дәрежесін өлшейді.
Жіктеу қатесі (Classification Error): түйіндегі ең көп таралған сыныпқа жатпайтын элементтердің үлесін өлшейді.
Бұл критерийлер шешім ағашында әрбір түйінді салу кезінде оңтайлы үлестіруді таңдау үшін қолданылады.

2. Басқа машиналық оқыту әдістерімен салыстырғанда градиентті бустинг алгоритмдерінің қандай артықшылықтары мен кемшіліктері бар?

Артықшылықтары:
Жоғары дәлдік: градиентті бустинг әдетте болжаудың жоғары дәлдігін көрсетеді.
Қайта оқытуға төзімділік: параметрлерді дұрыс конфигурациялау арқылы градиентті бустинг қайта оқытуды азайтуға қабілетті.
Ол әртүрлі деректер түрлерімен жұмыс істей алады: ол сандық және категориялық деректермен жақсы жұмыс істейді.
Тапсырмалардың әртүрлі түрлерін өңдеу мүмкіндігі: регрессиялық тапсырмалар үшін де, жіктеу үшін де қолданыла алады.

Кемшіліктері:
Шу мен шығарындыларға сезімталдық: градиентті бустинг деректердегі шығарындылар мен шуларға сезімтал болуы мүмкін.
Оқу уақыты: модельдер тізбегін құруға байланысты градиентті бустинг жаттығулары көп уақытты алуы мүмкін.
Интерпретацияланбау: алынған модельдер сызықтық модельдер сияқты басқа әдістермен салыстырғанда аз түсіндірілуі мүмкін.

3. Бустинг алгоритмдерін қолданатын модельдердің оқу жылдамдығына қандай факторлар әсер етуі мүмкін?

Күшейту алгоритмдеріне негізделген модельдердің оқу жылдамдығы бірнеше факторларға байланысты болуы мүмкін:

Модель өлшемі: үлкен модельдер жадтан оқуға немесе дискіде сақтауға көп уақытты қажет етеді.

Ағаштар саны: ансамбльдегі ағаштар неғұрлым көп болса, модельді жүктеуге соғұрлым көп уақыт кетуі мүмкін.
Ағаштардың тереңдігі: тереңірек ағаштар оқу жылдамдығына әсер ететін көлемді үлгілерге әкелуі мүмкін.
Бірақ тұтастай алғанда, бустинг алгоритмдерін қолданатын модельдердің оқу жылдамдығы әдетте маңызды фактор емес және оқу уақыты модельдің оқу уақытымен салыстыруға келмейді.

«Ақпараттық жүйелер» кафедрасы

№22 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. AdaBoost алгоритмі қалай жұмыс істейді?

AdaBoost (Adaptive Boosting) — әлсіз модельдер ансамблін (әдетте шешім ағаштары) құратын және оларды күшті модельдер құру үшін біріктіретін Машиналық оқыту алгоритмі. AdaBoost оқыту процесі келесі қадамдардан тұрады:

Таразыны инициализациялау: әрбір деректер үлгісі бірдей салмақпен басталады.
Негізгі жіктеуішті құру: алдымен деректерді жіктеуге тырысатын әлсіз модель (мысалы, шешім ағашы) құрылады.
Қатені бағалау: AdaBoost оқу деректеріндегі негізгі жіктеуіштің қаншалықты қате екенін бағалайды.
Таразыны жаңарту: әрбір деректер үлгісінің салмағы қате жіктелген үлгілерді мұқият қарау үшін негізгі жіктеуіштің қателігі негізінде түзетіледі.
Процесті қайталау: бұл процесс бірнеше рет қайталанады, әр жолы жаңа әлсіз модельге сәйкес келеді және үлгілердің салмағын жаңартады.
Жіктеуіштердің тіркесімі: әрбір негізгі жіктеуіштің салмағы олардың дәлдігімен анықталады және осылайша олар біріктіріледі қорытынды күшті жіктеуіш.
Осылайша, AdaBoost жіктеуге ең қиын үлгілерді оқытуға бағытталған әлсіз модельдер ансамблін жасайды.

2. TSVM мен классикалық SVM арасындағы айырмашылық неде?

TSVM (Twin Support Vector Machine) классикалық SVM (Support Vector Machine) кеңейтімі болып табылады, ол екі сыныпты белгілейтін тапсырмаларға арналған және гиперпланды бөлу кезінде екі сыныптың ақпаратын ескеруге мүмкіндік береді. TSVM мен классикалық SVM арасындағы негізгі айырмашылықтар:

Деректерді өңдеу: классикалық SVM екілік жіктеу тапсырмаларын қарастырады, ал TSVM екі сынып белгісімен тапсырмаларды өңдейді.
Бөлу гиперпланы: TSVM екі сыныптағы ақпаратты ескеретін екі параллель гиперплан құрастырады, ал классикалық SVM бір гиперплан құрастырады.

3. SVM-де оңтайландыру тапсырмасы дегеніміз не?

SVM-де оңтайландыру міндеті екі деректер класы арасындағы алшақтықты барынша арттыратын оңтайлы бөлу гиперпланын табу болып табылады. Мұны оңтайландыру мәселесі ретінде тұжырымдауға болады, мұнда жіктеу қатесі азайған жағдайда гиперплан үшін оңтайлы салмақтарды (немесе коэффициенттерді) табу керек.

SVM оңтайландыру тапсырмасының негізгі мақсаты:
Саңылауды максимизациялау: SVM әртүрлі кластардың нүктелері арасындағы қашықтықты (алшақтықты) барынша арттыратын гиперпланды табуға тырысады, бұл модельдің жалпылау қабілетін жақсартады.
Қолдау векторлар: бұл гиперпланға жақын деректер нүктелері, олар бөлетін гиперпланның орнын анықтауда шешуші рөл атқарады.
Регуляция: SVM оңтайландыру міндеті сонымен қатар үлкен салмақтар немесе коэффициенттер үшін айыппұл салу арқылы қайта оқытуды болдырмайтын регуляризацияны қамтиды.

«Ақпараттық жүйелер» кафедрасы

№23 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Уақыт қатарлары контекстінде SVMT мен классикалық SVM арасындағы айырмашылық неде?

SVMT-бұл уақыт қатарларымен жұмыс істеу үшін арнайы жасалған классикалық SVM модификациясы. SVMT мен классикалық SVM арасындағы негізгі айырмашылықтарға мыналар жатады:
Уақыт сипаттамаларын есепке алу: SVMT деректерді уақыт құрылымын есепке алмай өңдейтін классикалық SVM-ге қарағанда дәйектілік, тенденциялар және корреляциялар сияқты деректердің уақыт сипаттамаларын ескереді.
Қосымша мүмкіндіктерді пайдалану: svmt көбінесе модельді оқытуға арналған уақыт қатарларын ұсыну үшін кідірістер, трендтер, маусымдық және т.б. сияқты уақытқа негізделген қосымша мүмкіндіктерді немесе белгілерді пайдаланады.
Уақыт деректерінің динамикасына бейімделу: SVMT уақыттың өзгеруін ескеруі мүмкін, бұл деректердегі өзгеретін уақыт құрылымдары мен мінез-құлықтарын өңдеуге көмектеседі.

2. SVMT қолдану контекстінде уақыт қатарларының қандай ерекшеліктері бар?

SVMT пайдалану кезінде ескерілетін уақыт қатарының ерекшеліктері:

Уақыт құрылымы: Уақыт қатарлары реттелген деректер тізбегіне ие, бұл құрылымды есепке алу үшін арнайы өңдеуді қажет етеді.
Маусымдық және трендтер: уақыт қатарларында талдау және болжау үшін маңызды болуы мүмкін маусымдық және трендтік компоненттер болуы мүмкін.
Ауытқулар мен шығарындылар: уақыт қатарларында svmt моделін оқыту кезінде ескерілетін ауытқулар мен шығарындылар болуы мүмкін.

3. Уақыт қатарларын талдау үшін SVMT қандай салаларда қолданылады?

SVMT әртүрлі салаларда қолданылуы мүмкін, соның ішінде:
Қаржылық талдау: акциялар бағасын болжау, қаржылық қатарларды талдау.
Өнеркәсіп және өндіріс: өндірістік процестерді бақылау, жабдықтың істен шығуын болжау.
Медициналық диагностика: медициналық деректерді талдау, уақытша көрсеткіштерге негізделген ауруларды болжау.
SVMT осы және басқа салаларда уақыт сериялярын талдау үшін кеңінен қолданылады, өйткені деректердің уақыт сипаттамаларын ескеру және заңдылықтарды анықтау мүмкіндігі бар.

«Ақпараттық жүйелер» кафедрасы

№24 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. Сызықтық емес деректермен жұмыс істеу үшін SVM-де қандай ядро түрлері қолданылады?

SVM модельге сызықтық емес деректермен жұмыс істеуге мүмкіндік беретін ерекшеліктер кеңістігін түрлендіру үшін ядроларды пайдаланады. Ядролардың кейбір түрлері:
Сызықтық ядро (Linear Kernel): сызықтық бөлінетін деректер үшін қолданылады және ешқандай түрлендірулерді қолданбайды.
Көпмүшелік ядро (Polynomial Kernel): деректерді жоғары өлшемді кеңістікке түрлендіреді, бұл модельге сызықтық емес тәуелділіктерді ескеруге мүмкіндік береді. Оның көпмүшелік дәрежесін беретін дәреже параметрі бар.
RBF (Radial Basis Function) ядро: бұл SVM үшін ең танымал бірі. RBF Гаусс ядросын пайдаланып деректерді шексіз өлшемді кеңістікке түрлендіреді.
Сигмоидты ядро (Sigmoid Kernel): бұл деректерді сигмоидтық функция арқылы түрлендіру және деректер сызықтық емес бөлінген кезде пайдалы болуы мүмкін.

2. SVM-дің басқа классификация әдістерімен салыстырғанда қандай артықшылықтары мен кемшіліктері бар?

Артықшылықтары:
Үлкен өлшемді кеңістіктердегі тиімділік: көптеген белгілері бар кеңістіктерде жақсы жұмыс істейді.
Қайта оқытуды азайту: қайта оқытудың алдын алу үшін кіріктірілген механизмдері бар.
Ядролардың әмбебаптығы: әртүрлі деректер түрлерімен жұмыс істеу үшін әртүрлі ядроларды пайдалана алады.
Бөлгіш гиперпландарды қолдау: күрделі бөлгіш беттерді құра алады.

Кемшіліктері:
Үлкен деректер жиынындағы тиімсіздік: SVM өте үлкен деректер жиынында тиімсіз болуы мүмкін.
Ядроны таңдау: дұрыс ядроны таңдау қиын болуы мүмкін.
Параметрлерге сезімталдық: параметрлерді таңдауға сезімтал және оны реттеу қажет.

3. TSVM қандай салаларда қолданылады?

TSVM (Twin Support Vector Machine) векторларға (объектілерге) екі жақты қолдау қажет болатын жерлерде қолданылады, мысалы:
Биомедициналық диагностика: ауруларды жіктеу және диагностикалау үшін медициналық деректерді талдау.
Қаржылық талдау: нарықты болжау, несиелік тәуекелді бағалау.

Аномалияларды анықтау: деректердегі қалыптан тыс үлгілерді немесе мінез-құлықтарды анықтау.
TSVM векторларға екі жақты қолдау көрсетеді, бұл деректер күрделі құрылымдарға ие немесе әртүрлі сыныптардағы ақпаратты қамтитын жағдайларда пайдалы болуы мүмкін.

«Ақпараттық жүйелер» кафедрасы

№25 ЕМТИХАН БИЛЕТІ

«IZHMN 3214 Интеллектуалды жүйелердің математикалық негіздері» пәні бойынша «6B06103 – Ақпараттық жүйелер» білім беру бағдарламасының білім алушыларына арналған.

1. AdaBoost - та қандай негізгі алгоритмдер жиі қолданылады?

AdaBoost (Adaptive Boosting) қолданады әлсіз оқушылар (weak learners) негізгі Алгоритмдер ретінде. Көбінесе қарапайым модельдер негізгі Алгоритмдер ретінде қолданылады, мысалы:
Таяз тереңдіктегі шешуші ағаштар: көбінесе adaboost-тағы негізгі алгоритмдер үшін ең көп таралған таңдау болып табылады, өйткені олардың қарапайымдылығы мен деректердің әртүрлі бөліктерінде үйрену қабілеті.
Сызықтық модельдер (мысалы, логистикалық регрессия): кейде әлсіз оқушылар ретінде қолданылады.
Әлсіз оқушылар жиынтығы: бұл, мысалы, жақын көршілердің k модельдері немесе аз итерациялары бар тірек векторларының әдістері болуы мүмкін.
AdaBoost бұл әлсіз студенттерді дәйекті түрде қолданады, әр жолы алдыңғы модель дұрыс жіктелмеген деректер үлгілеріне назар аударады.

2. TSVM орналастырылған деректердің шектеулі саны жағдайында жіктеу мәселелерін қалай шешеді?

TSVM (Twin Support Vector Machine) классикалық SVM кеңейтімі болып табылады, ол деректер саны шектеулі жағдайларға арналған. Ол екі параллель гиперплан арасындағы алшақтықты ұлғайту арқылы модельді құруда қолданылатын ақпарат мөлшерін көбейтуге тырысады, орналастырылған деректер үшін бұл алшақтықты барынша арттырады.
TSVM орналастырылған деректердегі барлық қол жетімді ақпаратты пайдалана отырып, екі сынып арасындағы қашықтықты барынша арттыруға тырысады. Бұл tsvm-ге шешім қабылдау үшін шектеулі деректерді тиімді пайдалануға мүмкіндік береді.

3. AdaBoost негізгі модельдердің қателіктеріне қалай бейімделеді?

AdaBoost әлсіз оқушыларды алдыңғы оқушылар дұрыс жіктемеген үлгілерге дәйекті түрде үйретеді. Әрбір жаңа оқушы осы қателіктерді ескеруге және болжамдарды жақсартуға тырысып, алдыңғы модельдер қателескен үлгілерге назар аударады.
Оқушылар санының артуымен AdaBoost қателерді белсенді түрде түзетеді және түзетеді, бұл әрбір келесі модельді алдыңғы үлгілердің күштірек және қатеге төзімді етеді. Осылайша, AdaBoost жіктеуге қиын үлгілерге назар аудара отырып, негізгі модельдердің қателіктеріне бейімделуге тырысады.