№1 Емтихан билеті

1. Элементар оқиғалар кеңістігі (үлгі кеңістігі)

1. Үлгі (іріктеу) кеңістігі (қарапайым оқиғалар кеңістігі)

Біз ықтималдылықты Ω үлгі (іріктеу) кеңістігінен бастап жиынтық теориясы арқылы анықтаймыз. Бұл біз қарастырып отырған жағдайда болуы мүмкін барлық оқиғалардың жиынтығы. Осындай потенциалды нәтиженің бірі $\omega \in \Omega$ - бұл үлгінің нәтижесі немесе элементар оқиға, бұл Ω жиынының элементі. Әдетте бізді үлгі кеңістігінің $A \subseteq \Omega$ ішкі жиыны болып табылатын оқиға қызықтырады.

Мысал: 6 қырлы текшеге арналған дискретті үлгі кеңістігі

Бір адал 6 қырлы сүйекті лақтыруды қарастырайық. Сонда Ω = {1, 2, 3, 4, 5, 6}. Бір лақтыру ω = 3 нәтижесіне әкелуі мүмкін. Оқиға A = {1, 3, 5}, кез келген тақ сан болуы мүмкін.Онда тақ санның түсу ықтималдығы **Pr**(A) = |{1, 3, 5}|/|{1, 2, 3, 4, 5, 6}| = 1/2 болады.

Pr(A) оқиғасының *ықтималдығы* келесі қасиеттерді қанағаттандырады:

- $0 \leq$ **Pr**(A) ≤ 1 кез келген A *үшін*,
- **Pr**(Ω) = 1, және
- Қиылыспайтын оқиғаларды біріктіру ықтималдығы олардың жеке ықтималдықтарының қосындысына тең.

Ресми түрде, кез-келген $A_1, A_2, \ldots$ тізбегі үшін, мұндағы барлық $i \neq j$ үшін, бұл $A_i \cap A_j = \varnothing$, онда

Мысал: біржақты (адал емес) монета үшін ықтималдық

Енді Ω = {H, T} екі ықтимал оқиғасы бар біржақты монетаны лақтыруды қарастырайық (яғни бүркіт $H = A_1$ және құйрық $T = A_2$). Монета адал емес, сондықтан бұл оқиғалардың **Pr**(H)= 0,6 және **Pr**(T) = 0,4 ықтималдығы тең емес. Дегенмен, біз әлі де $0 \leq$ **Pr**(T), **Pr**(H) $\leq$ 1 және Pr(Ω) = **Pr**($H \cap T$) = **Pr**(H)+ **Pr**(T) = 0,6 + 0,4 = 1 екенін байқаймыз. Яғни, Ω үлгі кеңістігі бір уақытта пайда бола алмайтын, осы екі оқиғаның бірігуі болып табылады (яғни $H \cap T = \varnothing$), сондықтан олар қиылыспайды. Осылайша, Ω ықтималдығы осы екі оқиғаның ықтималдықтарының қосындысы ретінде жазылуы мүмкін.

Дискретті шамаларға ие болмайтын су, уақыт немесе жер массасы сияқты шамаларды көрсете отырып, Ω таңдамалы кеңістіктері де үздіксіз болуы мүмкін. Жоғарыда келтірілген барлық анықтамалар осы параметр үшін жарамды.

2. Нормалар

Келесі $v = (v_1, v_2, \ldots, v_d) \in \mathbb{R}^d$ векторының стандартты Евклид нормасы ("ұзындық" туралы ойланыңыз) анықталған

$$\|v\| = \sqrt{\sum_{i=1}^{d} v_i^2} = \sqrt{v_1 v_1 + v_2 v_2 + \ldots + v_d v_d} = \sqrt{\langle v, v \rangle}.$$

Бұл координаттардың басынан v нүктесіне дейінгі "түзу" қашықтықты өлшейді. v векторы $\|v\| = 1$ нормасымен *бірлік вектор* деп аталады; кейде $\|x\| = 1$ нормасымен x векторы *нормаланған* деп аталады.

Алайда, "норма" - бұл жалпы түсінік. L_p *нормалары* деп аталатын класс кез-келген $p \in [1, \infty)$ параметрі үшін нақты анықталған:

$$\|v\|_p = \left(\sum_{i=1}^{d} |v_i|^p \right)^{1/p}.$$

Осылайша, p көрсетілмеген кезде, ол $p = 2$ деп болжанады. Сондай-ақ, $\|v\|_\infty = \max_{i=1}^{d} |v_i|$, белгілеу қабылданған, бұл да норма. Шынында да, бұл p шегін ∞ - ке тең деп қабылдаудың нәтижесі.

Біз сондай-ақ A матрицасы үшін нормаларды анықтай аламыз. Олар сәл өзгеше шартты белгілерді қолданады. Екі ең көп таралған болып табылатындар $\|A\| = \|A\|_2$ спектрлік норма және $\|A\|_F$ Фробениус нормасы. *Фробениус нормасы* векторлар үшін $p = 2$ нормасының ең табиғи кеңеюі болып табылады, бірақ оның орнына F индексі қолданылады. Бұл $A \in \mathbb{R}^{n \times d}$ матрицасы үшін келесідей анықталады

$$\|A\|_F = \sqrt{\sum_{i=1}^{n} \sum_{j=1}^{d} A_{i,j}^2} = \sqrt{\sum_{i=1}^{n} \|a_i\|^2},$$

мұндағы $A_{i,j}$ - A-ның i-ші жолындағы және j-ші бағанындағы элемент, ал a_i - A-ның i-ші жолының векторы. $A \in \mathbb{R}^{n \times d}$ матрицасы үшін *спектрлік норма* келесідей анықталады

$$\|A\| = \|A\|_2 = \max_{\substack{x \in \mathbb{R}^d \\ \|x\| \neq 0}} \|Ax\| / \|x\| = \max_{\substack{y \in \mathbb{R}^n \\ \|y\| \neq 0}} \|yA\| / \|y\|.$$

Осы x және y векторларын бірлік векторлары ретінде қарастырған пайдалы, онда бөлімді елемеуге болады (өйткені олар 1-ге тең). Содан кейін біз x және y тек "бағытталған" ақпаратты қамтитынын көреміз, ал *arg max* векторы (мысалы, $\|Ax\|/\|x\|$ максимизациялайтын x) норманы максимизациялайтын бағыттарды көрсетеді.

3. Лассо

2. Лассо

Мұндай реттеудің таңқаларлық типті нұсқасы лассо деп аталады. Ол $s > 0$ параметрін қайтадан пайдаланып, $W_\diamond$ шығындар функциясын ауыстырады

$$W_\diamond(X, y, \alpha, s) = \frac{1}{n} \|X\alpha - y\|_2^2 + s\|\alpha\|_1.$$

Бұл жоталық регрессиясымен бірдей ортақ пішінге ие болады, бірақ регуляризатор нормасының $\|\cdot\|_2^2$-ден $\|\cdot\|_1$-ге шамалы өзгеруіне әкеледі.

Регуляризацияның бұл альтернативті түрі барлық негізгі сенімділікке ие және жотаның регрессиясындағы α-ның аз нормаланған таңдауына қарай жылжумен байланысты, жалпылаудың күшті қасиеттеріне ие болады. Дегенмен, оның екі қосымша әсері бар. Біріншіден, L_1 нормасын оған қатысты оңтайландыру оңай емес. Алгоритмдік және комбинаторлық тәсілдер болғанымен, кері матрицаны қолданатын қарапайым жабық форма енді жоқ. Жақында біз осы объектіні оңтайландырудың бірнеше әдісін талқылаймыз, келесі тараудың жалпы мазмұнында. Екіншіден, бұл формуланың қосымша артықшылығы бар, ол сонымен қатар сиретілген шешімдерге сүйенеді. Яғни, s мәндері жеткілікті үлкен болса,

$$\alpha_s^\diamond = \arg\min_\alpha W_\diamond(X, y, \alpha, s)$$

оңтайлы таңдауы бірнеше $\alpha_{s,j}^\diamond = 0$ координаттарына ие болады. Жалпы, s өскен сайын $\alpha_{s,j}^\diamond = 0$-мен j индекстерінің саны артады.

№2 Емтихан билеті

1. Дискретті үлгі кеңістігі

Мысал: 6 қырлы текшеге арналған дискретті үлгі кеңістігі

Бір адал 6 қырлы сүйекті лақтыруды қарастырайық. Сонда Ω = {1, 2, 3, 4, 5, 6}. Бір лақтыру ω = 3 нәтижесіне әкелуі мүмкін. Оқиға A = {1, 3, 5}, кез келген тақ сан болуы мүмкін.Онда тақ санның түсу ықтималдығы **Pr**(A) = |{1, 3, 5}|/|{1, 2, 3, 4, 5, 6}| = 1/2 болады.

Pr(A) оқиғасының *ықтималдығы* келесі қасиеттерді қанағаттандырады:

- $0 \le$ **Pr**(A) ≤ 1 кез келген A *үшін*,
- **Pr**(Ω) = 1, және
- Қиылыспайтын оқиғаларды біріктіру ықтималдығы олардың жеке ықтималдықтарының қосындысына тең.

Ресми түрде, кез-келген $A_1, A_2, \ldots$ тізбегі үшін, мұндағы барлық $i \neq j$ үшін, бұл $A_i \cap A_j = \varnothing$, онда

2. Матрица рангі

5. Ранг

$X = \{ x_1, x_2, \ldots, x_n \}$ векторлар жиынының *рангі* - бұл сызықтық тәуелсіз $X' \subset X$ ең үлкен ішкі жиынының өлшемі. Біз әдетте ранг (A)-ні A матрицасының рангі ретінде біліміз. Ол матрица жолдарының рангі немесе оның бағандарының рангі ретінде анықталады; белгілі болғандай, бұл шамалар әрқашан бірдей.

Егер $A \in \mathbb{R}^{n \times d}$, онда ранг($A$) $\le \min\{n, d\}$. Егер ранг(A) = $\min\{n, d\}$, онда A толық ранг деп есептеледі. Мысалы, егер $d < n$, онда, $A = [a_1; a_2; \ldots; a_n]$ жолдарын қолдана отырып, кез-келген $z \in \mathbb{R}^d$ векторын осы жолдардың сызықтық үйлесімі ретінде сипаттай аламыз: $z = \sum_{i=1}^{n} \alpha_i a_i$ кейбір $\{\alpha_1, \ldots, \alpha_n\}$ жиыны үшін. Шындығында, Егер A толық ранг болса, біз мұны жасай аламыз және d-ден басқа барлық скалярларды 0-ге теңестіре аламыз.

3. Қос шектеулермен тұжырымдау

3. Қос шектеулермен тұжырымдау

Жоталық регрессия үшін де, лассо үшін де олардың оңтайландыру қасиеттерін түсінуді жеңілдететін, сондай-ақ оларды шешу үшін қолданылатын жалпы тәсілді сипаттайтын баламалы тұжырым бар. Яғни, $W_\circ$ және $W_\square$ өзгертілген мақсатты функцияларын шешудің орнына, біз бастапқы $\|X\alpha - y\|_2^2$ ең кіші квадраттар есебін шеше аламыз, бірақ оның орнына α мүмкін мәндеріне қатаң шектеу енгізе аламыз.

Атап айтқанда, біз кейбір $t > 0$ параметрі үшін жоталық регрессияны келесідей қайта құра аламыз

$$\alpha_t^\circ = \underset{\alpha}{\operatorname{argmin}} \|X\alpha - y\|_2^2 \quad \text{such that} \quad \|\alpha\|_2^2 \le t$$

тағы да, қандай да бір $t > 0$ қолдана отырып, лассоны жазамыз

$$\alpha_t^\circ = \underset{\alpha}{\operatorname{argmin}} \|X\alpha - y\|_2^2 \quad \text{such that} \quad \|\alpha\|_1 \le t.$$

$s > 0$ әрбір параметрі мен α_s° шешімі үшін жоталық регрессия үшін сәйкес $t > 0$ параметрі бар, сондықтан $\alpha_t^\circ = \alpha_s^\circ$. Және сәйкесінше, әрбір s үшін лассо үшін t бар, сондықтан $\alpha_s^\circ = \alpha_t^\circ$. Бұған көз жеткізу үшін бекітілген s үшін α_s° шешімді табыңыз (мысалы, жабық пішіндегі шешімді пайдалану арқылы), содан кейін $t = \|\alpha_s^\circ\|$ орнатыңыз.

Енді t осы мәнін қолдана отырып, α_t° шешімі α_s° шешіміне сәйкес келеді, өйткені ол қатаң норманың шегін қанағаттандырады, ал егер $\|X\alpha - y\|$ кіші мәнімен осы норманың шегін қанағаттандыратын, басқа α шешімі болса, бұл $W_\circ$ екі терминінде α_s° қарағанда аз болар еді, бұл α_s° оңтайлылығына қайшы келеді.

Демек, біз $W_\circ$ және $W_\lozenge$ жұмсақ норма тұжырымдамаларын немесе жоталық регрессия немесе лассо үшін қатаң норма тұжырымдарын шешуге назар аудара аламыз. Сайып келгенде, біз кросс-тексеруді қолдана отырып, s немесе t параметрлерін таңдау бойынша іздейміз, сондықтан сәйкестікті алдын-ала білудің қажеті жоқ.

№3 Емтихан билеті

1. Үздіксіз үлгі кеңістігі

Мысал: үздіксіз үлгі кеңістігі

Сіз әрқашан уақытында келетін швейцариялық пойызбен жүресіз делік, бірақ оның жөнелтілуі тек бір минутқа дейінгі дәлдікпен көрсетілген (атап айтқанда, кешкі 13:37-де). Онда шынайы жөнелту Ω = [1:37:00, 1:38:00) күй кеңістігінде болады .

A= [1:37:00 − 1:37:40) үздіксіз оқиға болуы мүмкін, осы минуттың алғашқы 40 секундтары.

Пойыз операторлары тәуекелге бейім болмауы мүмкін, сондықтан **Pr**(A) = 0,80. Бұл пойыздардың 0,8% - ы осы минуттың алғашқы 2/3 бөлігінде кететінін көрсетеді (теңөлшемді үлестіру кезінде күтілетін 0,666-дан аз).

Кездейсоқ шама X: $\Lambda \to \Omega$ - бұл Λ үлгі (іріктеу) кеңістігінің бір түрінен Ω басқасына бейнелейтін ***функция***.

Бұл Λ -ғы нәтижелерге Ω -гі мәнді береді. Көптеген жағдайларда $\Omega \subseteq \mathbb{R}$ үлгі кеңістігімен сәйкес келеді, мұндағы $\mathbb{R}$-нақты сандардың кеңістігі. Әдетте, кездейсоқтық әлі орындалмаған экспериментке немесе жоспарланған бақылауға жатады, бұл іріктеу кеңістігіндегі нәтижеге, содан кейін кездейсоқ шаманың нәтижелік салыстырылған мәніне әкеледі. Бірінші іріктеу кеңістігі Λ көбінесе маңызды емес және еленбейді.

2. Кері матрица

6. Кері матрица

A матрицасы квадраттық деп аталады, егер онда қанша жол болса, сонша баған болса. $A \in \mathbb{R}^{n\times n}$ квадрат матрицасы A^{-1} деп белгіленген кері мәнге ие болуы мүмкін. Егер ол бар болса, онда бұл келесіні қанағаттандыратын бірегей матрица:

$$A^{-1}A = I = AA^{-1}$$

мұндағы I - $n \times n$ бірлік матрицасы

$$I = \begin{bmatrix} 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & 0 \\ 0 & 0 & \dots & 0 & 1 \end{bmatrix} = \mathrm{diag}(1, 1, \dots, 1).$$

I скалярлық алгебрада 1 мақсатқа қызмет ететінін ескеріңіз, сондықтан кез-келген (нөлдік емес) α скаляр үшін $\alpha^{-1} = 1 / \alpha$ көмегімен бізде $\alpha\alpha^{-1} = 1 = \alpha^{-1}\alpha$ болады.

Матрица кері мәнге ие болса, қайтымды деп аталады. Тек толық рангілік квадрат матрицалар қайтымды; және матрица әрқашан квадраттық және толық рангілік болса, қайтымды болады. Егер матрица квадрат болмаса, кері функция анықталмайды. Егер матрица толық рангіге ие болмаса, онда оның кері матрицасы болмайды.

3. Сәйкестікті іздеу

Сәйкестікті іздеу (MP - matching pursuit) деп аталатын қарапайым процедураны сипаттаймыз, бұл регрессия есептерін шешуге қарапайым ашкөз баламасын ұсынады. Бұл әсіресе жабық пішіннің шешімі жоқ лассо нұсқалары үшін пайдалы. Атап айтқанда, MP-ның lasso мақсатымен орындалуы кезінде, онда ол кейде базис бойынша іздеу немесе ішкі жиынды тікелей таңдау деп аталады, өйткені ол тәуелді айнымалыға қатысты тенденцияларды бекітетін, X деректер матрицасындағы маңызды белгілер жиынтығын немесе негізді итеративті түрде анықтайды.

МР алгоритмі (5.5.1 алгоритмінде сипатталған) бекітілген s мәнін қолданады, бастапқыда барлық координаттарда $\alpha_j = 0$ мәнін орнатады және нөлдік емес болған кезде W_0 мақсатын азайтуға тырысатын, j координаттарын итеративті түрде таңдайды. Ол сондай-ақ W_0 көмегімен іске қосылуы мүмкін. Координаттар таңдалып, мән меншіктелген кезде, y-тің әлі қамтылмаған бөлігінің r қалдық векторы жаңартылады. Бастапқыда $r = y$, алгоритм орындалғанда және ең жақсы сәйкестіктер табылғанда $\|r\|_2^2$ қалауынша азаяды. Әрбір келесі циклде келесі ең жақсы координат тек r (бастапқы y емес) көмегімен таңдалады; бұл алгоритмді басқаруға мүмкіндік беретін негізгі идея. Және, атап айтқанда, мұны сызықтық операторды (нүктелік көбейтінді) максималды ететін j координатын таңдау арқылы жасауға болады.

$$j^* = \underset{j}{\operatorname{argmax}} |\langle r, X_j \rangle|$$

мұндағы X_j - X деректер матрицасының n-өлшемді j-ші бағаны. Онда α_{j^*} келесідей шешуге болады

$$\alpha_{j^*} = \underset{\gamma}{\operatorname{argmin}} \|r - X_j\gamma\|^2 + s|\gamma| = \frac{1}{\|X_j\|^2}\left(\langle r, X_j \rangle \pm \frac{s}{2}\right).$$

± таңдау (s/2 мүшесін қосу немесе азайту) толық мәнде тексерілуі керек.

Бұл алгоритм ашкөз және шынайы оңтайлы шешімге әкелмеуі мүмкін: ол бастапқыда шынайы оптимумға кірмейтін координатты таңдап, оған шынайы оңтайлы мән емес αj мәнін бере алады.Дегенмен, шу жеткілікті аз болатын жағдайлар бар және бұл тәсіл әлі де шынайы оптимумды табуға мүмкіндік береді. Әр қадамда жоталық регрессия үшін W_0 мақсатын қолданған кезде α_j шешімдері осы уақытқа дейін таңдалған барлық координаттар үшін шешілуі мүмкін; бұл тәсіл жергілікті минимумдарға төзімді және көбінесе *ортогоналды сәйкестікті іздеу* деп аталады.

Кез-келген мақсат үшін бұл k координаттарының белгіленген саны таңдалғанға дейін (5.5.1 алгоритміндегідей) немесе $\|r\|_2^2$ қалдық нормасы белгілі бір шектен төмен түскенше орындалуы мүмкін. Объектіні таңдау мақсатында бұл координаттарға олардың ең қолайлысы модельдеу тапсырмасы үшін анағұрлым сәйкес деп саналатын тәртіп беріледі.

Algorithm 5.5.1 Сәйкестікті іздеу

Set $r = y$; and $\alpha_j = 0$ for all $j \in [d]$

for i = 1 **to** k **do**

Set Xj = argmax $_{X_{j'} \in X} |\langle r, X_{j'} \rangle|$

Set $\alpha_j = \operatorname{argmin}_\gamma \|r - X_{j'}\|^2 + s|\gamma|$

Set $r = r - X_j\alpha_j$

Return α

№4 Емтихан билеті

1. Үлгі кеңістігінің геометриясы

Үлгі кеңістігінің геометриясы

Квадрат түрінде Ω үлгі кеңістігін жалпы түрде көрсету пайдалы болуы мүмкін. Онда (a) көрсетілгендей, A оқиғасы осы кеңістіктің ерікті жиыны болуы мүмкін.

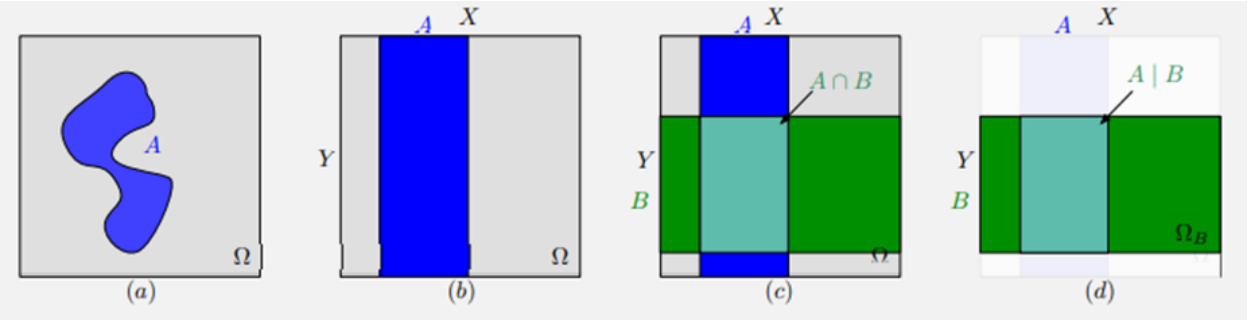
Үлгі кеңістігі екі кездейсоқ X және Y шамалары бойынша үлгілердің бірлескен кеңістігін сипаттаған кезде, Ω - ні оның x және y координаттары бойынша параметрлеу ыңғайлы болуы мүмкін, осылайша X мәні квадраттың бір жағында, ал Y мәні (b)-гі сияқты екінші жағында көрсетіледі. Онда $A \subset \Omega$ оқиғасы үшін, ол тек x мәніне қатысты (мысалы, $A = \{(x, y) \in \Omega \mid 0.2 \leq x \leq 0.5\}$), A оқиғасы A-ның x аймағымен қиылысуымен анықталған, тікбұрышты жолақ түрінде ұсынылады.

Егер сол сияқты B оқиғасы бар болса, ол тек y-координатасына қатысты (мысалы, $B = \{(x, y) \in \Omega \mid 0.1 \leq 0.6\}$), демек, тек Y кездейсоқ шамасына қатысты болса, онда (c)

көрсетілгендей басқа бағытта тағы бір тікбұрышты жолақ болады. Бұл оқиғалар тәуелсіз болған кезде, бұл жолақтар тек басқа $A \cap B$ тіктөртбұрышында қиылысады.

Кездейсоқ X және Y шамалары тәуелсіз болған кезде, $A = X$ және $B = Y$ оқиғаларымен анықталған барлық осындай жолақтар тіктөртбұрышта қиылысады. Егер оқиғалар тәуелсіз болмаса, онда олармен байланысты оқиғалар көрінісі (a) сияқты айқын көрінбейді.

Осындай $A \subset X$ және $B \subset Y$ тәуелсіз оқиғаларды ескере отырып, содан кейін $A \mid B$, (d) сияқты B-мен анықталған жолақпен шектелген, $A \cap B$ тіктөртбұрышымен жүзеге асырылуы мүмкін екенін байқаймыз. Сонымен қатар, пропорционалды ықтималдықтың ауданын көрсете отырып, біз $\mathbf{Pr}(A \mid B) = \mathbf{Pr}(A \cap B)/\mathbf{Pr}(B)$ екенін көре аламыз, өйткені B жолағы жаңа Ω_B шектеулі үлгі кеңістігін тудырады және оқиға тек, дәл $A \cap B$ тең, A-мен анықталған және қосымша шектелген, жолақпен туындаған тіктөртбұрышта болады.



2.Матрицаның анықтауышы

7. Анықтауыш

Матрица көлемінің түсінігі $|A|$ деп белгіленген A матрицасының детерминанты болып табылады. Ол тек квадрат матрицалар үшін анықталады. Бұл ең қарапайым индуктивті түрде анықталады. Өлшемі 2×2 болатын $B = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ матрицасы үшін детерминант $|B| = ad - bc$ арқылы анықталады. Бұл жағдайда ол $b - a$ және $d - c$ векторларымен анықталған параллелограммның ауданын анықтады.

$n \times n$ өлшемді A матрицасы үшін $n-1 \times n-1$ $\breve{A}_{i,j}$ ішкі матрицаны A-мен бірдей, бірақ i жолсыз және j бағанынсыз анықтаңыз. Енді детерминант A

$$|A| = \sum_{i=1}^{n} (-1)^{i+1} A_{1,i} \cdot |\breve{A}_{1,i}| = A_{1,1} \cdot |\breve{A}_{1,1}| - A_{1,2} \cdot |\breve{A}_{1,2}| + A_{1,3} \cdot |\breve{A}_{1,3}| - A_{1,4} \cdot |\breve{A}_{1,4}| + \dots$$

Мысалы, 3 × 3 матрица үшін

$$M = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix}$$

анықтауыш келесідей анықталады

$$|M| = a \left| \begin{bmatrix} e & f \\ h & i \end{bmatrix} \right| - b \left| \begin{bmatrix} d & f \\ g & i \end{bmatrix} \right| + c \left| \begin{bmatrix} d & e \\ g & h \end{bmatrix} \right|.$$

3.Функциялар. Минимумдар мен максимумдар

1. Функциялар

Біз $f: \mathbb{R}^d \to \mathbb{R}$ функциясының кейбір негізгі қасиеттерін қарастырамыз. Тағы да, мақсат көбінесе шағын өлшемдерде оңай ұсынылатын, бірақ жоғары өлшемді деректерге автоматты түрде жалпыланатын абстрактілі құралдарды ұсыну болады. Алдымен біз ешқандай есептеусіз анықтама береміз.

$B_r(\alpha)$ радиусы r болатын, $\alpha \in \mathbb{R}^d$ нүктесінің айналасындағы евклидтік шарды анықтасын делік. Яғни, ол α − дан r евклидтік қашықтықта орналасқан, барлық $\{p \in \mathbb{R}^d \mid \| \alpha - p\| \leq r\}$ нүктелерін қамтиды. Біз α нүктесінің айналасындағы жергілікті ауданды анықтау үшін $B_r(\alpha)$ қолданамыз. "Жергілікті" идеясы өте икемді және біз кез-келген $r > 0$ мәнін қолдана аламыз, негізінен, ол 0-ден қатаң үлкен болған жағдайда, ол біз қалағандай соншалықты кішкентай болуы мүмкін.

Минимумдар мен максимумдар. *Жергілікті максимум* f-бұл $\alpha \in \mathbb{R}^d$ нүктесі, сондықтан кейбір $B_r(\alpha)$ төңірегі үшін барлық $p \in B_r(\alpha)$ нүктелері α: $f(p) \leq f(\alpha)$ кезіндегіге қарағанда кіші (немесе тең) функция мәніне ие болады. *Жергілікті минимум* f-бұл $\alpha \in \mathbb{R}^d$ нүктесі, сондықтан кейбір $B_r(\alpha)$ төңірегі үшін барлық $p \in B_r(\alpha)$ нүктелері α: $f(p) \geq f(\alpha)$ кезіндегіге қарағанда үлкен (немесе тең) функция мәніне ие болады. Егер біз $p \in B_r(\alpha)$, $p \neq \alpha$ үшін екі анықтама үшін де "немесе тең" шартын алып тастасақ, онда максималды немесе минималды нүктелер қатаң деп айтамыз.

$\alpha \in \mathbb{R}^d$ нүктесі f *ауқымды максимумы* болып табылады, егер барлық $p \in \mathbb{R}^d$ үшін болса, онда $f(p) \leq f(\alpha)$. Сол сияқты, $\alpha \in \mathbb{R}^d$ нүктесі *ауқымды минимум* болып табылады, егер барлық $p \in \mathbb{R}^d$ үшін болса, онда $f(p) \geq f(\alpha)$. Бірнеше ауқымды минимумдар мен максимумдар болуы мүмкін. Егер ауқымды минимум немесе ауқымды максимум болып табылатын $\alpha \in \mathbb{R}^d$ дәл бір нүкте болса, біз оны тағы да *қатал* деп айтамыз.

Біз тек *минимум* немесе *максимум* терминін қолданған кезде (жергілікті немесе ауқымды емес), бұл жергілікті минимумды немесе максимумды білдіреді.

$S \subset \mathbb{R}^d$ тұйық және шектелген ішкі жиынымен шектелген, аумағы бар функцияға назар аудара отырып, егер функция үздіксіз болса (яғни, кез-келген жеткілікті кішкентай $\delta > 0$ мәні үшін, барлық $\alpha \in \mathbb{R}^d$ үшін, егер $p \in B_r\delta(\alpha)$ болса, онда $|f(\alpha) - f(p)| \leq \delta$ болатындай, r_δ радиусы бар), онда функция ауқымды минимумға және ауқымды максимумға ие болуы тиіс. Бұл S шекарасында болуы мүмкін.

$\alpha \in \mathbb{R}^d$ ($d > 1$ үшін) *седла (ершік) нүктесі* кез-келген $B_r(\alpha)$ маңында $f(p) < f(\alpha)$ -мен $p \in B_r(\alpha)$ (төменгі нүктелерге) және $f(p') > f(\alpha)$-мен $p' \in B_r(\alpha)$ нүктелерге (жоғарғы нүктелерге) ие болады. Атап айтқанда, егер $B_r(\alpha)$ ішінде жоғарғы нүктелердің (және төменгі нүктелердің) байланыспаған аймақтары болса, бұл *ершік*. *Ершік* нүктесі ұғымы $d = 1$ үшін әр түрлі анықталады. Егер бұл аймақтар жалғанған болса және бұл минимум немесе максимум болмаса, онда бұл *тұрақты* (тұрақты, қалыпты, дұрыс) *нүкте*.

Ерікті түрде (немесе кездейсоқ) таңдалған α нүктесі үшін бұл әдетте тұрақты (дұрыс) нүкте (сіздің бетпе-бет келуіңіз екіталай мысалдарды қоспағанда, минималды, максималды және *ершік* нүктелерінің жиыны ақырлы, ал тұрақты нүктелердің жиыны шексіз).

№5 Емтихан билеті

1. Шартты ықтималдық және тәуелсіздік

2. Шартты ықтималдық және тәуелсіздік

Енді А және В екі оқиғаны қарастырайық. Берілген B-ның A *шартты ықтималдығы* $\mathbf{Pr}(A \mid B)$ арқылы жазылады және B -ның ақиқат екенін білетін, орнатумен шектелген, A ықтималдығы ретінде түсіндірілуі мүмкін. Бұл $\mathbf{Pr}(A \mid B) = \mathbf{Pr}(A \cap B) / \mathbf{Pr}(B)$ ретінде қарапайым терминдермен анықталады, яғни A және B екеуінің де ақиқат болу ықтималдығы B-ның ақиқат болу ықтималдығына бөлінеді (қалыпқа келтіріледі).

Екі A және B оқиғалары

$$\mathbf{Pr}(A \mid B) = \mathbf{Pr}(A)$$

болғанда ғана бір-бірінен ***тәуелсіз*** болады.

Эквивалентті, алгебралық манипуляциялар арқылы олар $\mathbf{Pr}(B \mid A) = \mathbf{Pr}(B)$ болғанда ғана ***тәуелсіз*** болады, сонымен қатар $\mathbf{Pr}(A \cap B) = \mathbf{Pr}(A)\,\mathbf{Pr}(B)$ болғанда ғана. Бұл B туралы білім A ықтималдығына ешқандай әсер етпейтінін білдіреді (және керісінше A-дан B-ға дейін).

Мысал: Шартты ықтималдық

Т және С екі кездейсоқ шамасын қарастырайық, егер қатерлі ісік сынағы оң болса, Т айнымалысы 1-ге тең, әйтпесе 0-ге тең. Егер науқаста қатерлі ісік болса, С айнымалысы 1-ге, ал әйтпесе 0-ге тең. Оқиғалардың жалпы ықтималдығы келесі кестеде көрсетілген:

		рак	нет рака
		$C = 1$	$C = 0$
тесты положительные на рак	$T = 1$	0.1	0.02
тесты отрицательные на рак	$T = 0$	0.05	0.83

```
x = np.linspace(-3, 3, 201)
plt.plot(x, norm.pdf((x-mean)/sigma),linewidth=2.0, label='normal PDF')
plt.plot(x, norm.cdf((x-mean)/sigma),linewidth=2.0, label='normal CDF')
plt.legend(bbox_to_anchor=(.35,1))
plt.show()
```

Активация Windows

2. Векторлардың ортогоналдылығы

$x, y \in \mathbb{R}^d$ екі векторы *ортогоналды* болады, егер $\langle x, y \rangle = 0$ болса. Бұл осы векторлардың бір-біріне тік бұрышта орналасқанын білдіреді.

Мысал: Ортогоналдылық

$x = (2, -3, 4, -1, 6)$ және $y = (4, 5, 3, -7, -2)$ екі векторын қарастырайық. Олар ортогоналды, себебі

$\langle x, y \rangle = (2 \cdot 4) + (-3 \cdot 5) + (4 \cdot 3) + (-1 \cdot -7) + (6 \cdot -2) = 8 - 15 + 12 + 7 - 12 = 0.$

Қалыпқа келтірілген және барлығы бір-біріне ортогоналды бағандар жиынтығы *ортонормальды* деп аталады. Егер $V \in \mathbb{R}^{n \times d}$ және ортонормальды бағандары бар болса, онда $V^T V = I$ (мұндағы I - d × d), бірақ $VV^T \neq I$.

Барлық ортонормальды жолдар мен барлық ортонормальды бағандарға ие болатын $U \in \mathbb{R}^{n \times n}$ квадрат матрицасы *ортогоналды* болып табылады. Бұл мынаны білдіреді

$$U^T U = I = UU^T$$

себебі кез-келген нормаланған u векторы үшін, ол $\langle u, u \rangle = \|u\| = 1$, және $u_i \neq u_j$ кез-келген екі түрлі ортонормальды бағандар үшін, онда $\langle u_i, u_j \rangle = 0$. Ортогональды матрицалар көбейту кезінде норманы сақтайды. Бұл $U \in \mathbb{R}^{n \times n}$ ортогональды матрицасы және $x \in \mathbb{R}^n$ кез-келген векторы үшін, онда $\|Ux\| = \|x\|$ білдіреді.

Сонымен қатар, $U \in \mathbb{R}^{n \times n}$ ортогональды матрицаның $[u_1, u_2, \ldots, u_n]$ бағандары $\mathbb{R}^n$ үшін базисті құрайды. Бұл кез-келген $x \in \mathbb{R}^n$ векторы үшін $x = \sum_{i=1}^{n} \alpha_i u_i$. болатындай $\alpha_1, \ldots, \alpha_n$ скалярларының жиынтығы бар дегенді білдіреді. Одан да қызығы, бізде тағы $\|x\|^2 = \sum_{i=1}^{n} \alpha_i^2$. бар.

Мұны жаңа координаттар жиынтығына *бұрылысты* (мүмкінінше айналық айналдырулармен) сипаттайтын U деп түсіндіруге болады. Яғни, ескі x координаттары $(x_1, x_2, \ldots, x_n)$ тең, ал жаңа ортогональды базистегі $[u_1, u_2, \ldots, u_n]$ координаттары $(\alpha_1, \alpha_2, \ldots, \alpha_n)$ тең.

3. Дөңес функциялар

Дөңес функциялар. Көптеген жағдайларда біз функциямыздың дөңес екенін болжаймыз (немесе, кем дегенде, қалаймыз).

Мұны анықтау үшін кез-келген екі $p, q \in \mathbb{R}^d$ нүктелерімен $\ell \subset \mathbb{R}^d$ сызығын келесідей анықтау пайдалы болады. Онда $\ell_{p,q}$ түзуі - $\lambda \in \mathbb{R}$ кез-келген скалярымен анықталатын барлық нүктелердің жиыны

$$\ell_{p,q} = \{x = \lambda p + (1 - \lambda)q \mid \lambda \in \mathbb{R}\}.$$

$\lambda \in [0, 1]$ болғанда, бұл p мен q арасындағы түзудің кесіндісін анықтайды.

Функция *дөңес* болып табылады, егер $p, q \in \mathbb{R}^d$ кез-келген екі нүктесі үшін олардың арасындағы түзудің сегментінде орташа өлшенген p және q мәндерінен аз (немесе оған тең) мәнге ие болса. Яғни, ол дөңес болады, егер

Барлық $p, q \in \mathbb{R}$ үшін және барлық $\lambda \in [0, 1]$ үшін $f(\lambda p + (1 - \lambda)q) \leq \lambda f(p) + (1 - \lambda)f(q)$.

"Немесе тең" шартын алып тастағанда, функция қатаң дөңес болады.

Дөңес функциялардың көптеген қызықты қасиеттері бар. Мысалы, f және g екі дөңес функциялары үшін $h(\alpha) = f(\alpha) + g(\alpha)$ дөңес, сондықтан $h(\alpha) = \max\{f(\alpha), g(\alpha)\}$. Бірақ олардың бірі біз үшін ең маңызды болады:

Дөңестік және ауқымды минимумдар: Дөңес функцияның кез келген жергілікті минимумы да ауқымды минимум болады. Қатаң дөңес функция бір минимумнан аспайды: ауқымды минимум.

Бұл дегеніміз, егер біз минимумды тапсақ, онда біз ауқымды минимумды да тапқан болуымыз керек (біздің мақсатымыз).

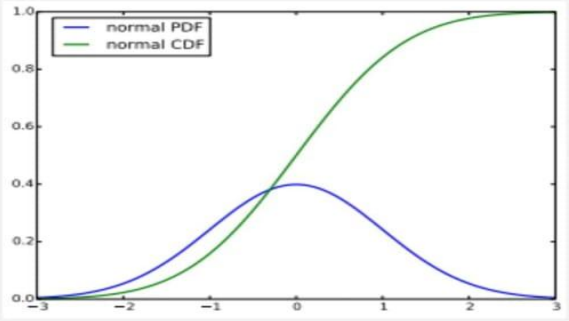
№6 Емтихан билеті

1. Қалыпты кесдейсоқ шама(1 лекция)

Мысал: Қалыпты кездейсоқ шама

X қалыпты кездейсоқ шамасы шуды модельдеу үшін өте кең таралған үлестіру болып табылады. Оның облысы $\Omega = \mathbb{R}$.

Стандартты қалыпты үлестірімнің pdf-ін $f_X(\omega) = \frac{1}{\sqrt{2\pi}} \exp(-\omega^2/2) = \frac{1}{\sqrt{2\pi}} e^{-\omega^2/2}$, анықтайды және оның cdf-ның тұйық түрдегі шешімі жоқ. Біз графикке [-3, 3] диапазонында cdf және pdf салдық, онда массаның көп бөлігі орналасқан:




```
import matplotlib.pyplot as plt
from scipy.stats import norm
import numpy as np
import math
mean = 0
variance = 1
sigma = math.sqrt(variance)
x = np.linspace(-3, 3, 201)
plt.plot(x, norm.pdf((x-mean)/sigma),linewidth=2.0,
label='normal PDF')
plt.plot(x, norm.cdf((x-mean)/sigma),linewidth=2.0,
label='normal CDF')
plt.legend(bbox_to_anchor=(.35,1))
plt.show()
```

2. Метрикалар(5 лекция)

1. Метрикалар

Сонымен, қашықтықты не жақсы етеді? Бұл сұраққа жауап берудің екі жағы бар. Біріншісі-бұл деректердің "дұрыс" қасиеттерін белгілейді, бірақ бұл кейде модельдеудің екіұшты мәселесі. Екіншісі неғұрлым нақты анықталған; бұл қашықтықты метрикаға айналдыратын қасиеттер.

Қашықтық **d**: $\mathcal{X} \times \mathcal{X} \to \mathbb{R}^+$ - бұл екі өлшемді оператор (ол екі аргументті қабылдайды, айталық, $a \in \mathcal{X}$ и $b \in \mathcal{X}$), ол $\mathbb{R}^+ = [0,\infty)$ -де көрсетіледі. Бұл метрика, егер

(M1) $\mathbf{d}(a, b) \geq 0$ (теріс еместік)

(M2) $\mathbf{d}(a, b) = 0$ егер a = b болса ғана (сәйкестік)

(M3) $\mathbf{d}(a, b) = \mathbf{d}(b, a)$ (симметрия)

(M4) $\mathbf{d}(a, b) \leq \mathbf{d}(a, c) + \mathbf{d}(c, b)$ (үшбұрыштың теңсіздігі)

(M1), (M3) және (M4) (бірақ (M2) міндетті емес) қанағаттандыратын қашықтық *псевдометриялық* деп аталады. (M1), (M2) және (M4) (бірақ (M3) міндетті емес) қанағаттандыратын қашықтық *квазиметриялық* деп аталады. Келесі бірнеше бөлімдерде біз деректерді талдауда қолданылатын әртүрлі жалпы қашықтықтарды сипаттаймыз және оларды пайдалану мысалдарын келтіреміз.

3. Градиент(10 лекция)

2. Градиенттер

$f(\alpha) = f(\alpha_1, \alpha_2, \ldots, \alpha_d)$ функциясы және бағытты білдіретін $u = (u_1, u_2, \ldots, u_d)$ бірлік векторы үшін *бағыт бойынша туынды* анықталады

$$\nabla_u f(\alpha) = \lim_{h \to 0} \frac{f(\alpha + hu) - f(\alpha)}{h}.$$

Бізді дифференциалданатын f функциялары қызықтырады; бұл барлық α және u үшін $\nabla_u f(\alpha)$ -ның жақсы анықталғанын білдіреді.

$e_1, e_2, \ldots, e_d \in \mathbb{R}^d$ - бұл бірлік векторлардың анықталған жиынтығы болсын, сонымен $e_i = (0, 0, \ldots, 0, 1, 0, \ldots, 0)$, мұнда e_i үшін 1 i-ші координатада орналасқан. Содан кейін келесіні анықтаңыз

$$\nabla_i f(\alpha) = \nabla_{e_i} f(\alpha) = \frac{\mathrm{d}}{\mathrm{d}\alpha_i} f(\alpha).$$

Бұл барлық басқа координаттарды тұрақты деп қарастыратын i -ші координата бойынша туынды.

Енді f *дифференциалданатын* функция үшін f *градиентін* келесідей анықтай аламыз

$$\nabla f = \frac{\mathrm{d}f}{\mathrm{d}\alpha_1} e_1 + \frac{\mathrm{d}f}{\mathrm{d}\alpha_2} e_2 + \ldots + \frac{\mathrm{d}f}{\mathrm{d}\alpha_d} e_d = \left(\frac{\mathrm{d}f}{\mathrm{d}\alpha_1}, \frac{\mathrm{d}f}{\mathrm{d}\alpha_2}, \ldots, \frac{\mathrm{d}f}{\mathrm{d}\alpha_d} \right).$$

Назар аударыңыз, ∇f - бұл $\mathbb{R}^d \to \mathbb{R}^d$ -дан функция, оны біз $\alpha \in \mathbb{R}^d$ кез-келген нүктесінде бағалай аламыз.

Мысал: Градиент

$\alpha = (x, y, z) \in \mathbb{R}^3$ үшін $f(x, y, z) = 3x^2 - 2y^3 - 2xe^z$ функциясын қарастырайық. Онда $\nabla f = (6x - 2e^z, -6y^2, -2xe^z)$ және $\nabla f(3, -2, 1) = (18 - 2e, -24, -6e)$.

№7 Емтихан билеті

1. Математикалық күтілім

4. Математикалық күтілім

Кездейсоқ шаманың күтілетін мәні X: $\Lambda \to \Omega$-бұл өте маңызды ұғым, мәні бойынша Ω өлшенген мәні, х ықтималдығымен өлшенеді. X дискретті кездейсоқ шамасы үшін ол, бейнеленетін таңдамалы кеңістіктегі ω барлық нәтижелерінің қосындысы немесе олардың $\omega \in \Omega$ мәнін олардың ықтималдығына көбейту ретінде анықталады

$$\mathbf{E}[X] = \sum_{\omega \in \Omega} (\omega \cdot \mathbf{Pr}[X = \omega]).$$

X үздіксіз кездейсоқ шамасы үшін

$$\mathbf{E}[X] = \int_{\omega \in \Omega} \omega \cdot f_X(\omega) \mathrm{d}\omega.$$

Математикалық күтілімнің сызықтығы: математикалық күтілімнің негізгі қасиеті-бұл сызықтық операция. Бұл дегеніміз, X және Y екі кездейсоқ шамалары үшін бізде $\mathbf{E}[X + Y] = \mathbf{E}[X] + \mathbf{E}[Y]$ бар. α скалярлық мәні үшін бізде $\mathbf{E}[\alpha X] = \alpha \mathbf{E}[X]$ бар.

Мысал: Математикалық күтілім

Әділ текшеде $\Omega = \{ \omega_1 = 1, \omega_2 = 2, \omega_3 = 3, \omega_4 = 4, \omega_5 = 5, \omega_6 = 6 \}$ үлгі кеңістігі бар және әр нәтиженің ықтималдығы $\mathbf{Pr}[D = w_i] = 1/6$ болады. Мұндай сүйекті лақтыру нәтижесінің D кездейсоқ шамасының күтілетін мәні

$$\mathbf{E}[D] = \sum_{\omega_i \in \Omega} \omega_i \cdot \mathbf{Pr}[D = \omega_i] = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = \frac{21}{6} = 3.5$$

Мысал: Математикалық күтілімнің сызықтығы

H-аяқ киімсіз метрдегі адам бойының кездейсоқ шамасы болсын. H үшін f_H pdf - қалыпты үлестіру, күтілетін мәні $\mu = 1{,}755$ м және стандартты ауытқуы 0,1 м болсын. S-сантиметрдегі аяқ киімді (1 метр 100 сантиметрге тең) киген кезде қосылатын, кездейсоқ бой шамасы болсын, оның *pdf* келесі кестеде келтірілген:

$S = 1$	$S = 2$	$S = 3$	$S = 4$
0.1	0.1	0.5	0.3

Онда сантиметрмен аяқ киім киген адамның күтілетін бойы

$\mathbf{E}[100 \cdot H + S] = 100 \cdot \mathbf{E}[H] + \mathbf{E}[S] = 100 \cdot 1.755 + (0.1 \cdot 1 + 0.1 \cdot 2 + 0.5 \cdot 3 + 0.3 \cdot 4) = 175.5 + 3 = 178.5$

Математикалық күтудің сызықтығы $100 \cdot H + S$ өрнегін оның компоненттеріне қалай ыдыратуға және әрқайсысының математикалық күтуін жеке қабылдауға мүмкіндік бергеніне назар аударыңыз. Бұл трюк көптеген факторлары бар күрделі сценарийлерді талдауда өте тиімді.

Активация Windows

2. Lp қашықтықтары

2.1 L_p қашықтықтары

$\mathbb{R}^d$-гі $a = (a_1, a_2, \ldots, a_d)$ және $b = (b_1, b_2, \ldots, b_d)$ екі векторды қарастырамыз. Енді L_p- қашықтығы келесідей анықталады

$$\mathbf{d}_p(a,b) = \|a-b\|_p = \left(\sum_{i=1}^{d}(|a_i - b_i|)^p\right)^{1/p}.$$

1. Ең көп тарағаны- L_2 қашықтық, оны *Евклидтік қашықтық* деп те атайды,

$$\mathbf{d}_2(a,b) = \|a-b\| = \|a-b\|_2 = \sqrt{\sum_{i=1}^{d}(a_i - b_i)^2}.$$

Бұл екі нүкте немесе векторлар арасындағы "түзу" қашықтық ретінде оңай түсіндіріледі, өйткені егер сіз екі нүктенің арасына түзу сызық сызсаңыз, оның ұзындығы евклидтік қашықтықты өлшейді.

Бұл сондай-ақ координаттар жүйесінің айналуына инвариантты (өзгермейтін) жалғыз L_p қашықтығы (біз көретініміздей, бұл жиі пайдалы, бірақ кейде шектеулі болады).

2. Тағы бір кең таралған қашықтық L_1 қашықтығы

$$\mathbf{d}_1(a,b) = \|a-b\|_1 = \sum_{i=1} |a_i - b_i|.$$

Ол сондай-ақ "Манхэттен" қашықтығы деп аталады, өйткені ол әрбір координаталық осьтегі ұзындықтардың қосындысын білдіреді; Манхэттен сияқты қалада жаяу жүру керек болатын қашықтық, себебі сіз көшеде қалуыңыз тиіс және ғимараттардан өте алмайсыз.

3. Модельдеудің тағы бір жалпы мақсаты L_0 қашықтығы

$$\mathbf{d}_0(a,b) = \|a-b\|_0 = d - \sum_{i=1}^{d} \mathbb{1}(a_i = b_i),$$

мұндағы $$\mathbb{1}(a_i = b_i) = \begin{cases} 1 & \textbf{if } a_i = b_i \\ 0 & \textbf{if } a_i \neq b_i. \end{cases}$$ Өкінішке орай, d_0 дөңес емес.

Әрбір a_i немесе b_i координаты 0 немесе 1 тең болғанда, бұл Хэмминг қашықтығы деп аталады.

4. Соңында, тағы бір пайдалы өзгеріс - L_∞ қашықтығы

$$\mathbf{d}_\infty(a,b) = \|a-b\|_\infty = \max_{i=1\ldots d} |a_i - b_i|.$$

Бұл кез-келген бір координата бойынша максималды ауытқу. Геометриялық тұрғыдан $\mathbb{R}^2$ -де бұл L_1 қашықтығын айналдыру, сондықтан L_1 үшін жасалған көптеген алгоритмдерді $\mathbb{R}^2$ -де L_∞-ке бейімдеуге болады. Алайда, үлкен өлшемдерде олар таңқаларлықтай әр түрлі әрекет ете алады. d_∞ техникалық тұрғыдан L_p қашықтығы емес, бірақ p -нің ∞ - ке өтетін арақашықтықтарының шегі болып табылады.

Жоғарыда келтірілген барлық қашықтықтар метрика болып табылады және жалпы L_p үшін метрика болып табылады, $p \in [1, \infty)$ үшін.

3. Градиенттің түсуі. Оқу жылдамдығы

3. Градиенттік түсу

Градиенттік түсу - бұл әдістер тобы, олар $f : \mathbb{R}^d \to \mathbb{R}$ дифференциалданатын функция үшін не келесіні анықтауға тырысады

$$\min_{\alpha \in \mathbb{R}^d} f(\alpha) \quad \text{және / немесе} \quad \alpha^* = \operatorname*{argmin}_{\alpha \in \mathbb{R}^d} f(\alpha).$$

Бұл f дөңес болған кезде тиімді және бізде "жабық пішінді" α^* шешімі жоқ. Алгоритм итеративті болып табылады, өйткені ол ешқашан толық оңтайлы α^* -ға жете алмауы мүмкін, бірақ ол жақынырақ және барынша жақынырақ бола түседі.

Algorithm 6.3.1 Gradient Descent(f, α_{start})
initialize $\alpha^{(0)} = \alpha_{\text{start}} \in \mathbb{R}^d$; $k = 0$.
repeat
$\alpha^{(k+1)} := \alpha^{(k)} - \gamma_k \nabla f(\alpha^{(k)})$;
increment $k = k + 1$.
until $(\|\nabla f(\alpha^{(k)})\| \leq \tau)$
return $\alpha^{(k)}$

Негізінде, $\alpha^{(0)}$ кез келген бастапқы нүкте үшін алгоритм градиентке қарама-қарсы бағытта, локальды f ең жылдам төмендейтін бағытта басқа нүктеге ауысады. Оның қозғалу жылдамдығы γ_k оқытудың скалярлық жылдамдығына және $\nabla f(\alpha^{(k)})$ градиент векторының шамасына байланысты.

Тоқтату шарты. τ параметрі алгоритмнің төзімділігі болып табылады. Егер функция дифференциалданады деп есептесек, онда α^* минимумында $\nabla f(\alpha) = (0, 0, ..., 0)$ ие болуымыз керек. Сонымен, минимумға жақын α үшін $\nabla f(\alpha)$ да аз нормаға ие болуы керек. Алгоритм ешқашан шынайы минимумға жете алмауы мүмкін (және біз оның не екенін білмейміз, сондықтан біз функцияның мәнімен тікелей салыстыра алмаймыз). Осылайша, әдетте $\|\nabla f\|$ прокси (аралық) ретінде қолданылады.

Басқа жағдайларда біз t қадамдарының белгіленген санымен жұмыс істей аламыз. Бұл τ тұрақтылығын пайдалану сияқты кіріс деректеріне алгоритмді автоматты түрде баптауға әкелмесе де, оны сипаттау және салыстыру оңайырақ. Сондықтан, осы мәтіндегі мысалдардың көпшілігінде дәл осы әдіс қолданылады.

3.1 Оқыту жылдамдығы

Градиенттік түсудің ең маңызды параметрі-γ, *оқу жылдамдығы*. Көптеген жағдайларда алгоритм барлық k үшін $\gamma_k = \gamma$ тұрақтылығын сақтайды. Ол алгоритмнің қаншалықты жылдам жұмыс істейтінін

анықтайды. Бірақ егер біз минимумға жақындаған кезде ол тым үлкен болса, онда алгоритм тым асыра сілтеп, одан асып кетуі мүмкін.

γ қалай таңдау керек? Бұл бойынша біртұтас пікір жоқ және көбінесе іс жүзінде ол арнайы түрде реттеледі. Әрі қарай, біз кейбір математикалық сипатталған сценарийлерді сипаттаймыз, онда γ таңдау туралы ресми нәрсе айтуға болады. Кейбір жағдайларда бұл талдау егер функция әлсіз қасиетке сәйкес келсе, онда көптеген белгіленген γ нұсқалары дәлдік кепілдіктеріне әкелетінін көрсетеді. Біз сондай-ақ γ_k оқыту параметрін бейімдеуге болатын әдістерді көрсетеміз.

№8 Емтихан билеті

1. Дисперсия

X кездейсоқ шамасының *дисперсиясы* (ауытқуы) оның $\mathbf{E}[X]$ орташа мәніне қатысты қаншалықты таралуын сипаттайды. Бұл келесідей анықталады

$$\mathbf{Var}[\mathrm{X}] = \mathbf{E}[(\mathrm{X} - \mathbf{E}[\mathrm{X}])^2] = \mathbf{E}[\mathrm{X}^2] - \mathbf{E}[\mathrm{X}]^2.$$

Жоғарыда келтірілген екі жалпы форманың эквиваленттілігі **E** [X] бекітілген скаляр болып табылатындығын пайдаланады:

$$\mathbf{E}[(\mathrm{X} - \mathbf{E}[\mathrm{X}])^2] = \mathbf{E}[\mathrm{X}^2 - 2X\mathbf{E}[\mathrm{X}] + \mathbf{E}[\mathrm{X}]^2] = \mathbf{E}[\mathrm{X}^2] - 2\mathbf{E}[\mathrm{X}]\mathbf{E}[\mathrm{X}] + \mathbf{E}[\mathrm{X}]^2 = \mathbf{E}[\mathrm{X}^2] - \mathbf{E}[\mathrm{X}]^2.$$

$\alpha \in \mathbb{R}$ кез-келген скаляр үшін, онда $\mathbf{Var}[\alpha X] = \alpha^2 \mathbf{Var}[X]$.

Дисперсияда кездейсоқ шама немесе математикалық күту сияқты өлшем бірліктері жоқ екенін ескеріңіз, бұл квадраттағы өлшем бірлігі. Сонымен, біз *стандартты ауытқуды* жиі талқылаймыз. $\mathbf{Var}[X]$ немесе σ_X төмен мәндерінің көпшілігі орташа мәнге жақын екенін көрсетеді, ал үлкен мән деректердің орташадан алысырақ болуы ықтимал екенін көрсетеді.

Мысал: Дисперсия

Аяқ киіммен қосылған биіктік үшін кездейсоқ S шамасын тағы бір рет қарастырайық:

Оның күтілетін мәні $\mathbf{E}[\mathrm{S}] = 3$ (бекітілген скаляр) және оның ауытқуы

$$\mathbf{Var}[\mathrm{S}] = 0.1 \cdot (1 - 3)^2 + 0.1 \cdot (2 - 3)^2 + 0.5 \cdot (3 - 3)^2 + 0.3 \cdot (4 - 3)^2$$

$$= 0.1 \cdot (-2)^2 + 0.1 \cdot (-1)^2 + 0 + 0.3(1)^2 = 0.4 + 0.1 + 0.3 = 0.8.$$

Онда стандартты ауытқу $\sigma_S = \sqrt{0,8} \approx 0,894$ тең.

X және Y екі кездейсоқ шамасының *ковариациясы* $\mathbf{Cov}[X, Y] = \mathbf{E}[(X - \mathbf{E}[X])(Y - \mathbf{E}[Y])]$.

2. Махаланобис қашықтығы

2.2 Махаланобис қашықтығы

L_2 қашықтығының кеңеюі $a, b \in \mathbb{R}^d$ екі векторы және $d \times d$ өлшемді M матрицасы үшін анықталған Махаланобис қашықтығы болып табылады

$$\mathbf{d}_M(a, b) = \sqrt{(a - b)^T M (a - b)}.$$

$M = I$ болған кезде (бірлік матрицасы, сондықтан $I_{j,j} = 1$ және $j \neq j'$ үшін $I_{j,j'} = 0$), онда $\mathbf{d}_M = \mathbf{d}_2$. M диагональды матрица болған кезде (осылайша, $j \neq j'$ үшін $M_{j,j'} = 0$), онда $\mathbf{d}_M$ -ді M матрицасына негізделген Евклид кеңістігінің бұрмалануы (кейбір координаттардың қысылуы және басқаларының кеңеюі) деп түсіндіруге болады. M диагональды болмаған кезде Евклид кеңістігінің қисаюы әлі де сақталады, бірақ қисаю координаталық осьпен туралanбайды; оның орнына ол M -нің меншікті векторлары мен меншікті мәндері арқылы анықталады (11 дәрісті қараңыз). Барлық меншікті мәндер оң және нақты болғанша (M оң анықталған дегенді білдіреді), $\mathbf{d}_M$ метрика болып табылады; осы кезден бастап қисаю жақсы анықталған және толық өлшемге айналады.

3. Деректер матрицалары

1. Деректер матрицалары

Біз $A \in \mathbb{R}^{n \times d}$ матрицасындағы мәліметтерден бастаймыз және сызықтық алгебраны көмекке шақырамыз. А әрбір a_i жолын $\mathbb{R}^d$ -гі деректер нүктесі ретінде қарастырған пайдалы, сондықтан n деректер нүктелері бар. Әрбір $j \in 1, 2, ..., d$ өлшеміне деректер нүктелерінің атрибуты сәйкес келеді.

Мысал: Деректер матрицалары

Деректер матрицалары туындаған кезде көптеген жағдайлар болады.

- Уақыттың d нүктелеріндегі температура туралы хабарлайтын, n метеостанциялар жиынтығын қарастырайық. Онда әрбір a_i жолы бір метеостанцияға сәйкес келеді және осы жолдың әрбір $A_{i,j}$ координаты j сәтіндегі i станциядағы температура болып табылады.
- Фильм рейтингтерінде n пайдаланушыны қарастыра аламыз, олар d фильмдерінің әрқайсысын 1-5 баллға бағалады. Онда әрбір a_i жолы пайдаланушыны білдіреді, ал j -осы пайдаланушының жазбасы - бұл j фильміне берілген баға.

Осы сценарийлердің әрқайсысында деректер нүктелерінің (n) жиыны бар, олардың әрқайсысы d атрибуттарына ие болады.

Деректер матрицалары және өлшем бірліктері: Деректер матрицасы үшін өлшемнің төмендеуін ескеру қажет

- барлық координаттарда бірдей өлшем бірліктері болуы керек!

Егер осы "бірдей өлшем бірліктері" қасиеті орындалмаса, онда біз $\mathbb{R}^d$ -гі деректер нүктелері арасындағы қашықтықты өлшегенде, әдетте L_2 нормасын қолдансақ, онда қашықтық мағынасыз болады. Дегенмен бұл мәселелерді шешу үшін "қалыпқа келтіру" эвристикасы болғанымен, олардың әрқайсысы өзінің күтпеген салдарына әкелуі мүмкін.

Келесі мақсат-заңдылықты немесе M моделін анықтау. Бұл жағдайда модель төмен өлшемді B ішкі кеңістігі болады. Ол k-өлшемді кеңістікті білдіреді, мұндағы $k \ll d$.

№9 Емтихан билеті

1. Бірлескен, шекті және шартты үлестіру

6. Совместное, предельное и условное распределения¶

Теперь мы распространим некоторые из этих концепций на более чем одну случайную величину. Рассмотрим две случайные величины X и Y. Их *совместный pdf* определяется $f_{X,Y}: \Omega_X \times \Omega_Y \to [0, \infty]$, а для дискретных случайных величин это определяется вероятностью¶

$$f_{X,Y}(x, y) = \mathbf{Pr}(X = x, Y = y).$$¶

В этом дискретном случае область $f_{X,Y}$ ограничена таким образом, что $f_{X,Y} \in [0, 1]$ и поэтому $\sum_{x,y \in X \times Y} f_{X,Y}(x, y) = 1$, например, сумма вероятностей в пространстве совместной выборки равна 1.¶

Предельный pdf в дискретном случае определяется¶

$$f_X(x) = \sum_{y \in \Omega_Y} f_{X,Y}(x, y) = \sum_{y \in \Omega_Y} \mathbf{Pr}(X = x, Y = y).$$¶

Маргинализация (изолирование) устраняет эффект случайной величины (Y в приведенных выше определениях).¶

В этом непрерывном случае более естественно сначала определить совместный и предельный cdf. Когда $\Omega_X = \Omega_Y = \mathbb{R}$, *совместный cdf* определяется $f_{X,Y}(x, y) = \mathbf{Pr}(X \leq x, Y \leq y)$. Определены *предельные значения cdf* для $f_{X,Y}$: $F_X(x) = lim_{y \to \infty} f_{X,Y}(x, y)$ и $F_Y(y) = \lim_{x \to \infty} f_{X,Y}(x, y)$. Тогда для непрерывных случайных величин мы теперь можем определить $f_{X,Y}(x, y) = \frac{\mathrm{d}^2 F_{X,Y}(x,y)}{\mathrm{d}x\mathrm{d}y}$. И тогда предельное pdf для X (когда $\Omega_Y = \mathbb{R}$) определяется $f_X(x) = \int_{y=-\infty}^{\infty} f_{X,Y}(x, y)\mathrm{d}y$.¶

Теперь мы можем сказать, что случайные величины X и Y независимы тогда и только тогда, когда $f_{X,Y}(x, y) = F_X(x) \cdot f_Y(y)$ для всех x и y.¶

Тогда определяется *условное распределение* X при заданном $Y = y$: $f_{X|Y}(x \mid y) = f_{X,Y}(x, y) / f_Y(y)$ (учитывая, что $f_Y(y) \neq 0$).¶

6. Бірлескен, шекті және шартты үлестірулер Енді ¶

біз осы тұжырымдамалардың кейбірін біреуден көпке кеңейтеміз кездейсоқ шама. Екі кездейсоқ шаманы қарастырайық: X және-Y. Олардың бірлескен 2y=: [0,00], ал үшін дискретті кездейсоқ шамалардың бұл ықтималдықпен анықталады¶

fxy(x,y)-Pr(X=x, Y=y) ¶

Бұл дискретті жағдайда домен [0, 1] және сондықтан 2xyexxy болатындай шектелген fxy(x, y) = 1, мысалы, бірлескен үлгі кеңістігіндегі ықтималдықтардың қосындысы 1-ге тең. Шекті pdf дискретті жағдайда анықталады ¶

$$f_X(x) = \sum_{y \in \Omega_Y} f_{X,Y}(x,y) = \sum_{y \in \Omega_Y} \mathbf{Pr}(X = x, Y = y).$$

¶

Маргинализация (оқшаулау) кездейсоқ шаманың әсерін жояды (жоғарыда көрсетілгендердегі Y анықтамалар бойынша).

Бұл үздіксіз жағдайда алдымен бірлескен және шекті ККҚ-ны анықтау табиғирақ болады. Қашан = = R, бірлескен fxy(x, y) = Pr(X) арқылы анықталады < x, < y). Шекті мәндер анықталды fxy үшін cdf мәндері: Fx(x) = limy fxy(x, y) (y) = lim #fxx (x, y). Содан кейін үздіксіздер үшін кездейсоқ шамаларды енді анықтай аламыз $f_{X,Y}(x,y) = \frac{\mathrm{d}^2 F_{X,Y}(x,y)}{\mathrm{d}x\mathrm{d}y}$. Және содан кейін pdf үшін шектеу.X·

$$f_X(x) = \int_{y=-\infty}^{\infty} f_{X,Y}(x,y)\mathrm{d}y.$$

(IR анықталған кезде) ¶

Енді кездейсоқ шамалар тәуелсіз болған жағдайда ғана айта аламыз барлық хиу үшін fxy(x, y) = Fx(x) fy(y). ⁞

Сонда шартты үлестірім анықталады X берілген y үшін: (x-| y) = (x, y) / (y) (fr(y) #-0 екенін ескере отырып).

2. Косинус және бұрыштық қашықтық

2.3 Косинустік және бұрыштық қашықтық

Косинустік қашықтық 1 минус $\mathbb{R}^d$ -гі $a = (a_1, a_2, \ldots, a_d)$ және $b = (b_1, b_2, \ldots, b_d)$ векторлары арасындағы "бұрыштың" косинусын өлшейді

$$\mathbf{d}_{\cos}(a,b) = 1 - \frac{\langle a,b\rangle}{\|a\|\|b\|} = 1 - \frac{\sum_{i=1}^{d} a_i b_i}{\|a\|\|b\|}.$$

Еске салайық,егер $\theta_{a,b}$ - a және b векторлары арасындағы бұрыш болса, онда $\cos(\theta_{a,b}) = \frac{\langle a,b\rangle}{\|a\|\|b\|}$. Демек, $\mathbf{d}_{\cos}(a, b) = 1 - \cos(\theta_{a,b})$.

Назар аударыңыз, $\mathbf{d}_{\cos}(A, B) \in [0, 2]$ және бұл $\|a\|$ векторларының шамасынан тәуелсіз, өйткені ол қалыпқа келтірілген. Ол тек олардың нұсқаулары туралы ойлайды. Бұл объект векторы әртүрлі өлшемдегі деректер жиынын көрсеткенде және біз бұл үлестірімдердің қаншалықты ұқсас екендігін салыстырғымыз келгенде пайдалы, бірақ олардың өлшемін емес. Бұл $\mathbf{d}_{\cos}$ -ты ең жақсы жағдайда жалған қашықтық етеді, өйткені a және $a' = (2a_1, 2a_2, \ldots, 2a_d)$ екі вектор үшін бізде $\mathbf{d}_{\cos}(a, a') = 0$ бар, бірақ олар тең емес, мұндағы $\|a'\| = 2\|a\|$.

Кейде $\mathbf{d}_{\cos}$ тек a, $b \in \mathbb{S}^{d-1}$ қалыпқа келтірілген векторларға қатысты анықталады, мұндағы

$$\mathbb{S}^{d-1} = \left\{ x \in \mathbb{R}^d \mid \|x\| = 1 \right\}.$$

Бұл жағдайда бәрі қарапайым

$$\mathbf{d}_{\cos}(a, b) = 1 - \langle a, b\rangle.$$

Егер $\mathbb{S}^{d-1}$-дегі векторлармен шектелсеңіз, онда $\mathbf{d}_{\cos}$ -те $\mathbf{d}_{\cos}(a, b) = 0$ болатындай $a \neq b$ екі векторымен проблема болмайды.

Алайда, бұл әлі метрика емес, өйткені ол үшбұрыш теңсіздігін бұзуы мүмкін.

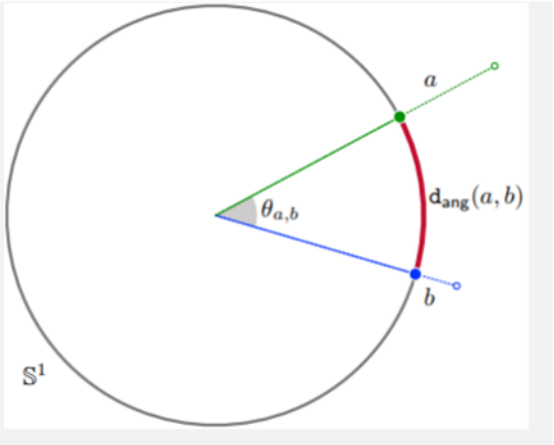
Косинустік қашықтықтың қарапайым изометриялық түрленуі (бұл нүктелердің кез–келген жұбы арасындағы тәртіп бірдей дегенді білдіреді) $\mathbf{d}_{\text{ang}}$ *бұрыштық арақашықтық* деп аталады; яғни $a, b, c, d \in \mathbb{S}^{d-1}$ үшін, егер $\mathbf{d}_{\cos}(a, b) < \mathbf{d}_{\cos}(c, d)$ болса, онда $\mathbf{d}_{\text{ang}}(a, b) < \mathbf{d}_{\text{ang}}(c, d)$. Нақтырақ айтсақ, біз кез–келген $a, b \in \mathbb{S}^{d-1}$ үшін келесіні анықтаймыз

$$\boldsymbol{d}_{ang}(a, b) = \cos^{-1}(\langle a, b\rangle) = \arccos(\langle a, b\rangle).$$

Яғни, бұл косинус қашықтығының косинус интерпретациясын жояды және тек бұрышты өлшейді. Кез–келген $a, b \in S^{-1}$ үшін ішкі көбейтінді [-1, 1] диапазонында болғандықтан, $\mathbf{d}_{\cos}$ мәні [0, 2] диапазонында болады, бірақ мән $\boldsymbol{d}_{ang}(a, b) \in [0, \pi]$. Сонымен қатар, $\boldsymbol{d}_{ang}$ –бұл $\mathbb{S}^{d-1}$ бойынша метрика.

Бұрыштық қашықтықтың геометриясы

$\mathbf{d}_{\cos}(a, b) = 1 - \cos(a, b)$ косинустік арақашықтықтың және $\boldsymbol{d}_{ang}(a, b) = \theta_{a,b}$ бұрыштық арақашықтықтың бұрыштық интерпретациясын сферадағы нүктелер үшін қолданған ыңғайлы. Екі нүкте арасындағы бұрыштық қашықтықтың геометриясын түсіну үшін оларды $\mathbb{S}^1 \subset \mathbb{R}^2$ бірлік сферасында жатқандай қарау жеткілікті. Енді $\boldsymbol{d}_{ang}(a, b)$ - бұл $\theta_{a,b}$ бұрышының радиандары немесе баламалы түрде сферада жүру кезінде a мен b арасында өтетін доғаның ұзындығы.



Енді біз олар $\mathbb{S}^{d-1}$-гі векторлармен шектелген болса, неге $\boldsymbol{d}_{ang}$ метрика екенін көре аламыз. (M1) және (M3) анықтама бойынша орындалады, ал (M2) $\mathbb{S}^{d-1}$ -де орындалады, өйткені ешқандай екі түрлі бірлік вектор арасында 0 радиан бұрышқа ие болмайды. (M4) үшбұрыш теңсіздігін көрсету үшін (мұнда біз $\mathbb{S}^2 \subset \mathbb{R}^3$-те ойлауымыз керек), $\boldsymbol{d}_{ang}$ сферамен шектелген ең қысқа қашықтықты өлшейтіндіктен, $\boldsymbol{d}_{ang}(a, b)$ - нің $\boldsymbol{d}_{ang}(a, c) + \boldsymbol{d}_{ang}(c, b)$- ке қарағанда ұзынырақ болуы мүмкін емес екенін байқаймыз, себебі бұл $c \in \mathbb{S}^{d-1}$ нүктесі арқылы өтуді білдіретіндіктен a-дан b -ға дейінгі жолды қысқартады, бұл мүмкін емес.

3. Сингулярлық мәндер бойынша ыдырау

2. Сингулярлық мәндер бойынша жіктеу

Шынында да сызықтық алгебраның қуатты және пайдалы операциясы сингулярлық мәндер бойынша жіктеу деп аталады (SVD- Singular Value Decomposition).

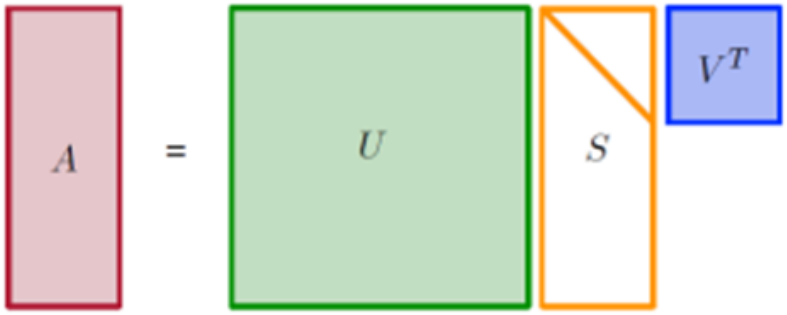
Ол *A* матрицасы туралы көптеген ақпаратты алады.

Мысал: тіктөртбұрыштардағы SVD

Матрицаларды тіктөртбұрыш түрінде көрсету арқылы сингулярлық ыдырауды (SVD) елестету оңғайлы. "Ұзартылған және тар" *A* матрицасында бағандарға қарағанда көбірек жолдар бар ($n > d$). Оның ыдырауын ескере отырып

$$[U, S, V] = \text{svd}(A),$$

U және *V* сәйкесінше $n \times n$ және $d \times d$ өлшемді квадрат матрицалар, сондықтан олар квадрат түрінде ұсынылған. *S*-ұзартылған және тар тіктөртбұрыш, өйткені оның өлшемдері *A*-мен бірдей; оның диагональды екенін көрсету үшін біз матрицаның көп бөлігін нөлдер орналасқан жерде бос қалдыра аламыз.



Іші жасырылған, құрылым. *S* матрицасы негізінен нөлдерден тұрады; оның тек диагоналінде нөлдік емес элементтер бар. Яғни, $S_{i,j} = 0$, егер $i \neq j$. Қалған мәндер $\sigma_1 = S_{1,1}$, $\sigma_2 = S_{2,2}$, ..., $\sigma_r = S_{r,r}$ сингулярлық мәндер деп аталады. Олар кемімелі емес, яғни

$$\sigma_1 \geq \sigma_2 \geq \ldots \geq \sigma_r \geq 0$$

мұндағы $r \leq \min\{ n, d \}$ - *A* матрицасының рангі, яғни нөлдік емес сингулярлық мәндердің саны рангты анықтайды (бұл матрицаның ранг-сын есептеудің сандық тәсілі).

U және *V* матрицалары ортогоналды. Осылайша, олардың бағандары бірлік векторлары болып табылады және бір-біріне ортогоналды (әр матрица ішінде). $u_1, u_2, \ldots, u_r$ ретінде белгіленген *U* бағандары *сол жақ сингулярлық векторлар* деп аталады, ал *V* бағандары (яғни V^T жолдары) $v_1, v_2, \ldots, v_d$ деп белгіленеді оң жақ сингулярлық векторлар деп аталады.

Бұл $x \in \mathbb{R}^d$ кез-келген векторы үшін *V* бағандары (оң жақ сингулярлық векторлар) базисті құрайды дегенді білдіреді. Яғни, біз $a_i = \langle x, v_i \rangle$ *x* -ті $x = \sum_{i=1}^{d} a_i v_i$ түрінде жаза аламыз. Сол сияқты, $y \in \mathbb{R}^n$ кез-келген векторы үшін *U* бағандары (сол жақ сингулярлық векторлар) базисті құрайды. Бұл сонымен қатар $\|x\| = \|V^T x\|$ және $\|y\| = \|yU\|$ дегенді білдіреді. Осылайша, бұл матрицалар мен олардың векторларында *S* матрицасында болатын, *A* матрицасының "масштабы" туралы ақпарат жоқ. Оның орнына олар масштабты арнайы түрде сипаттау үшін базистерді қамтамасыз етеді.

№10 Емтихан билеті

1. Гаусс бойынша үлестіру(1 лекция)

Гаусс бойынша үлестіру

Гаусс үлестірімі – бір өлшемді қалыпты үлестірімді жалпылайтын $\boldsymbol{G_d}: \boldsymbol{R^d} \to \boldsymbol{R}$ d-вариациясы бар үлестіру. Симметриялық нұсқаның анықтамасы орташа мәнге $\mu \in R^d$ және σ^2 дисперсиясына байланысты. Кез келген вектор үшін $v \in R^d$–мен анықталады.

$$\mathcal{G}_d(v) = \frac{1}{\sigma^d \sqrt{(2\pi)^d}} \exp\left(-\frac{\|v-\mu\|^2}{2\sigma^2}\right),$$

мұндағы $\|v-\mu\|$ v мен μ арасындағы евклидтік қашықтық . Екі өлшемді жағдай үшін, мұндағы $v = (v_x,\ v_y)$ және $\mu = (\mu_x,\ \mu_y)$, содан кейін ол келесі түрге түрленеді.

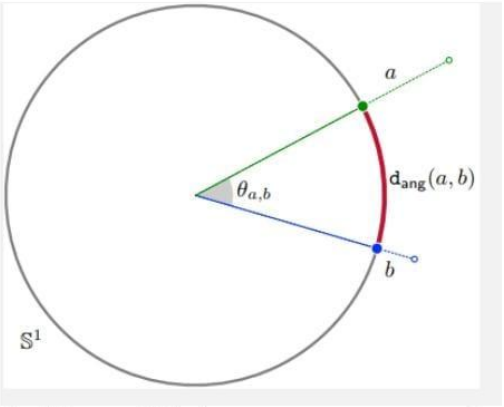
$$\mathcal{G}_2(v) = \frac{1}{2\pi\sigma^2} \exp\left(\frac{-(v_x-\mu_x)^2 - (v_y-\mu_y)^2}{2\sigma^2}\right).$$

Гаусстың таралуының сиқырлы қасиеті - оның барлық шартты нұсқалары да Гаусс, бірақ өлшемі аз. Мысалы, екі өлшемді жағдайда $G_2(v_x \mid v_y = 1)$ бір өлшемді Гаусс үлестірімі болып табылады, ол дәл $N = G_1$ үлестірімі болып табылады. Гаусс теңдеуінің көптеген басқа маңызды қасиеттері бар, соның ішінде ол барлық негізгі түрлендірулерге инвариантты және орталық шекті теореманың шекаралары үшін шекті үлестіру болып табылады.

2. Бұрыштық қашықтық геометриясы(5 лекция)

Бұрыштық қашықтықтың геометриясы

$\mathbf{d}_{\cos}(a, b) = 1 - \cos(a, b)$ косинустік арақашықтықтың және $\boldsymbol{d}_{ang}(a, b) = \theta_{a,b}$ бұрыштық арақашықтықтың бұрыштық интерпретациясын сферадағы нүктелер үшін қолданған ыңғайлы. Екі нүкте арасындағы бұрыштық қашықтықтың геометриясын түсіну үшін оларды $\mathbb{S}^1 \subset \mathbb{R}^2$ бірлік сферасында жатқандай қарау жеткілікті. Енді $\boldsymbol{d}_{ang}(a, b)$ - бұл $\theta_{a,b}$ бұрышының радиандары немесе баламалы түрде сферада жүру кезінде a мен b арасында өтетін доғаның ұзындығы.



Енді біз олар $\mathbb{S}^{d-1}$-гі векторлармен шектелген болса, неге $\boldsymbol{d}_{ang}$ метрика екенін көре аламыз. (M1) және (M3) анықтама бойынша орындалады, ал (M2) $\mathbb{S}^{d-1}$ -де орындалады, өйткені ешқандай екі түрлі бірлік вектор арасында 0 радиан бұрышқа ие болмайды. (M4) үшбұрыш теңсіздігін көрсету үшін (мұнда біз $\mathbb{S}^2 \subset \mathbb{R}^3$-те ойлауымыз керек), $\boldsymbol{d}_{ang}$ сферамен шектелген ең қысқа қашықтықты өлшейтіндіктен, $\boldsymbol{d}_{ang}(a, b)$ - нің $\boldsymbol{d}_{ang}(a, c) + \boldsymbol{d}_{ang}(c, b)$- ке қарағанда ұзынырақ болуы мүмкін емес екенін байқаймыз, себебі бұл $c \in \mathbb{S}^{d-1}$ нүктесі арқылы өтуді білдіретіндіктен a-дан b -ға дейінгі жолды қысқартады, бұл мүмкін емес.

3. Меншікті сандар және меншікті векторлар(12 лекция)

3. Меншікті мәндер және меншікті векторлар

SVD жіктелуіне байланысты матрицаның жіктелуі меншікті жіктелу болып табылады. Ол тек шаршы матрицалар үшін анықталады $M \in R^{n \times n}$.

M-нің *меншікті векторы* - бұл

$$Mv = \lambda v$$

қанағаттандыратын, λ скаляры болатындай, v векторы болып табылады.

Яғни, M -ді v-ге көбейту v-нің масштабталған нұсқасын береді. v-ні $||v|| = 1$ болатындай қалыпқа келтірілгенде, сәйкес λ мәні *меншікті мән* деп аталады.

Жалпы жағдайда, $M \in \mathbb{R}^{n \times n}$ квадрат матрица n-ге дейін меншікті векторларға (матрица $V \in \mathbb{R}^{n \times n}$) және меншікті мәндерге (вектор $l \in \mathbb{R}^n$) ие болуы мүмкін. Кейбір меншікті мәндер комплексті сандар болуы мүмкін (тіпті барлық m элементтері нақты сандар болса да!).

```
from scipy import linalg as LA
l, V = LA.eig(M)
```

Сондықтан біз оң жартылай анықталған матрицаларға назар аударамыз. *Оң анықталған матрица* $M \in \mathbb{R}^{n \times n}$ - оң меншікті мәндері бар симметриялы матрица. Тағы бір сипаттама - $x \in \mathbb{R}^n$ кез-келген векторы үшін $x^T Mx > 0$ орындалады.

$M \in \mathbb{R}^{n \times n}$ *оң жартылай анықталған матрицаның* кейбір меншікті мәндері 0-ге тең болуы мүмкін, алайда олардың қалған бөлігі оң болады; сол сияқты, $x \in \mathbb{R}^n$ кез-келген векторы үшін $x^T Mx$ нөлге немесе оң санға тең болуы мүмкін.

Оң жартылай анықталған матрицаларды қалай алуға болады? $A \in \mathbb{R}^{n \times d}$ деректер матрицасынан бастайық. Содан кейін біз екі оң жартылай анықталған матрицаны құра аламыз:

$$M_R = A^T A \quad \text{и} \quad M_L = AA^T.$$

M_R матрицасы $d \times d$ өлшеміне, ал M_L матрицасы $n \times n$ өлшеміне ие болады. Егер A матрицасының рангі d болса, онда M_R оң анықталады. Егер A матрицасының рангі n болса, онда M_L оң анықталады.

№11 Емтихан билеті

1. Ядро тығыздығын бағалау геометриясы

Геометрия оценок плотности ядра

Оценка плотности ядра - это мощный инструмент моделирования, который позволяет взять конечный набор точек $P \subset \mathbb{R}^d$ и оператор сглаживания, ядро K, и преобразовать их в непрерывную функцию $\mathrm{KDE}_P : \mathbb{R}^d \to \mathbb{R}$.

Наиболее распространенным ядром является гауссово ядро

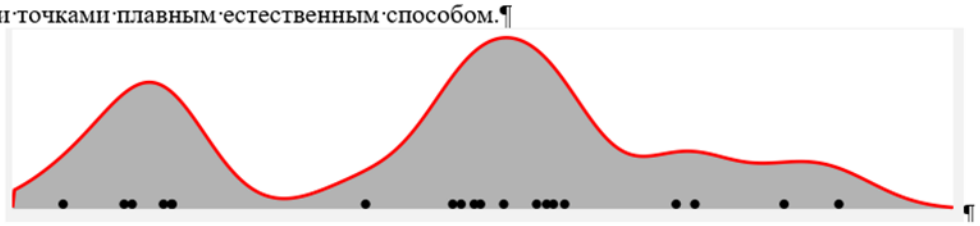
$$K(p, x) = \frac{1}{\sigma^d \sqrt{(2\pi)^d}} \exp\left(-\frac{\|x - p\|^2}{2\sigma^2}\right),$$

что в точности является оценкой гауссова распределения $\mathcal{G}_\sigma(x)$ со средним значением p и стандартным отклонением σ, оцененным в x. Таким образом, это можно интерпретировать как взятие "массы" точки p и распределение ее в соответствии с этим распределением вероятностей.

Теперь оценка плотности ядра определяется в точке $x \in \mathbb{R}^d$ как

$$\mathrm{KDE}_P(x) = \frac{1}{|P|} \sum_{p \in P} K(p, x).$$

То есть он присваивает каждой точке $p \in P$ массу, равную $1/|P|$ (каждая взвешена равномерно), затем распределяет каждую из этих $|P|$ масс, используя Гауссовы ядра, и суммирует их. Хотя P является дискретным по своей природе, оценка плотности ядра KDE_P позволяет выполнять интерполяцию между этими точками плавным естественным способом.



Ядро тығыздығын бағалаудың геометриясы

Ядро тығыздығын бағалау - бұл алуға мүмкіндік беретін қуатты модельдеу құралы нүктелердің ақырлы жиыны P бірге Rd және тегістеу операторы, ядросы Қ, және оларды үздіксізге түрлендіру KDEp функциясы: Rd. > R.

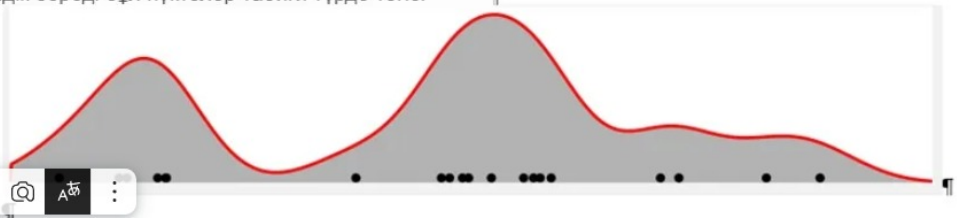
Ең көп тараған 'ядро'Таус ядросы болып табылады

$$K(p, x) = \frac{1}{\sigma^d \sqrt{(2\pi)^d}} \exp\left(-\frac{\|x - p\|^2}{2\sigma^2}\right),$$

бұл орташа P және стандартты мәні бар Ga(x) Гаусс үлестірімінің дәл бағасы болып табылады x-да бағаланған о ауытқуымен. Осылайша, оны нүктенің "массасын" алу деп түсіндіруге болады р және оны ықтималдықтардың осы үлестіріміне сәйкес бөлу. Енді ядроның тығыздығын бағалау келесі нүктеде анықталады: ретінде

$$\mathrm{KDE}_P(x) = \frac{1}{|P|} \sum_{p \in P} K(p, x).$$

Яғни, ол әрбір нүктеге P E.P массасын тағайындайды: 1/[P] (әрқайсысы біркелкі өлшенеді), содан кейін осы |P| массалардың әрқайсысын Гаусс ядроларының көмегімен таратады және оларды қорытындылайды. Дегенмен P болып табылады табиғаты бойынша дискретті, ядро тығыздығын бағалау KDE, P арасындағы интерполяцияға мүмкіндік береді бұл нүктелер табиғи түрде тегіс.



2. Жиындар мен жолдар үшін қашықтық

1. Жиындар мен жолдар үшін қашықтық

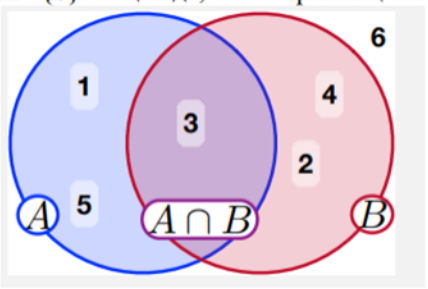
Енді біз қашықтықтың кейбір жалпы ұғымдарын, атап айтқанда мәтіндік деректер арасындағы байланысты түсіну үшін кеңінен қолданылатын ұғымдарды енгіземіз: сөздер немесе таңбалар жолдары. Мәтіннің семантикалық және ұсақ түйіршікті құрылымдық қасиеттеріне көбірек сүйенетін басқа әдістер бар. Мұнда біз қарапайым математикалық байланыстары бар және нәтижесінде көбінесе масштабталатын және икемді болып табылатындарға назар аударамыз.

Жиынтықтарға қысқаша шолу. A жиыны - $\{ a_1, a_2, \ldots, a_k \}$ элементтерінің жиынтығы. Жиынды белгілеу үшін {. . .} фигуралық жақшаларды қолдану стандартты болып табылады. Элементтердің реті маңызды емес, мысалы $\{ a_1, a_2\} = \{ a_2, a_1\}$. Көптікке жол берілмейді немесе еленбейді, мысалы $\{ a_1, a_1, a_2\} = \{ a_1, a_2\}$; егер ол ескерілсе, онда ол мультижиын деп аталады (бұл модельдер табиғи түрде есептеледі немесе ықтималдық үлестірімдері қалыпқа келтірілгеннен кейін; косинус қашықтығы мен KL алшақтығын қараңыз).

A жиынын ескере отырып, $|A|$ деп белгіленген A *қуаты* A-да қанша элемент бар екенін есептейді.Екі A және B жиындарының *қиылысы* $A \cap B$ деп белгіленеді және *екі* жиындағы барлық элементтерді көрсетеді. Екі A және B жиындары арасындағы *біріктіру* $A \cup B$ деп белгіленеді және *кез келген* жиындағы барлық элементтерді көрсетеді. Екі A және B жиындарының *айырмашылығы* $A \setminus B$ арқылы белгіленеді және B-да жоқ A-дағы барлық элементтерді білдіреді, Екі A және B жиындарының арасындағы *симметриялық қашықтық* $A \Delta B$ арқылы белгіленеді және $A \setminus B$ және $B \setminus A$ бірігуі болып табылады. Ω аймағын ескере отырып (онда барлық қызығушылық көрсететін жиындар бар, яғни $A \subset \Omega$), A жиынының *толықтауышы* $\bar{A} = \Omega \setminus A$ ретінде анықталады.

Мысал: Жинақ операциялары

$A = \{1, 3, 5\}$ және $B = \{2, 3, 4\}$ мысалын қарастырайық. Олар A үшін көк аймақ және B үшін қызыл аймағымен Венн диаграммасы ретінде ұсынылған. 6 элементі жиынтықтардың ешқайсысына кірмейді. Онда A қуаты $|A| = 3$, және бұл B үшін бірдей. Қиылысу $A \cap B = \{3\}$, өйткені ол екі жиынтықтағы жалғыз объект болып табылады және күлгін аймақ ретінде визуалды түрде ұсынылған. Бірігу $A \cup B = \{1, 2, 3, 4, 5\}$. Берілген айырмашылық $A \setminus B = \{1, 5\}$ және $B \setminus A = \{2, 4\}$. Толықтауыш $\bar{A} = \{2, 4, 6\}$ және толықтауыш $\overline{A \cup B} = \{6\}$. Соңында, симметриялық айырмашылық $A \Delta B = \{1, 2, 4, 5\}$.



3. Күштік (дәрежелік) әдіс

4. Дәрежелік әдіс

Күштік (дәрежелік) әдіс матрицаның бірінші меншікті векторы мен мәнін есептеудің ең қарапайым алгоритміне жатады. Бірінші меншікті вектордың әсерін жою арқылы біз барлық меншікті векторлар мен мәндерді тапқанға дейін қалған процесті рекурсивті түрде қайталай аламыз. Сонымен қатар, бұл сингулярлық мәндер бойынша жіктеуді қалпына келтіре алатынымызды білдіреді.

$M \in \mathbb{R}^{n \times n}$, оң жартылай анықталған матрицаны қарастырайық: $M = A^TA$.

Алгоритм 7.4.1 PowerMethod (M, q)

$u^{(0)}$ кездейсоқ бірлік векторы ретінде инициализациялау.

for $i = 1$ **to** q **do**

$u^{(i)} := Mu^{(i-1)}$

return $v := u^{(q)}/\|u^{(q)}\|$

Біз басқа интерпретацияны ашу үшін for циклін кеңейте аламыз. Біз $v^{(q)} = M^q v^{(0)}$-ді тікелей орната аламыз, осылайша барлық қайталанулар бір матрицалық-векторлық көбейтуге біріктіріледі. Естеріңізге сала кетейік, $M^q = M \cdot M \cdot M \cdot \ldots \cdot M$, q рет. Алайда, бұл q матрицалық көбейту q матрицалық-векторлық көбейтуге қарағанда әлдеқайда көп есептеу ресурстарын қажет етеді.

Сонымен қатар, егер бізде тек A матрицасы болса (мұндағы $M = A^TA$), онда біз алгоритмді M-ді нақты құрмай орындай аламыз (өйткені, мысалы, егер $d > n$ және $A \in \mathbb{R}^{n \times d}$ болса, онда M (d^2) өлшемі A (n^d) өлшемінен едәуір үлкен болуы мүмкін). Содан кейін біз тек for циклінің ішкі бөлігін келесіге ауыстырамыз

$$u^{(i)} := A^T(Au^{(i-1)})$$

мұнда біз алдымен $\tilde{u} = Au^{(i-1)}$ көбейтеміз, содан кейін $u^{(i)} = A^T\tilde{u}$ аяқтаймыз.

Барлық меншікті мәндерді қалпына келтіру. PowerMethod($M = A^TA$, q) орындалуының нәтижесі v бірлік векторы болып табылады, оны біз бірінші v_1 меншікті векторына ерікті түрде жақын деп санаймыз. Біз бірінші меншікті мәнді $\lambda_1 = \|Mv_1\|$ ретінде қалпына келтіре алатынымыз анық. Меншікті векторлар M үшін базисті құрайтынын және олар ортогоналды екенін білетіндіктен, біз келесі мәндерді есептей аламыз:

$$A_1 := A - Av_1v_1^T$$
$$M_1 := A_1^TA_1$$

Содан кейін біз v_2 және λ_2қалпына келтіру үшін PowerMethod($M_1 = A_1^T A_1$; q) іске қосамыз және оларды M_2 алу үшін M_1-ден таңдап, осы процесті қайталай береміз.

№12 Емтихан билеті

1. Байес ережесі

Байес ережесі деректерге негізделген "модельдерді" бағалау үшін оңтайландыру кезінде қажет болатын ықтималдық функцияларын құрудың негізгі құрамдас бөлігі болып табылады. Байес пайымдауы-бұл "ең оңтайлы" модельді іздеуден әлдеқайда кең өріс. Бұл бөлім тек таныстыратын жұмыс бағыты көптеген мүмкін модельдер туралы айтады және осы белгісіздікті ескере отырып болжам жасай алады.Екі м және В оқиғаларын ескере отырып, Байес ережесінде: $\mathbf{Pr}(M \mid D) = \frac{\mathbf{Pr}(D \mid M) \cdot \mathbf{Pr}(M)}{\mathbf{Pr}(D)}$. Механикалық түрде бұл кездейсоқ шамалардың кондиционерлеу бағытын (берілген M-де D) - ден (берілген D-де M) - ге аударудың алгебралық әдісін ұсынады. Бұл M және D тәуелсіздігі туралы ештеңе білдірмейді (әйтпесе бұл өте қызық емес). Мұны алу үшін біз қолданамыз: $\mathbf{Pr}(M \cap D) = \mathbf{Pr}(M \mid D)\mathbf{Pr}(D)$ сондай-ақ $\mathbf{Pr}(M \cap D) = \mathbf{Pr}(D \cap M) = \mathbf{Pr}(D \mid M)\mathbf{Pr}(M)$. Оларды біріктіру арқылы біз Pr (M | D) PR (D) = Pr (D | M) Pr (M) аламыз, одан Pr (M | D) шешу үшін Pr (D) деп бөлуге болады. Осылайша, Байес ережесі сөзсіз дұрыс; кез келген" жиі қарсы

Байес " пікірталас осы ереженің ерекшелігі немесе дұрыстығы туралы емес, деректерді модельдеу және талдау жасау туралы.

2. Жаккард қашықтығы

1.1 Жаккард қашықтығы

Екі A және B жиынтығы арасындағы Жаккард қашықтығы анықталған

$$\mathbf{d}_J(A,B) = 1 - \frac{|A \cap B|}{|A \cup B|}.$$

Біріктіру әрқашан қиылысудан үлкен болғандықтан, бөлшек мүше әрқашан 0 мен 1 арасында болады және бұл қашықтық әрқашан [0, 1] -гі мәнді қабылдайды. Егер жиындардың ортақ ештеңесі болмаса, бұл тек 1, ал егер қиылысу біріктіруге тең болса және жиындар дәл сәйкес келсе, тек 0 болады.

Мысал: Жаккард бойынша қашықтық

Екі $A = \{0, 1, 2, 5, 6\}$ және $B = \{0, 2, 3, 5, 7, 9\}$ жиынтықтарын қарастырайық. A және B арасындағы Жаккард қашықтығы келесіге тең

$$\mathbf{d}_J(A,B) = 1 - \frac{|A \cap B|}{|A \cup B|}$$
$$= 1 - \frac{|\{0,2,5\}|}{|\{0,1,2,3,5,6,7,9\}|} = 1 - \frac{3}{8} = 0.625$$

Назар аударыңыз, егер Біз B-да орналасқан 7 элементін A-ға қоссақ (бұл жиынтықты A' деп атайық), онда алым көбейеді, бірақ бөлім өзгеріссіз қалады. Сонымен, $\mathbf{d}_J(A', B)$ = 1-4/ 8 = 0,5 және қашықтық аз – олар бір-біріне жақын.

Екінші жағынан, егер A-ға да, B-ға да кірмейтін 4 элементін A-ға қоссақ (бұл жиынтықты A'' деп атайық), онда алым өзгеріссіз қалады, бірақ бөлім көбейеді. Сонымен, онда $\mathbf{d}_J(A'', B) = 1 - 3/9 \approx 0{,}666$, және онда қашықтық үлкен – жиынтықтар бір-бірінен алшақ орналасқан.

Жаккард қашықтығы-бұл жиындар арасындағы танымал қашықтық, өйткені ол метрика және жиындардың өлшеміне инвариантты (өзгермейтін) болып табылады. Бұл тек екі жиынтықтағы элементтердің үлесінен тәуелді, олар бірдей болып табылады. Ол сондай-ақ олардан жиынтықтар құрылуы мүмкін элементтердің біршама үлкен Ω универсумын білуді қажет етпейді. Мысалы, мысалдағыдай, біз жиындардан тек оң бүтін сандарды қамтуды талап ете аламыз, бірақ бізге ең үлкен мүмкін болатын оң бүтін сан үшін жоғарғы шекараны білудің қажеті жоқ.

3. Кластерлеу

Кластерлеу

Кластерлеу-бұл деректер нүктелерін ұқсас нүктелердің ішкі жиындарына автоматты түрде топтастыру. Бұл мәселені анықтаудың көптеген жолдары бар және олардың көпшілігі өте шатасқан. Кластерлеудің көптеген әдістерінде математикалық тұжырым жетіспейді.

Алайда анықтама үшін біз Вороной диаграммаларына математикалық экскурсиядан бастаймыз. Содан кейін біз осы ішкі саладағы тәсілдердің кеңдігі мен әртүрлілігі туралы түсінік беру үшін кластерлеудің әртүрлі басқа тұжырымдамаларын сипаттаймыз.

Кластерлеу мүмкіндігі туралы: кластерлеу тәсілдерінің кең ауқымын ескере отырып, осы шолуды қарастырайық:

Деректер оңай немесе табиғи түрде кластерленген кезде, кластерлеу алгоритмдерінің көпшілігі тез және жақсы жұмыс істейді.

Деректер жеңіл немесе табиғи кластерлеуге жауап бермеген кезде, ешқандай алгоритм жақсы кластерлерді таба алмайды.

Кластерлеу мүмкіндігі туралы: кластерлеу тәсілдерінің кең ауқымын ескере отырып, осы шолуды қарастырыңыз:

Деректер оңай немесе табиғи түрде кластерленген кезде, кластерлеу алгоритмдерінің көпшілігі тез және жақсы жұмыс істейді.

Деректер жеңіл немесе табиғи кластерлеуге жауап бермеген кезде, ешқандай алгоритм жақсы кластерлерді таба алмайды.

Бұл мәлімдеме даулы болуы мүмкін және "оңай немесе табиғи түрде кластерленген" термині мұнда анықталмаған. Бірақ, әрине, деректерді кластерлеудің көптеген жолдары бар және олардың ең көп тарағандары кластерлермен ақылға қонымды деректер мысалдарында жұмыс істейді.

№13 Емтихан билеті

1. "Iid" мәні

Деректерді талдаудың көпшілігі кейбір мәліметтер жиынтығынан басталады; біз бұл мәліметтер жиынтығын P деп атаймыз, ол n деректер нүктелерінің жиынтығынан тұрады $P = \{p_1, p_2, \ldots, p_n\}$.

Бірақ бұл деректердің негізінде әрдайым дерлік, осы деректердің бекітілген, бірақ әдетте белгісіз pdf-тен (ықтималдық тығыздығы функциясы-Probability Density Function) тұратын iid-мен келеді деген өте күшті болжам бар, оны f деп атайық. " iid" нені білдіреді: бірдей және тәуелсіз таратылған (Identically and Independently Distributed). "Бірдей" - әрбір деректер нүктесі бірдей f-тен алынғанын білдіреді. "Тәуелсіз" бірінші нүктелердің келесі нүктенің мәніне ешқандай қатысы жоқ екенін білдіреді

Мысал: Сауалнама

Алдағы сайлауда $n = 1000$ ықтимал сайлаушыларды сауалнамасын қарастырайық. Егер біз сауалнамаға қатысқан әрбір адам iid-лік таңдалды деп есептесек, онда біз мұны барлық ықтимал сайлаушылардың таралуы сияқты, негізгі f таралуы туралы бір нәрсені түсіну үшін пайдалана аламыз.

Жалпы алғанда, f кез-келген процестің нәтижесі болуы мүмкін, мейлі ол рандомизацияланған алгоритм, шулық зондтау әдісі немесе жануарлардың кез-келген түрінің әдеттегі мінез-құлқы болсын. Осы жағдайлардың әрқайсысында біз процесті (алгоритм, өлшеу, мұқият бақылау), оған іріктеуді (үлгіні) бере отырып, "сұраймыз" және оны бірнеше рет қайталаймыз.

Мұнда біз f орташа мәнін бағалау туралы айтатын боламыз. Мұны талқылау үшін, біз енді $X \sim f$ кездейсоқ шамасын енгіземіз; гипотетикалық жаңа деректер нүктесін. f орташа мәні- бұл күтілетін X мәні: $\mathbf{E}[X]$.

Біз $\bar{P} = \frac{1}{n}\sum_{i=1}^{n} p_i$. арқылы анықталған, *іріктелген орташа* көмегімен f орташа мәнін бағалаймыз. Бұл жалпы процесс келесі схемада ұсынылған: белгісіз f процесінен біз n тәуелсіз бақылаулар жиынтығына $\{ p_i \}$ сәйкес келетін n iid -лік $\{ X_i \}$ кездейсоқ шамаларын қарастырамыз және олардың орташа мәнін аламыз $\bar{P} = \frac{1}{n}\sum_{i=1}^{n} p_i$ (f орташа мәнін бағалау үшін).

$$\bar{P} \underset{\frac{1}{n}\sum}{=} \{p_i\} \underset{\text{realize}}{\leftarrow} \{X_i\} \underset{\text{iid}}{\sim} f$$

2. Қашықтықты өңдеу

$C \cong B$, демек $C \cong A \cap B$, және, демек $|A \setminus C| + |B \setminus C| \geq |A \setminus B| + |B \setminus A| = |A \Delta B|$ деп болжаймыз.

1.2 Қашықтықты өңдеу (Edit Distance)

Σ - жиын болсын, бұл жағдайда мүмкін таңбалардың алфавиті (мысалы, барлық ASCII таңбалары немесе барлық кіші әріптер, сондықтан $\Sigma = \{a, b, \ldots, z\}$). Онда d ұзындықтағы a жолы Σ^d-гі элемент деп айта аламыз; бұл Σ алфавитінен алынған таңбалардың реттелген тізбегі. Редакциялау қашықтығы $a, b \in \Sigma^d$ екі жолды және келесі операцияларды қарастырады

$\mathbf{d}_{ed}(a, b) = \#\ a = b$ жасау бойынша операциялар,

мұнда операция әріпті алып тастай алады немесе әріпті енгізе алады. Шын мәнінде, жолдардың ұзындығы бірдей болуы міндетті емес, себебі біз айырмашылықты өтеу үшін элементтерді қысқа жолға енгізе аламыз.

Мысал: Қашықтықты өңдеу

$a = mines$ және $b = smiles$ екі жолын қарастырайық. $\mathbf{d}_{ed}(a, b) = 3$.

mines

1 : *minles* **insert** *l*

2 : *miles* **delete** *n*

3 : *smiles* **insert** *s*

Операциялардың көптеген балама нұсқалары бар. *Кірістіру* операциясы *жою* операциясына қарағанда қымбатырақ болуы мүмкін. Немесе біз *ауыстыру* (*replace*) операциясына *кірістіру* немесе *жою* сияқты үлестік құнымен рұқсат бере аламыз; бұл жағдайда *mines* және *smiles* өңдеу қашықтығы небәрі 2 құрайды.

Өңдеу қашықтығы- бұл метрика. (M1) орындалады, себебі өңдеулер саны әрқашан теріс емес. (M2) Өңдеулер бірдей болған жағдайда ғана болмайды. (M3) операциялар кері тәртіпте орындалуы мүмкін. (M4) Егер c аралық "сөз" болса, онда $\mathbf{d}_{ed}(a, c) + \mathbf{d}_{ed}(c, b) = \mathbf{d}_{ed}(a, b)$, керісінше жағдайда көбірек өңдеу қажет.

Бұл үлкен мәтіндік құжаттар үшін жақсы ма? Әрқашан олай емес. Бұл баяу есептеледі - негізінде ең аз өзгерістер жиынтығын табу үшін, ең нашар жағдайда квадраттық уақытпен динамикалық бағдарламалау қажет. Және бір сөйлемді алып тастау мағынасын өзгертпестен үлкен редакциялау қашықтығына әкелуі мүмкін. Бірақ бұл кішкентай жолдар үшін жақсы. Кейбір нұсқа дұрыс жазу бойынша нұсқаулық жүйелерінің көпшілігінде қолданылады (мысалы, іздеу жүйесінің автоматты түзетуі). Бұл жақсы нұсқаулық, себебі әдетте $\mathbf{d}_{ed}(a, b) > 3$ өте үлкен, себебі, мысалы, $\mathbf{d}_{ed}(cart, score) = 4$ ауыстырумен.

3. Вороной диаграммалары

1. Вороной диаграммалары

Сайттардың (нүктелер, түйіндер) $S = \{s_1, s_2, ..., s_k\} \subset \mathbb{R}^d$ жиынын қарастырайық. Біз бұл нүктелердің $\mathbb{R}^d$ кеңістігін қалай бөлетінін түсінгіміз келеді.

Енді біз мұны ресми түрде *пошта бөлімінің мәселесі* ретінде қарастырамыз. Осы k сайттардың әрқайсысы пошта бөлімшесінің орналасқан жерін анықтасын. $\mathbb{R}^d$ - гі барлық нүктелер үшін (мысалы, $\mathbb{R}^2$-гі нүктелер үшін картадағы нүкте) біз оны ең жақын пошта бөлімшесіне тағайындағымыз келеді. $x \in \mathbb{R}^d$ бекітілген нүкте үшін біз әр пошта бөлімшесіне дейінгі қашықтықты тексере аламыз:

$$\phi_S(x) = \arg\min_{s_i \in S} \|x - s_i\|.$$

Алайда, бұл баяу болуы мүмкін (әр x нүктесі үшін барлық k объектілерінің қашықтығын тексеру аңғалдық) және барлық нүктелер үшін жалпы көрініс немесе түсінуді қамтамасыз етпейді. Бұл мәселенің "дұрыс" шешімі-Вороной диаграммасы.

Вороной диаграммасы $\mathbb{R}^d$ -ні k аймақтарына бөледі (*Вороной ұяшығы*), әр сайт үшін біреуден. i сайттары үшін аймақ анықталған.

$$R_i = \{x \in \mathbb{R}^d \mid \phi_S(x) = s_i\}.$$

Вороной қабырғалары мен төбелері. Біз талқылауды $\mathbb{R}^2$-де бастаймыз. Әрі қарай, біз S нүктелері *ортақ жағдайда* деп есептейміз: бұл орнатуда бұл үш нүктенің бірде-бір жиынтығы ортақ сызықта жатпайтынын және төрт нүктенің бірде-бір жиынтығы ортақ шеңберде жатпайтынын білдіреді.

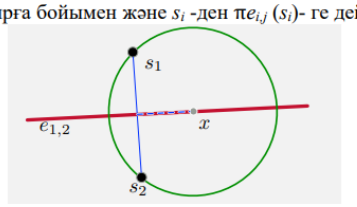
Вороной қабырғасы деп аталатын R_i және R_i екі аймағының арасындағы шекара түзу сызықты немесе кесіндісін білдіреді. Бұл $e_{i,j}$ қабырғасы

$$e_{i,j} = \{x \in \mathbb{R}^2 \mid \|x - s_i\| = \|x - s_j\| \leq \|x - s_\ell\| \text{ барлық } \ell \neq i, j \text{ үшін}\}$$

арқылы анықталады, себебі барлық нүктелердің жиыны s_i және s_j дейінгі қашықтыққа тең және ешбір басқа s_ℓ нүктесіне жақын емес.

Вороной диаграммасының қабырғасының геометриясы

Неліктен ei,j нүктелерінің жиыны түзу кесіндісі болып табылады? Егер бізде S - те тек екі нүкте болса, онда бұл екеуінің арасындағы биссектриса. Осы биссектрисаның кез-келген x нүктесінде центрі бар шеңбер сызыңыз, егер ол s_i немесе s_j біреуін кесіп өтсе, ол екіншісін де кесіп өтеді. Бұл дұрыс, себебі біз ортогональды компоненттер бойынша x-тен s_i -ге дейінгі қашықтықтың квадратын жіктей аламыз: қабырға бойымен және s_i -ден $\pi e_{i,j}$ (s_i)- ге дейінгі қабырғаға перпендикуляр.



Сол сияқты, $v_{i,j,\ell}$ Вороной төбесі - s_i, s_j және s_ℓ барлық үш түйіні бірдей қашықтықта орналасқан және ешбір басқа нүкте жақын орналаспаған, нүкте:

Бұл төбе - $e_{i,j}$, $e_{i,\ell}$ және $e_{j,\ell}$ Воронойдың үш қабырғасының қиылысы (және соңғы нүктесі). Сіз x центрі бар шеңберді сақтай және s_i және s_j -ге жанаса отырып, x нүктесін $e_{i,j}$ қабырғасының бойымен жылжытуды елестетіп көріңіз. Бұл шеңбер s_ℓ нүктесіне жанасатын жерге дейін өскенде, $e_{i,j}$ тоқтайды.

№14 Емтихан билеті

1. Орталық шекті теорема

Орталық шекті теорема. Орталық шекті теорема іріктелген орташа мәннің шынайы орташа мәнге қаншалықты жақындағанын көрсетеді. Бірақ іріктелген орташа $\bar{P}$ (бұл тұрақты шама) туралы талқылау үшін $\{X_1, X_2, \ldots, X_n\}$ кездейсоқ шамаларды және олардың орташа мәнін $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ талқылау қажет. Бұл жағдайда да $\bar{X}$ кездейсоқ шама екенін ескеріңіз. Егер біз жаңа iid-лік P' деректер жиынтығын алып, жаңа іріктелген $\bar{P}'$ орташа мәнін есептесек, онда ол $\bar{P}$-мен бірдей болмауы мүмкін; дегенмен, осы $\bar{P}'$ болатын үлестіру дәл $\bar{X}$ болуы мүмкін. Мүмкін, бұл үлестіру $\bar{P}$-ге қарағанда маңызды болар.

Орталық шекті теореманың көптеген ресми нұсқалары бар, бірақ негізгі түрі келесідей:

Орталық шекті теорема: n iid $X_1, X_2, \ldots, X_n$ кездейсоқ шамаларын қарастырайық, мұндағы әрбір $X_i \sim f$, μ орташасы және σ^2 шектеулі дисперсиясы бар кезкелген f бекітілген үлестірімі үшін. Онда $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ қалыпты үлестірімге жинақталады, оның орташа мәні $\mu = \mathbf{E}[X_i]$ және дисперсиясы σ^2/n.

Кейбір маңызды салдарды атап өтейік:

- Кез - келген f үшін (бұл өте қорқынышты емес, өйткені σ^2 шексіз емес), онда $\bar{X}$ қалыпты үлестірімге ұқсайды.
- $\bar{X}$ күтілетін мәні болып табылатын, қалыпты үлестірімнің орташа мәні $E[\bar{X}] = \mu$, f орташа мәнін қанағаттандырады (яғни әрбір i үшін, онда $E[\bar{X}] = E[X_i]$). Бұл біз $\bar{X}$-ті (содан кейін сол сияқты $\bar{P}$) μ үшін болжам ретінде пайдалана алатынымызды білдіреді.

- n өскен сайын (бізде көбірек деректер нүктелері бар) $\bar{X}$ (біздің бағалауымыздың) дисперсиясы төмендейді. Сонымен, $\bar{X}$ дұрыс күтілетін мәнге ие болғанымен, оның кейбір қателіктері бар екенін ескере отырып, n жоғарылаған сайын бұл қате азаяды.

2. Қашықтықты пайдаланып мәтінді модельдеу

2. Қашықтықты пайдаланып мәтінді модельдеу

Қашықтықтың көптеген нұсқалары бар. Қайсысын таңдау керектігі (бұл сөзсіз таңдау) (а) есептеу тиімділігінен және (б) модельдеу тиімділігінен тәуелді. $\mathbf{d}_2$ евклидтік қашықтық және кейде $\mathbf{d}_J$ Жаккард қашықтығы жиі таңдалады, себебі олар үшін әртүрлі алгоритмдік және есептеу артықшылықтары бар – көріп отырғанымыздай, бұл тиімділік қашықтықты бір рет есептеу уақытынан ғана емес, сонымен қатар оны күрделі операцияларда қалай қолдануға болатынына байланысты. Дегенмен, олардың әрқайсысының модельдеу факторларына байланысты басқа да артықшылықтары бар. Кейде бұл модельдеу тек математикалық қасиеттерге негізделген (бұл метрика ма? менің векторларым қалыпқа келтірілген бе?), кейде бұл интуитивті, ал кейде төменгі қосымшалардың өнімділігін өлшеу арқылы эмпирикалық түрде расталуы мүмкін. Бұл бөлімде мәтінді модельдеу мысалында логикалық таңдау ретінде әртүрлі қашықтықтарға қалай жетуге болатынын көрсетеміз.

Жоғарыда айтылғандай, ded қашықтықты өңдеу қысқа жолдар үшін пайдалы. Барлық басқа нұсқалар әлдеқайда үлкен мәтіндермен жұмыс істегенде пайдалы болады.

Мысал: Мәтінді орындау мысалы

Бұл бөлімде біз келесі 4 қысқа құжаттағы мәтінді ағымдағы мысал ретінде қолданамыз. Іс жүзінде бұл тәсілдер әдетте әлдеқайда ұзын құжаттарға қолданылады.

D_1 : *I am Sam.*
D_2 : *Sam I am.*
D_3 : *I do not like jelly and ham.*
D_4 : *I do not, do not, like them, Sam I am.*

Осы 4 құжат арасындағы қашықтықты қалай өлшеуге болады?

3. k - центрі бойынша кластерлеуге арналған Гонсалес алгоритмі

2. *k* - центрі бойынша кластерлеуге арналған Гонсалес алгоритмі

Біз ең қарапайым және жалпы кластерлік алгоритмнен бастаймыз: Гонсалес алгоритмі.

Бұл алгоритм *k*-центрінің тұжырымдамасымен тікелей салыстырылады, мұнда әрбір нүкте қайтадан ең жақын орталыққа меншіктеледі және мақсат кез келген осындай меншіктеу байланысының ең ұзақ қашықтығының ұзындығын минимизациялау болып табылады.

Өкінішке орай, *k*-центрлерді кластерлеу міндеті дәл шешу үшін NP- қиын болып табылады.[1]

Шынында да, жалпы жағдай үшін NP-қиын оңтайлы құнның 2 коэффициенті шегінде кластерлеуді табуға арналған!

Бақытымызға орай, бұл жуықтауды 2 коэффициентімен қамтамасыз ететін қарапайым, талғампаз және тиімді алгоритм бар. Яғни, *k* мәні мен *X* жиыны үшін ол $\hat{S}$ сайттарының *k* жиынын табады, сондықтан

$$\max_{x \in X} \mathbf{d}(\phi_{\hat{S}}(x), x) \leq 2 \max_{x \in X} \mathbf{d}(\phi_{S^*}(x), x),$$

мұндағы S^* - тиімді құны бар *k* сайттарының жиынтығы. Яғни, $S^* = \text{argmin}_{S:|S|=k} \max_{x \in X} \mathbf{d}(\varphi_S(x), x)$. Сонымен қатар, іс жүзінде бұл көбінесе ең нашар жағдайдың теориялық кепілдігіне қарағанда жақсы жұмыс істейді. 8.2.1 алгоритмі ретінде ұсынылған бұл алгоритм әдетте Теофило Ф.Гонсалес (1985) атына жазылады, атау осыдан шыққан. Мұны келесі сараң афоризммен сипаттауға болады: *Ашкөз болыңыз және көршілеріңізден аулақ болыңыз!*.

[1] NP - қиын термині (яғни, non-deterministic polynomial time hard-белгісіз көпмүшелік уақытында қиын) кіріс деректерінің өлшеміне қатысты жұмыс уақыты тұрғысынан белгілі бір мәселелер жиынтығы сияқты күрделі мәселелерді білдіреді. Бұл мәселелер үшін, егер дұрыс шешім табылса, оны тез тексеруге болады (уақыт бойынша, кіріс деректерінің өлшеміне қатысты көпмүшелік), бірақ бұл дұрыс шешімді табу үшін жалғыз белгілі тәсілдер негізінен кіріс деректерінің өлшемінен экспоненциалды уақытты талап ететін, мүмкін болатын шешімдердің экспоненциалды үлкен жиынтығы бойынша толық іріктеуге дейін келтіріледі. Бұл кіріс деректерінің өлшемінен экспоненциалды уақытты алуы тиіс пе, әлде кіріс деректерінің өлшемінен көпмүшелік уақытты алатын шешім болуы мүмкін бе, белгісіз (*P* мәселелер класы). Алайда, іс жүзінде бұл мүмкін емес деп саналады. Қысқаша айтқанда, бұл мәселелерді тиімді шешу өте қиын болуы мүмкін.

№15 Емтихан билеті

1. Шамамен дұрыс ықтималдық (PAC)

Қысқаша айтқанда, біз үлестіру құйрықтары үшін қатаң шекараларды қамтамасыз ететін, бірақ негізгі *f* үлестірімі туралы көбірек ақпаратты қажет ететін, шаралардың шоғырлануының ең көп таралған үш шегін ұсынамыз: $\mathbf{Pr}[|\bar{X} - \mathbf{E}[\bar{X}]| \geq \varepsilon] \leq \delta.$ Яғни, -тің (кейбір кездейсоқ шама, көбінесе iid кездейсоқ шамалардың қосындысы) өзінің күтілетін мәнінен (бұл *f* күтілетін мәніне, μ-ге тең, мұндағы $X_i \sim f$) ε-ге қарағанда алыс болу ықтималдығы δ-тен аспайды. Бұл ықтималдықтың *дәл* δ тең екенін айтуға тырыспайтынымызды ескерейік, бұл көбінесе тым қиын. Іс жүзінде көптеген құралдар бар және пайдаланушы олардың әрқайсысын сынап көре алады және қайсысы ең жақсы шекара беретінін көре алады. ε -бұл рұқсат етілген қателік, ал δ - сәтсіздік ықтималдығы деп санау пайдалы, яғни сәтсіздік біздің рұқсат етілген қатеден асып кететінімізді білдіреді. Алайда, көбінесе бұл шекаралар қажетті *n* іріктеу өлшемін ε және δ терминдерімен жазуға мүмкіндік береді. Бұл бізге кез-келген бекітілген белгілі *n* үшін осы екі терминмен алмасуға мүмкіндік береді; егер біз сәтсіздікке жол беруге дайын болсақ, біз аз қателікке кепілдік бере аламыз және керісінше.

2. "Сөздер жиынтығы" векторлары

2.1 "Сөздер жиынтығы" векторлары

Қашықтықты қолдана отырып, мәтінді абстрактілі көрініске айналдырудың қарапайым моделі - "сөздер жиынтығы" тәсілі. Интуитивті түрде әр құжат "пакет" құрып, әр сөзді сол "пакетке" (көп мағыналы деректер құрылымы) орналастырады және әр сөздің санын ғана сақтайды. Бұл әр құжатты көп жинаққа түрлендіреді. Дегенмен, бұл туралы (өте сиретілген, бұл негізінен 0s дегенді білдіреді) вектор ретінде ойлау оңғайлы.

Яғни, өте үлкен D үшін $v \in \mathbb{R}^d$ векторын қарастырайық, мұндағы D-барлық мүмкін сөздердің саны. Мұндай вектордың әрбір координаты бір сөзге сәйкес келеді және сол сөздің санын жазады.

Бұл векторлық көріністер, әрине, олардың арақашықтығын өлшеу үшін L_p қашықтығын, көбінесе $\mathbf{d}_2$ қолдануға болатындығын болжайды. Дегенмен, косинустық қашықтықтағы $\mathbf{d}_{\cos}$ қолдану жиі кездеседі.

Мұның артықшылығы-белгілі бір құжаттарға олардың көлемі үшін айыппұл салынбайды, негізінен олардың мазмұнына көбірек көңіл бөлінеді. Мысалы, қарапайым сөз тіркесі бар құжат $\mathbf{d}_{\cos}$ -қа сәйкес осы сөз тіркесі бірнеше рет қайталанатын басқа құжатпен бірдей болады. Немесе бейсбол туралы екі құжат, әдетте, ұқсас сөздер жиынтығынан тұрады (мысалы, {*бит, доп, соққы, жүгіру, ұру, беру*}) және олардың ұзындығы әртүрлі болса да, жақын болуы мүмкін.

Мысал: Сөздер жиынтығы

Ағымдағы мысал үшін D = 11 бар D-өлшемді кеңістікті қарастырайық; ол әлдеқайда жоғары болуы мүмкін. Әрбір координат үшін біз сәйкес сөзді келесідей тізімдейміз

(*am, and, do, ham, I, jelly, like, not, Sam, them, zebra*).

Енді құжаттардың әрқайсысында келесі көрсеткіш векторлар бар

$$v_1 = (1,0,0,0,1,0,0,0,1,0,0)$$
$$v_2 = (1,0,0,0,1,0,0,0,1,0,0)$$
$$v_3 = (0,1,1,1,1,1,1,1,0,0,0)$$
$$v_4 = (1,0,2,0,2,0,1,2,1,1,0).$$

Енді біз осы векторлар арасында $\mathbf{d}_2$ евклидтік қашықтықты (немесе кез келген басқа L_p қашықтықты) пайдалана аламыз. Мәтін әртүрлі болса да, $\mathbf{d}_2(v_1, v_2) = 0$ екенін байқаймыз. Алайда, сөздер жиынтығы олардың қалай қолданылатынын емес, қандай сөздердің бар екенін ғана өлшейтіндіктен, ол бұл жағдайларды ажырата алмайды.

Сондай-ақ, zebra сөзі үшін 11-ші координат ешқашан қолданылмайтынын және векторлардың барлық координаттарында 0-ге тең екеніне назар аударыңыз. Егер бұл координат алынып тасталса және тек 10 өлшемді көрініс қолданылса, бұл қашықтықты өзгертпес еді. Екінші жағынан, бұл векторлар әлдеқайда үлкен болуы мүмкін және көптеген басқа сөздерді білдіруі мүмкін және бұл қашықтыққа әсер етпейді.

	(v_1, v_2)	(v_1, v_3)	(v_1, v_4)	(v_2, v_3)	(v_2, v_4)	(v_3, v_4)
$\mathbf{d}_2$	0	2.83	3.32	2.83	3.32	3
$\mathbf{d}_{\cos}$	0	0.781	0.423	0.781	0.423	0.339

Сонымен қатар, біз $\mathbf{d}_{\cos}$ косинустық қашықтықты пайдалана аламыз. Бұл мәтінді басқаша модельдейді, басты айырмашылығы-ол векторларды қалыпқа келтіреді. Мәселен, мысалы, D_3 және D_4 енді бір-бірінен алшақ болуы мүмкін, себебі оларда $\mathbf{d}_2$-мен жағдайдағыдай көп сөздер бар. Бұл метрика әлі де D_1 және D_2 бірдей деп санайды.

3. Сызықтық жіктеуіштер

1 Сызықтық классификаторлар

Мұндағы біздің кіріс деректеріміз $X \subset \mathbb{R}^d$ нүктелерінің жиынтығы болып табылады, мұнда әрбір $x_i \in X$ элементі сәйкес y_i белгісіне ие болады. Және $y_i \in \{-1, +1\}$.

Регрессия сияқты, біздің мақсатымыз - болжау және жалпылау. Біз әрбір $(x_i, y_i) \sim \mu$, яғни деректер нүктелерінің әрбір жұбы белгілі бір тұрақты, бірақ белгісіз үлестірімнен iid алады деп болжаймыз.Содан кейін біздің мақсатымыз- $g : \mathbb{R}^d \to \mathbb{R}$ функциясы, егер $y_i = +1$ болса, онда $g(x_i) \geq 0$, ал егер $y_i = -1$ болса, онда $g(x_i) \leq 0$.

Біз g сызықты болумен шектелеміз. $x \in \mathbb{R}^d$ деректер нүктесі үшін $x = (x^{(1)}, x^{(2)}, \ldots, x^{(d)})$ жазбасын қолданамыз

$$g(x) = \alpha_0 + x^{(1)}\alpha_1 + x^{(2)}\alpha_2 + \ldots + x^{(d)}\alpha_d = \alpha_0 + \sum_{j=1}^{d} x^{(j)}\alpha_j,$$

$\alpha = (\alpha_0, \alpha_1, \alpha_2, \ldots, \alpha_d)$ скалярлық параметрлердің кейбір жиынтығы үшін. Әдетте басқа белгілер қолданылады: $b = \alpha_0$ және $w = (w_1, w_2, \ldots, w_d) = (\alpha_0, \alpha_1, \alpha_2, \ldots, \alpha_d) \in \mathbb{R}^d$ орнатамыз. Содан кейін жазамыз

$$g(x) = b + x^{(1)}w_1 + x^{(2)}w_2 + \ldots + x^{(d)}w_d = \langle w, x \rangle + b.$$

Енді біз (w, b)-ны $\mathbb{R}^d$ - гі жартылай кеңістіктің анықтамасы ретінде түсіндіре аламыз. Мұнда w - бұл жартылай кеңістіктің шекарасына нормаль (оған ортогональды жалғыз бағыт), ал b-бұл $\mathbf{0} = (0, 0, \ldots, 0)$ координаттар басынан $w/\|w\|$ бағытындағы жартылай кеңістік шекарасына дейінгі қашықтық. w жартылай кеңістіктің шекарасына перпендикуляр болғандықтан, b сонымен қатар жартылай кеңістіктің шекарасындағы ең жақын нүктеден координаттардың басына дейінгі қашықтық болып табылады (кез келген бағытта).

Әдетте біз w бірлік вектор ретінде қолданамыз, бірақ бұл маңызды емес, өйткені оны b өзгерту арқылы реттеуге болады. w, b - бұл $\|w\| = 1$ болғандағы қажетті жартылай кеңістік болсын. Енді бізде тағы $\|w'\| = \beta \neq 1$ және $w = w'/\|w'\|$ бірге w', b' бар делік, сондықтан олар бір бағытты көрсетеді, ал b' олар бірдей жартылай кеңістікті анықтайтындай етіп берілген. Бұл $b' = b \cdot \beta$ және $b = b'/\beta$ дегенді білдіреді. Осылайша, w қалыпқа келтіру кез-келген құрылымды өзгертпестен жасалуы мүмкін.

Еске салайық, біздің мақсатымыз - $g(x) \geq 0$, егер $y = +1$ болса және $g(x) \leq 0$, егер $y = -1$ болса. Сонымен, егер x тікелей жартылай кеңістікте жатса, онда $g(x) = 0$.

№16 Емтихан билеті

1. Марков теңсіздігі

Марков теңсіздігі. X кездейсоқ шама болсын, $X \geq 0$, яғни ол теріс мәндерді қабылдай алмайды. Онда кез-келген $\alpha > 0$ параметрі үшін

$$\mathbf{Pr}[X > \alpha] \leq \frac{\mathbf{E}[X]}{\alpha}.$$

Бұл $\varepsilon = \alpha - \mathbf{E}[X]$ және $\delta = \mathbf{E}[X] / \alpha$ бірге PAC шекарасы екенін ескеріңіз немесе біз бұл шекараны келесідей қайта өрнектей аламыз:

$$\mathbf{Pr}[X - \mathbf{E}[X] > \varepsilon] \leq \delta = \mathbf{E}[X]/(\varepsilon + \mathbf{E}[X]).$$

Марков теңсіздігінің геометриясы

Даяшы науаны қалай теңестіретіні сияқты, $\mathbf{E}[X]$ нүктесіндегі өз саусағыңызда қандайда бір X кездейсоқ шаманың мәнін теңестіріп жатқаныңызды елестетіп көріңіз. Егер сіздің саусағыңыз μ мәнінде болмаса, сонымен $\mathbf{E}[X] = \mu$ болса, онда pdf (және даяшы науасы) аударылып және μ – "масса орталығы" бағытына құлайды.

Енді кейбір α ықтималдық шамасы үшін, $\mathbf{E}[X] = \mu$ сақтау үшін оның орнын қаншалықты қатты арттыра аламыз. Біз үлкейтетін pdf-тің әр бөлігі үшін бөлікті пропорционалды түрде азайтуымыз керек. Алайда, $X \geq 0$ болжамында pdf массасы 0-ден төмен болмауы керек. Оның шегінде біз $\mathbf{Pr}[X = 0] = 1 - \alpha$ орната аламыз, содан кейін қалған α ықтималдығын мүмкіндігінше δ орнына жылжыта аламыз, осылайша $\mathbf{E}[X] = \mu$.

Яғни

$$\mathbf{E}[X] = 0 \cdot \mathbf{Pr}[X = 0] + \delta \cdot \mathbf{Pr}[X = \delta] = 0 \cdot (1 - \alpha) + \delta \cdot \alpha = \delta \cdot \alpha.$$

δ шеше отырып, біз $\delta = \mathbf{E}[X]/\alpha$ табамыз.

2. k-грамм

2.2 k -граммдар

"Сөз пакеті" түріндегі векторларға балама ретінде k-грамм мәтін үшін бай контекст бере алады. Олар құжатты жиынтыққа айналдырады (мультижиынтық емес), алайда олар тек сөздерді ғана қолданбайды. k -граммды қолданудың бірнеше нұсқасы бар және біз сөздер мен таңбаларға арналған екі кең таралған және қарапайым нұсқаларға тоқталамыз. Құжаттағы k-граммдық сөздер-бұл k сөздерден тұратын жиынтықтардың барлық тіркелген тізбекті жиынтығы.

Мысал: 2-Грамм сөзі

Ағымдағы мысалды қолдана отырып, біз құжаттардың әрқайсысының 2-сөздік граммын көрсетеміз. Әр грамм квадрат жақшадағы екі сөзден тұратын жиынтық түрінде көрсетілген.

$D_1 : G_1 = \{[I\ am], [am\ Sam]\}$
$D_2 : G_2 = \{[Sam\ I], [I\ am]\}$
$D_3 : G_3 = \{[I\ do], [do\ not], [not\ like], [like\ jelly], [jelly\ and]$
$[and\ ham]\}$
$D_4 : G_4 = \{[I\ do], [do\ not], [not\ do], [not\ like], [like\ them],$
$[them\ Sam], [Sam\ I], [I\ am]\}$

Нақтырақ айтсақ, D_4-те [do not] ≠ [not do] екеніне назар аударыңыз, сондықтан екеуі де G_4-те пайда болады; дегенмен, [do not] екі сөз тізбегі D_4-те екі рет пайда болғанына қарамастан, ол G_4 жиынтығында бір рет қана пайда болады.

Содан кейін біз осы жиындар арасындағы Жаккард қашықтығын құжаттар арасындағы қашықтықты бейнелеу ретінде есептей аламыз.

	(D_1, D_2)	(D_1, D_3)	(D_1, D_4)	(D_2, D_3)	(D_2, D_4)	(D_3, D_4)
d_J	$1-\frac{1}{3}$ ≈ 0.667	$1-\frac{0}{8}$ $= 1$	$1-\frac{1}{9}$ ≈ 0.889	$1-\frac{0}{8}$ $= 1$	$1-\frac{2}{8}$ $= 0.75$	$1-\frac{3}{11}$ ≈ 0.727

Модельдеу нұсқалары мен нұсқалар. Сөздер үшін k-граммды қысқартудың көптеген нұсқалары бар. Олардың ішіндегі ең көрнектісі - k тізбекті сөздердің орнына k тізбекті таңбаларды қолдану; біз оны *таңбалық k-граммдар* деп атаймыз.

Көптеген басқа модельдеу шешімдері k-граммдарын құруда қолданылады. Тыныс белгілерін қосу керек пе? Бос орынды таңба ретінде пайдалану керек пе, әлде сөйлем үзілімдері word grams-та сөз ретінде қолданылуы керек пе? Әр түрлі таңбалар немесе әр түрлі бас әріптермен жазылған сөздер әр түрлі объектілерді бейнелеуі керек пе? Ең көнілсіз нәрсе, k қаншалықты үлкен болуы керек?

Мысал: Символдық (таңбалық)k-граммдар

D_4 құжат үлгісі үшін k граммдық таңбалар бос орындарды, тыныс белгілерін және бас әріптерді елемеу.

k = 3 таңбалары:
{[ido], [don], [ono], [not], [otd], [tdo], [otl], [tli], [lik],
[ike], [ket], [eth], [the], [hem], [ems], [msa], [sam], [ami],
[mia], [iam]}
Символы k = 4:
{[idon], [dono], [onot], [notd], [otdo], [tdon], [notl], [otli],
[tlik], [like], [iket], [keth], [ethe], [them], [hems], [emsa],
[msam], [sami], [amia], [miam]}

Осы нұсқалардың барлығына бірнеше жалпы ережелер қолданылады. Біріншіден, k–граммдары неғұрлым мәнерлі болса (мысалы, тыныс белгілерін, бас әріптерді және бос орындарды қадағалау), мағыналы нәтижелерге қол жеткізу үшін соғұрлым көп деректер қажет болады - әйтпесе, құжаттардың көпшілігінде жаккард бойынша 1 қашықтық болады немесе оған өте жақын болады, егер мәтіннің үлкен блоктары сөзбе-сөз қайталанбаса (мысалы, плагиат).

3. Сызықтық регрессия арқылы сызықтық классификация

Сызықтық регрессия көмегімен сызықтық классификациялау. $(x_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$ әрбір деректер нүктесі үшін біз бірден x_i мәнін түсіндіретін айнымалылардың d мәні ретінде, ал y_i жалғыз тәуелді айнымалы ретінде көрсете аламыз. Содан кейін $\tilde{X}$, $n \times (d + 1)$ матрицаны бере аламыз, мұндағы i-жол (1, x_i); яғни бірінші координат 1, ал келесі d координаттары x_i векторынан алынады. Онда $y \in \mathbb{R}^n$ векторымен біз мыналарды шеше аламыз

$$\alpha = (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T y$$

бізде g_α: $\mathbb{R}^d \to \mathbb{R}$ сызықтық функциясын сипаттайтын, $\alpha = (\alpha_0, \alpha_1, ..., \alpha_d)$ коэффициенттерінің $d + 1$ жиынтығы бар

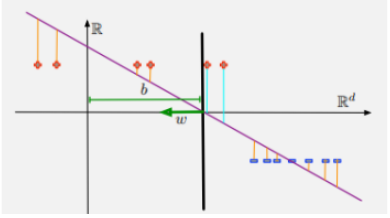
$$g_\alpha(x) = \langle \alpha, (1, x) \rangle.$$

Сондықтан, $b = \alpha_0$ және $w = (\alpha_0, \alpha_1, ..., \alpha_d)$. $g_\alpha(x) > 0$ болатындай x үшін біз $y = +1$ болжаймыз, ал $g_\alpha(x) < 0$ үшін $y = -1$ болжаймыз.

Алайда, бұл тәсіл дұрыс емес мәселені оңтайландырады. Бұл біздің gα(x) болжамдарымыздың қателік квадраттарының қосындысын азайту арқылы -1 немесе +1-ге қаншалықты жақын екенін азайтады. Бірақ біздің мақсатымыз - сандық мән емес, дұрыс түсіндірілмеген мәндер санын азайту.

Мысал: Жіктеуге арналған сызықтық регрессия

Біз $\mathbb{R}^{d+1}$-ге сәйкес келетін $\mathbb{R}^d$ -де 6 оң және 7 теріс нүктелерді көрсетеміз. d координаттарының барлығы x осіне сәйкес келеді. Соңғы координаталар y осіне сәйкес келеді және +1 (оң нүктелер) немесе -1 (теріс нүктелер) тең. Содан кейін сызықтық регрессияның ең жақсы сәйкестігі (күлгін түспен) көрсетіледі және оның y координаты 0 болатын нүктелер жартылай кеңістіктің шекарасын (тік қара сызық) анықтайды. Сызықтық бөлгіштің болуына қарамастан, бұл әдіс екі нүктені дұрыс жіктемейтінін ескеріңіз, себебі ол дұрыс емес өлшемді оңтайландырады.



№17 Емтихан билеті

1. Чебышев теңсіздігі

Чебышев теңсіздігі. Енді X кездейсоқ шама болсын, онда біз **Var**[X] және **E**[X] білеміз. Онда кез-келген $\varepsilon > 0$ параметрі үшін

$$\mathbf{Pr}[|X - \mathbf{E}[X]| \geq \varepsilon] \leq \frac{\mathbf{Var}[X]}{\varepsilon^2}.$$

Тағы да, бұл $\delta = \mathbf{Var}[X]/\varepsilon^2$ бірге PAC шекарасы екені анық. Бұл шекара әдетте Марковтан гөрі күшті өйткені δ сызықтық емес, ε бойынша квадраттық түрде төмендейді.

Мысал: Чебышев пен кофенің теңсіздігі

Тағы да, C - деректер университетінің оқытушылары бір апта ішінде ішетін кофе литрінің саны үшін кездейсоқ айнымалы болсын (**E**[C = 20]). Егер біз дисперсияның тым үлкен емес екенін білсек, атап айтқанда **Var**[C] = 9 (литр квадрат), онда жақсартылған шекараны алу үшін Чебышев теңсіздігін қолдануға болады.

$$\mathbf{Pr}[C \geq 50] \leq \mathbf{Pr}[|C - \mathbf{E}[C]| \geq 30] \leq \frac{\mathbf{Var}[C]}{30^2} = \frac{9}{900} = 0.01$$

Яғни, (**E**[C] = 20) маткүтілім және (**Var**[C] = 9) дисперсия көмегімен біз 50 л-ден асу ықтималдығын 0,01 ықтималдығына дейін азайта аламыз.

Бірінші теңсіздікте біз бір жақты C ≥ 50 өрнегінен екі жақты өрнекке ауысатынымызды ескеріңіз |C-E[C]| ≥ 30 өрнегі (яғни C-**E**[C] ≥ 30 немесе **E**[C] - C ≥ 30). Бұл біршама ысырапшылдық, сонымен қатар Чебышев теңсіздігінің қатаң біржақты нұсқалары бар, біз оларды ықшамдылық мақсатында осында талқыламаймыз.

Естеріңізге сала кетейік, кездейсоқ шаманың $\bar{X} = (X_1 + X_2 + \ldots + X_n)/n$ орташа мәні үшін, мұндағы X_i - iid, және σ^2 дисперсияға ие, онда **Var**[$\bar{X}$] = σ^2/n. Сондықтан,

$$\mathbf{Pr}[|\bar{X} - \mathbf{E}[X_i]| \geq \varepsilon] \leq \frac{\sigma^2}{n\varepsilon^2}.$$

Енді бізде ε және δ кіріс параметрлері, қажетті рұқсат етілген қателік және сәтсіздік ықтималдығы бар екенін қарастырайық. Егер біз белгісіз f үшін $X_i \sim f$ (iid) құра алсақ (белгілі күтілетін мәнмен және σ дисперсиясымен), онда n қаншалықты үлкен болуы керектігін шеше аламыз: $n = \sigma^2/(\varepsilon^2\delta)$.

Себебі iid $X_1, X_2, \ldots, X_n$ кездейсоқ шамалары үшін **E** [$\bar{X}$] = **E** [X_i] болғандықтан, онда n деректер көлемін ұлғайту кезінде шоғырланудың жақсарғанын көрсететін Марков теңсіздігі үшін ұқсас мағыналы-ажыратылатын кеңейту жоқ.

Чернофф-Хеффдинг теңсіздігі. Жоғарыдағы Чебышев теңсіздігінің кеңеюіне сүйене отырып, біз $X_1, X_2, \ldots, X_n$ кездейсоқ шамалардың n iid жиынтығын қарастыра аламыз, мұндағы $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$. Енді біз әрбір X_i -дің $[b, t]$ шектеулі аймағында жатқанын біледі делік, және $\Delta = t - b$ болсын. Онда $\varepsilon > 0$ кез-келген параметрі үшін

$$\mathbf{Pr}[|\bar{X} - \mathbf{E}[\bar{X}]| > \varepsilon] \leq 2\exp\left(\frac{-2\varepsilon^2 n}{\Delta^2}\right).$$

Тағы да, бұл PAC шегі, енді $\delta = 2\ \exp(-2\ \varepsilon^2 n\ /\Delta^2)$. Қажетті ε қатесі және δ сәтсіздік ықтималдығы үшін біз $n = (\Delta^2/(2\varepsilon^2))\ \ln(2/\delta)$ орната аламыз. Назар аударыңыз, бұл Чебышевтің шектеуі сияқты ε-мен ұқсас байланысқа ие, бірақ n-нің δ-ден тәуелділігі бұл шектер үшін экспоненциалды аз.

2. Сөздердің үздіксіз жиынтығы (пакеті)

Сөздердің (пакеттің) үздіксіз жиынтығы (*continuous bag-of-words*). Шегініс ретінде біз соңғы тенденцияны атап өтеміз. Бүкіл құжаттардың абстрактілі көріністерін жасаудың орнына, біз құжаттардың бірігуінде қалай көрінетініне сүйене отырып, әр сөз үшін ұқсас көріністер жасау үшін көптеген осындай құжаттарды қолдана аламыз. Бұл әдістер әдетте сөздерді евклидтік бейнелеуге бағытталған. Сөздер жиынтығы үшін бұл векторлық сөз тіркесі деп аталады. Онда бұл сөздердің абстрактілі көріністері арасындағы қашықтық әртүрлі ақпаратты алып жүретіндігін көрсетуге болады.

Мұндай әдістер өте көп, бірақ жоғары деңгейде олар сөздің әр данасы үшін сөздер жиынтығын құрудан басталады. Яғни, мәтіндегі сөздердің кейбір дәйекті r радиусы шегінде сөздің әрбір данасы үшін D-өлшемді вектор құрылады (мұнда біз әр жол үшін D өлшемі шегінде есептеулерді қолдаймыз). Бұл мысалдағы $D = 11$ сөзге ұқсас, бірақ әдетте D - бұл ондаған немесе жүздеген мың. Әр сөздің бұл векторлық көрінісі сиретілген және көршісіндегі әрбір басқа сөздің еселігін есептейді. Содан кейін бұл векторлар әр сөздің барлық даналары бойынша орташаланады. Бұл үздіксіз сөздер жиынтығының моделі немесе CBOW (*continuous bag-of-words*) деп аталады. Әдетте, бұл көріністер көбінесе 200 немесе 300 өлшемдерді қолдана отырып, кішірек өлшемді көрініске дейін сызықтық емес қысылады.

3. Перцептрон алгоритмі

2. Перцептрон алгоритмі

Жоғарыда аталған барлық алгоритмдердің ішінде әдеттегі сызықтық регрессия дұрыс есепті шешпейді, ал градиентті түсіру әдістері есептің құрылымын пайдаланбайды. Шындығында, көретініміздей, егер градиентті есептей алсақ, $g_a(x) = \langle a, (1,x) \rangle$ сызықтық функциясын кез келген g функциясымен (тіпті сызықтық емес) ауыстыра аламыз. Енді біз есептің сызықтық құрылымын нақты қолданатын перцептрон алгоритмін қарастырамыз. (Техникалық тұрғыдан алғанда, ол тек скалярлық көбейтіндінің болу фактісін пайдаланады-біз оны жалпылауда қолданамыз.)

Ықшамдау: Ықшамдау үшін біз деректер туралы бірнеше болжам жасаймыз. Біріншіден, біз ең жақсы сызықтық классификатор (w^*, b^*) - бұл жартылай кеңістік, оның шекарасы кординаттардың басынан өтеді деп болжаймыз. Бұл $b^* = 0$ дегенді білдіреді және біз оны елемеуіміз мүмкін. Бұл $x_i = (1, x_i') \in \mathbb{R}^d$ көмегімен $(x_i', y_i) \in \mathbb{R}^{d'} \times \mathbb{R}$ деректер нүктеліне арналған, мұндағы $d' + 1 = d$.

Екіншіден, барлық (x_i, y_i) деректер нүктелері үшін $\|x_i\| \leq 1$ шарты орындалды деп есептейміз (мысалы, барлық деректер нүктелері бірлік шарда). Мұны $\|x_{max}\|$ ең үлкен нормасы бар $x_{max} \in X$ нүктесін таңдап, барлық деректер нүктелерін $\|x_{max}\|$ - на бөлу арқылы жасауға болады, осылайша бұл нүкте 1 нормаға ие болады, ал қалған нүктелер аз нормаларға ие болады.

Соңында, әрбір деректер нүктесін дұрыс сыныпқа жіктейтін тамаша сызықтық классификатор бар деп есептейміз. Перцептрон алгоритмінің нұсқалары бар, олар сізге керемет классификаторларсыз жұмыс істеуге мүмкіндік береді, бірақ олар осы мәтін шеңберінен тыс.

Алгоритм. Енді алгоритмді іске қосу үшін біз қалыпты w бағытынан бастаймыз (кез-келген оң нүктемен инициализацияланған), содан кейін w -ге қате жіктелген нүктелерді бір-бірден қосамыз.

Алгоритм 1. Персептрон(X, y)

Кез келген $(x_i, y_i) \in (X, y)$ үшін $w = y_i x_i$ инициализациялау

қайталау

Кез келген (x_i, y_i) үшін $y_i \langle x_i, w \rangle < 0$ (қате жіктелген) болатын: $w \leftarrow w + y_i x_i$ жаңарту

(қате жіктелген нүктелер немесе T қадамдары жоқ) болғанша

$w \leftarrow w / \| w \|$ **қайтару**

Негізінде, егер біз дұрыс жіктелмеген нүктені (x_i, y_i) және $y_i = +1$ тапсақ, онда біз $w = w + x_i$ орнатамыз. Бұл w-ді xi-ге жақындатады, бірақ оны ұзағырақ етеді. $w\, x_i$ -ге көбірек бағытталған кезде, бұл оның скалярлық көбейтіндісін (w -нің қалыпқа келтірілген нұсқасымен) 1-ге жақындатуға бейім.

Сол сияқты, егер $y_i = -1$ бар дұрыс жіктелмеген нүктені (x_i, y_i) тапсақ, онда біз $w = w + x_i$ орнатамыз; бұл w терістеуін x_i жағына қарай "итереді", демек, $w\, x_i$ -ден алшақтайды, ал оның скалярлық көбейтіндісі теріс болады.

№18 Емтихан билеті

1. Чернофф-Хеффдинг теңсіздігі

Чернофф-Хеффдинг теңсіздігі. Жоғарыдағы Чебышев теңсіздігінің кеңеюіне сүйене отырып, біз $X_1, X_2, \ldots, X_n$ кездейсоқ шамалардың n iid жиынтығын қарастыра аламыз, мұндағы $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$. Енді біз әрбір X_i -дің $[b, t]$ шектеулі аймағында жатқанын білеміз делік, және $\Delta = t - b$ болсын. Онда $\varepsilon > 0$ кез-келген параметрі үшін

$$\mathbf{Pr}[|\bar{X} - \mathbf{E}[\bar{X}]| > \varepsilon] \leq 2\exp\left(\frac{-2\varepsilon^2 n}{\Delta^2}\right).$$

Тағы да, бұл PAC шегі, енді $\delta = 2\exp(-2\,\varepsilon^2 n\,/\Delta^2)$. Қажетті ε қатесі және δ сәтсіздік ықтималдығы үшін біз $n = (\Delta^2/(2\varepsilon^2))\ \ln(2/\delta)$ орната аламыз. Назар аударыңыз, бұл Чебышевтің шектеуі сияқты ε-мен ұқсас байланысқа ие, бірақ n-нің δ-ден тәуелділігі бұл шекара үшін экспоненциалды аз.

Мысал: Чернофф-Хоффдинг және сүйектер.

Сүйекті 120 рет лақтырып, 3-тің қанша рет түсетінін жазып алыңыз. T- түскен үштіктердің жалпы санын анықтайтын кездейсоқ шама болсын. Әрбір лақтыру 1/6 ықтималдықпен түседі, сондықтан үштіктің күтілетін саны $\mathbf{E}[T] = 20$ болады. Біз 40-тан астам лақтырудың 3-ті қайтару ықтималдығы қандай екеніне жауап бергіміз келеді.

Ол үшін әр лақтырумен байланысты, $n = 120$ iid $T_1, T_2, \ldots, T_n$ кездейсоқ шамаларын талдаймыз. Атап айтқанда, $T_i = 1$, егер i-ші лақтыру 3-ке тең болса және басқаша жағдайда 0-ге тең. Осылайша, әр лақтыру үшін $\mathbf{E}[T_i] = 1/6$. $\bar{T} = T/n = \frac{1}{n}\sum_{i=1}^{n} T_i$ пайдалану және $\mathbf{Pr}\,[T \geq 40] = \mathbf{Pr}\,[\bar{T} \geq 1/3]$ белгілей отырып, біз енді Чернофф-Хоффдинг шектеулерін келесідей қолдана аламыз

$$\mathbf{Pr}[T \geq 40] \leq \mathbf{Pr}\left[\left|\bar{T} - \mathbf{E}[T_i]\right| \geq \frac{1}{6}\right] \leq 2\exp\left(\frac{-2(1/6)^2 \cdot 120}{1^2}\right) = 2\exp(-20/3) \leq 0.0026$$

Осылайша, 1000-нан 3 -тен аз жағдайда, осы 120 лақтыруды орындау кезінде біз 40-тан астам қайтарылған 3 көреміз деп айтуға болады.

Салыстыру үшін біз Чебышев теңсіздігін де қолдана аламыз. Бір T_i кездейсоқ шаманың дисперсиясы $\mathbf{Var}[T_i] = 5/36$, демек, $\mathbf{Var}[T] = n \cdot \mathbf{Var}[T_i] = 50/3$. Сондықтан біз келесідей шектеулер қоя аламыз

$$\mathbf{Pr}[T \geq 40] \leq \mathbf{Pr}[|T - 20| \geq 20] \leq (50/3)/20^2 \leq 0.042$$

Яғни, Чебышевтің теңсіздігін қолдана отырып, біз бұл оқиғаның орын алуы 1000 сынақ ішінде 42 реттен аспауы керек деп айта алдық.

Соңында, біз осы талдаулардың екеуінде де 3-ке тең лақтыру санының белгілі бір шектен (≥ 40) асып кету ықтималдығын шектеуге тырысамыз, ал біз қолданатын теңсіздік орташа мәннен ауытқудың абсолютті мәнін шектеді. Яғни, біздің мақсатымыз біржақты болды, ал теңсіздікте күштірек екі жақты шекара болды. Шынында да, бұл нәтижелерді ұқсас біржақты теңсіздіктерді қолдану арқылы шамамен 2 есе жақсартуға болады, оларды біз мұнда ресми түрде көрсетпейміз.

Мұның бәрін CLT-дегі Гаусстың таралуымен байланыстыра отырып, Чебышев шектеуі тек Гаусс дисперсиясы туралы ақпаратты пайдаланады, бірақ Чернофф-Хеффдинг шектеуі барлық "сәттерді" пайдаланады: бұл сәтсіздік ықтималдығын экспоненциалды түрде азайтуға мүмкіндік береді.

Бұл PAC шоғырлануын өлшеудің ең негізгі және кең таралған шекаралары, бірақ олар толық емес.

2. Ұқсастықтар

3. Ұқсастықтар

d арақашықтығының екі жақты ұғымы, **s** ұқсастығы болып табылады. Бұл әлі де екі өлшемді функция, бірақ аргументтер жақын болған кезде мән үлкен болуы керек. Көбінесе, бірақ әрдайым емес, анықтамалар қалыпқа келтіріледі, сондықтан объектінің өз-өзіне ұқсастығы $\mathbf{s}(A, A) = 1$, және сондықтан функция диапазоны [0, 1] - де болады, бұл толығымен өзгеше, A, B мәндер жұбының $\mathbf{s}(A, B) = 0$ мәндеріне ие болатындығын көрсетеді.

Ұқсастықты қашықтыққа айналдырудың екі стандартты әдісі бар. Жиынға негізделген ұқсастықтар үшін қашықтық әдетте $\mathbf{d}(A, B) = 1 - \mathbf{s}(A, B)$ түрінде алынады. Векторлық және нормаға негізделген ұқсастықтарда қашықтық әдетте $\mathbf{d}(A, B) = \sqrt{\mathbf{s}(A, A) + \mathbf{s}(B, B) - 2\mathbf{s}(A, B)}$. ретінде анықталады.

3.1 Нормаланған ұқсастықтар

Ең негізгі нормаланған ұқсастық-евклидтік нүктелік көбейтінді. $p, q \in \mathbb{R}^d$ екі векторы үшін *нүктелік көбейтіндінің ұқсастығын* келесідей анықтай аламыз

$$\mathbf{s}_{\text{dot}}(p, q) = \langle p, q \rangle;$$

яғни, жай ғана нүктелік көбейтінді. Шынында да, бұл евклидтік қашықтыққа айналады

$$\begin{aligned}\mathbf{d}_2(p, q) = \|p - q\|_2 &= \sqrt{\mathbf{s}_{\text{dot}}(p, p) + \mathbf{s}_{\text{dot}}(q, q) - 2\mathbf{s}_{\text{dot}}(p, q)} \\ &= \sqrt{\langle p, p \rangle + \langle q, q \rangle - 2\langle p, q \rangle} \\ &= \sqrt{\|p\|_2^2 + \|q\|_2^2 - 2\langle p, q \rangle}.\end{aligned}$$

Алайда, бұл жағдайда ұқсастық қалағаныңызша үлкен болуы мүмкін және шын мәнінде p векторының өзіне-өзі ұқсастығы $\mathbf{s}_{\text{dot}}(p, p) = \langle p, p \rangle = \|p\|^2$ евклидтік норманың квадраты болып табылады. Ұқсастықтың 1-ден аспауын қамтамасыз ету үшін алдымен векторларды қалыпқа келтіре аламыз және *косинустық ұқсастық* аламыз

$$\mathbf{s}_{\cos}(p, q) = \langle \frac{p}{\|p\|}, \frac{q}{\|q\|} \rangle = \frac{\langle p, q \rangle}{\|p\|\|q\|}.$$

Нормаланған түрлендіру арқылы қашықтыққа түрлендіру:

$$\sqrt{\mathbf{s}_{\cos}(p, p) + \mathbf{s}_{\cos}(q, q) - 2\mathbf{s}_{\cos}(p, q)} = \mathbf{d}_2\left(\frac{p}{\|p\|}, \frac{q}{\|q\|}\right)$$

3. k-NN классификаторы

4. *k*NN классификаторы

Енді мүлдем басқа нәрсеге көшейік. Классификаторды анықтаудың көптеген жолдары бар және біз олардың кейбірін жаңа ғана қозғадық. Оларға шешім ағаштары (олар негізінен "иә" / "жоқ" сұрақтар сериясын қояды және түсіндіруге өте оңай) және терең нейрондық желілер (олар күрделірек, түсіндіруі қиын, бірақ үлкен дәлдікке қол жеткізе алады) жатады. Біз тағы бір қарапайым жіктеуішті сипаттаймыз.

k-NN классификаторы (немесе k -жақын көршілер классификаторы) келесідей жұмыс істейді. k скалярлық параметрін таңдаңыз (k тақ сан ретінде таңдау әлдеқайда қарапайым болады, айталық $k = 5$). Содан кейін $maj : \{-1, +1\}^k \to \{-1, +1\}$ мажоритарлық функциясын (көпшілік функциясын) анықтаңыз. $Y = (y_1, y_2, \ldots, y_k) \in \{-1, +1\}^k$ жиыны үшін:

$$maj(Y) = \begin{cases} +1 - \text{егер } \frac{k}{2} \text{элементтен артық болса } Y \text{ тең } +1 \\ -1 - \text{егер } \frac{k}{2} \text{элементтен артық болса } Y \text{ тең } -1. \end{cases}$$

Содан кейін, $x_i \in X$ әрбір элементі сәйкес $y_i \in \{-1, +1\}$ белгісіне ие болатын X деректер жиыны үшін $\varphi_{X,k}(q)$ - k -жақын көршілер функциясын анықтаңыз, ол q сұрау нүктесіне ең жақын X -гі k нүктелерін қайтарады. Әрі қарай sign кезкелген x_i кіріс нүктесі үшін y_i хабарлайды; x_i кіріс деректерінің жиынтығы үшін ол y_i мәндерінің жиынтығын қайтарады.

Соңында, *k*-NN классификаторы

$$g(q) = maj(sign(\varphi_{X,k}(q))).$$

Яғни, ол q сұрау нүктесінің k-ең жақын көршілерін табады және осы нүктелердің барлық класс белгілерін қарастырады және сол белгілер бойынша дауыстардың көпшілігін қайтарады.

Көптеген басқа оң нүктелерге жақын q нүктесін сұрау +1-ді әрине дерлік қайтарады және теріс нүктелер үшін симметриялы болады. Бұл жіктеуіш көптеген тапсырмалар үшін таңқаларлықтай жақсы жұмыс істейді, бірақ $\varphi_{X,k}$ анықтауға арналған қашықтық функциясының жақсы таңдауына сүйенеді.

Өкінішке орай, жіктеуіштің моделі тек барлық X-тен тәуелді. сондықтан үлкен X деректер жиынтығында бағалау көп уақытты алуы мүмкін. Керісінше, жоғарыда сипатталған ядролық емес әдістерге арналған g функциялары $\mathbb{R}^d$ нүктелерін есептеу үшін $O(d)$ уақытты қажет етеді және осылайша өте тиімді.

№19 Емтихан билеті

1. Квантильдік бағалау

Кванттық бағалау-квантильдің мәнін бағалау үшін қолданылатын статистикалық талдау әдісі (квантильдер үлестірімді белгілі бір бөліктерге бөлетін мәндер, мысалы, медиана үлестірімді екіге бөледі). Кванттық бағалау, мысалы, деректердің белгілі бір пайызы төмендейтін мәнді анықтау маңызды болған кезде пайдалы болуы мүмкін.

Кванттық бағалауды алудың негізгі әдістерінің бірі-деректер үлгісін пайдалану. Мысалы, медианаңы (50%-квантиль) бағалау үшін деректерді өсу бойынша реттеуге және деректерді екіге бөлетін мәнді таңдауға болады. Сол сияқты, басқа квантильдерді бағалау үшін (мысалы, деңгей квантилі p, мұндағы $0 < p<1$), p-квантиль бөлетін мән болатын тәсілді қолдануға болады p деректер пайызы.

Ресми түрде, егер $X_1, X_2, \ldots, X_n$- кездейсоқ іріктеу бақылаулары, p-квантиль, Q_p ретінде белгіленеді , келесідей анықталады: $Q_p = F^{-1}(p)$

қайда F (x) - кездейсоқ шаманың таралу функциясы, а $F^{-1}(p)$ - кері тарату функциясы.

Егер деректер өсу бойынша реттелген болса, онда p-квантильді бөлетін реттік статистикаға сәйкес келетін мән ретінде бағалауға болады $p \times n$ бақылаулар.

Кванттық бағалау статистика мен эконометрикада деректердің таралуын талдау және әртүрлі таралу сипаттамаларын бағалау үшін жиі қолданылады.

2. Орналасқан жерді ескере отырып хэштеу. Жергілікті сезімтал хэштер тобы

Орналасқан жерді ескере отырып хэштеу немесе жергілікті сезімтал хэш тобы-бұл хэштеу кезінде деректердің кеңістіктік орналасуын ескеретін әдіс. Кәдімгі хэш функциялары

деректерді бүкіл хэш кеңістігіне біркелкі таратуға тырысады, бірақ кейбір жағдайларда, мысалы, географиялық деректермен жұмыс істеу кезінде жергілікті деректер қасиеттерін сақтау пайдалы болуы мүмкін.
Жергілікті сезімтал хэш тобын, мысалы, географиялық жақындықты ескеру маңызды тапсырмаларда қолдануға болады. Бұл, мысалы, географиялық мәліметтер базасында, геолокацияда немесе орналасу маңызды фактор болып табылатын басқа сценарийлерде жақын объектілерді іздеу кезінде пайдалы болуы мүмкін.
Жергілікті сезімтал хэш тобының принципі кеңістіктегі жақын объектілерді хэш функциясының жақын мәндеріне көрсету болып табылады. Осылайша, хэш кеңістігіндегі объектілердің көршілігі олардың орналасу кеңістігіндегі физикалық көршілігін көрсетеді.
Бір мысал функцияны пайдалану болуы мүмкін

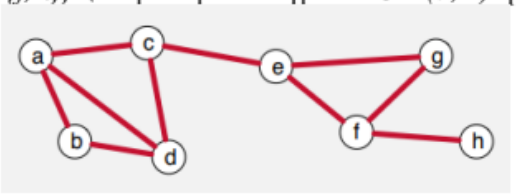
3. Графтарға арналған негізгі анықтамалар мен модельдер

Графтар үшін негізгі анықтамалар мен модельдер. Ресми түрде (бағдарланбаған) $G = (V, E)$ графы $V = \{v_1, v_2, \ldots, v_n\}$ шыңдар жиынтығы және $E = \{e_1, e_2, \ldots, e_m\}$ қабырғалар жиынтығымен анықталады, мұнда әрбір e_j қабырғасы шыңдардың реттелмеген жұбы болып табылады: $e_j = \{v_i, v_{i'}\}$. *Бағдарланған графта* қабырғалар реттелген және $e_j = \{v_i, v_{i'}\}$ - v_i түйінінің $v_{i'}$ - ге бағытталғанын көрсетеді, бірақ керісінше бағытта емес.

v_1 және v_k екі шыңы *байланысқан*, егер $\langle e_1, \ldots, e_{k-1}\rangle$ қабырғалар тізбегі болса, e_1 –ге v_1, e_{k-1} -ге v_k кіреді және тізбекті қабырғалар, $e_j = \{v_i, v_{i+1}\}$ және $e_{j+1} = \{v_{i+1}, v_{i+2}\}$ болатындай етіп реттелуі мүмкін, мұнда e_j -гі екінші элемент e_{j+1} -гі біріншісіне сәйкес келеді. Кез келген $v_i, v_{i'} \in V$ екі шыңның арасындағы $\mathbf{d}_E(v_i, v_{i'})$) граф арақашықтығы ($E$ қабырғалар жиынымен индукцияланған) - бұл v_i -ден $v_{i'}$ - ге өту үшін қажет қабырғалардың ең минималды саны. Бұл бағдарланбаған графтар үшін метрика; бағдарланған графтар үшін ол симметриялық болмауы мүмкін.

Мысал: Бағдарланбаған граф

$V = \{a, b, c, d, e, f, g, h\}$ төбелерінен және $E = \{\{a, b\}, \{a, c\}, \{a, d\}, \{b, d\}, \{c, d\}, \{c, e\}, \{e, f\}, \{e, g\}, \{f, g\}, \{f, h\}\}$ қабырғаларынан тұратын $G = (V, E)$ графын қарастырамыз.



№20 Емтихан билеті

1. Барлық квантильдерді жуықтау

Статистикалық үлестірудің барлық квантильдерін жуықтау-кездейсоқ шаманың таралуын берілген пайыздық бөліктерге бөлетін мәндерді бағалау процесі. Әдетте квантильдер медиана (50%-квантиль), квартильдер (25%-квантиль, 75%-квантиль) және т. б. сияқты пайыздармен көрсетіледі.
Барлық квантильдерді жуықтау үшін қол жетімді деректер мен тарату сипаттамаларына байланысты әртүрлі әдістерді қолдануға болады. Кейбір танымал әдістерге мыналар жатады:
Эмпирикалық квантильдерді қолдану: қарапайым әдіс-қолда бар деректер үлгісінен тікелей есептелетін эмпирикалық квантильдерді пайдалану.
Параметрлік әдістер: егер таралу формасы белгілі болса (мысалы, қалыпты таралу), таралу параметрлерін бағалау және олардың негізінде квантильдерді есептеу сияқты параметрлік әдістерді қолдануға болады.

Интерполяция: егер сізде тек пайыздық нүктелердің шектеулі саны үшін квантиль мәндері болса, интерполяция әдісін аралық нүктелердегі квантильдерді бағалау үшін қолдануға болады.

2. Орналасқан жеріне байланысты хэштеу қасиеттері

Орналасқан жерді ескере отырып хэштеу хэш функцияларын қолдану кезінде деректердің кеңістіктік орналасуы туралы ақпаратты пайдалануды білдіреді. Бұл географиялық мәліметтер базасы, геолокация, кескінді өңдеу және объектілердің орналасуы маңызды болатын басқа аймақтар сияқты әртүрлі контексттерде пайдалы болуы мүмкін. маңызды болуы мүмкін кейбір хэштеу қасиеттері берілген:

Жергілікті сезімталдық(Locality Sensitivity): орналасқан жерді ескере отырып хэштеу жергілікті сезімталдықты қамтамасыз етуі керек, яғни орналасу кеңістігіндегі жақын объектілердің хэш функциясының жақын мәндеріне көрсету ықтималдығы жоғары болуы керек.

Тәртіпті сақтау: осы контексте қолданылатын хэш функциялары объектілердің орналасу кеңістігіндегі ретін сақтауы керек. Яғни, егер А объектісі в объектісіне жақын болса, онда олардың хэш мәндері де жақын болуы керек.

Біркелкі үлестіру: хэш функциялары белгілі бір аймақтардағы мәндердің күшті шоғырлануын болдырмау үшін хэш кеңістігіндегі мәндердің біркелкі таралуын мақсат етуі керек.

3. Графтардың матрицалық көріністері

Графтардың матрицалық көріністері. Графтың матрицалық көрінісі оның құрылымының көптеген қасиеттерін түсіну үшін маңызды. Төменде біз осындай ең негізгі және маңызды екі көріністен бастаймыз, бірақ оларды келесі бөлімдерде қорытындылап, кеңейтеміз. Айта кету керек, іс жүзінде бұл графты сақтаудың көлемі жағынан өте тиімсіз тәсілі болуы мүмкін. Бұл матрицаларда $\|V\|^2$ ұяшық бар, бірақ көптеген жағдайларда нақты $|E|$ қабырғалар саны шыңдар санына әлдеқайда жақын (айталық $|E| \leq 20|V|$ немесе $|E| \leq 5|V| \log_2|V|$ немесе $|E| \leq |V|^{1.2}$ жиі негізсіз болмайды). Осы мәтінде келтіре алатын шағын мысалдарда бұл болжамдардың мағынасы жоқ. Бірақ өнеркәсіптегі көптеген графтар жиынтығында (мысалы, $|V| > 1\ 000\ 000$) бұл айырмашылық деректер жиынтығы ноутбукке оңай сиятындығына немесе компьютерлер кластерін қажет ететіндігіне байланысты болуы мүмкін.

Матрица түріндегі графтың ең табиғи көрінісі - *А көршілес матрицасы*. n шыңдары бар граф үшін бұл $n \times n$ матрицасы, ол әрбір $e_{i,j} = \{v_i, v_j\}$ қабырғасы үшін 1-ді $A_{i,j}$ -ге жазады. Керісінше жағдайда жазбалар 0-ге тең.

Дәреже матрицасы $n \times n$ квадрат және диагональды матрица болып табылады. Бұл оның $D_{i,i}$ диагональдары тек нөлдік емес элементтерден тұратынын білдіреді. Атап айтқанда $D_{i,i}$ - бұл v_i тұратын

қабырғалардың санын білдіретін, v_i шыңдарының дәрежесін жазады. Атап айтқанда, біз кейде $D^{-1/2}$ матрицасын қолданамыз.

Естеріңізге сала кетейік, квадрат матрицаны өзіне көбейтуге болады, сондықтан жалпы жағдайда p бүтін оң дәрежесі үшін D^p матрицалық операциясы D-ні өзіне p рет $D \cdot D \cdot \ldots \cdot D$ ретінде көбейтуді білдіреді. Алайда бөлшек дәрежелер үшін бұл интуитивті емес және әдетте әрдайым анықталмайды.

Барлық диагональ элементтері оң элементтерден тұратын, диагональ матрицалар үшін біз оларды әр $D_{i,i}$ -ді $D_{i,i}^p$ -ге ауыстыратын диагональды матрица ретінде анықтай аламыз. Нақтырақ айтсақ, бұл диагональды матрицаны кері айналдыру (инвертировать) оңай дегенді білдіреді, өйткені D^{-1} әр $D_{i,i}$ -ді $1 / D_{i,i}$ -ге ауыстырады. Анықтаманың матрицалық қуаттың жалпы анықтамасына сәйкес келетіндігін тексеруге болады; яғни $(D^p)^{1/p} = D$.

№21 Емтихан билеті

1.Маңыздылық үлгісі

1. Маңыздылық үлгісі

Жинақтылықтың көптеген маңызды шекаралары үлестірімнің орташа мәніне жуықтаумен байланысты. Барлық үлгілер белгісіз үлестірімнен біртекті болған кезде, жоғарыдағы бағалаулар (және оларды жалпылау) жинақтылықты түсінудің ең жақсы тәсілі болып табылады, тіпті кішігірім коэффициенттерге дейін. Атап айтқанда, бұл деректерге жалғыз қол жетімділік жаңа iid үлгісі болған кезде дұрыс.

Дегенмен, кейбір жағдайларға қарағанда үлгінің қалай қалыптасатынын көбірек бақылауды қамтамасыз етуге болатын кезде, қарапайым өзгерістер бағалаудың дәлдігін айтарлықтай жақсарта алады. Негізгі идея маңыздылығы бойынша іріктеу деп аталады және келесі принципке ие: *дисперсиясы жоғары деректер нүктелерін жиі таңдаңыз, бірақ бағалауда оларды іріктеу ықтималдығына кері пропорционалды түрде өлшеңіз*.

Салмақтың үлгілік орташа мәні. $A = \{a_1, a_2, \ldots, a_n\}$ дискретті және өте үлкен жиынын қарастырайық, мұнда әрбір a_i элементі сәйкес $w(a_i)$ салмағына ие болады. Біздің мақсатымыз күтілетін (немесе орташа)

$$\bar{w} = \mathbf{E}[w(a_i)] = \frac{1}{n} \sum_{a_i \in A} w(a_i).$$

салмағын бағалау болады

Бұл жиынтық соншалықты үлкен болуы мүмкін, сондықтан біз қосындыны нақты есептегіміз келмейді немесе салмақты қымбат сұрағымыз келмейді (мысалы, клиенттерге сауалнама жүргізу сияқты).

Сондықтан біз бұл есептеуді барлық элементтер бойынша орындаудан аулақ болғымыз келеді. Керісінше, біз $\{a'_1, a'_2, \ldots, a'_k\}$ iid -дің k элементтерін таңдаймыз (әрбір a'_j A-дан біркелкі және тәуелсіз таңдалады, сондықтан кейбіреулері бірнеше рет алынуы мүмкін), әрқайсысының $w(a'_j)$ салмағын сұраймыз және орташа салмақты

$$\hat{w} = \frac{1}{k}\sum_{j=1}^{k} w(a'_j).$$

ретінде бағалаймыз.

$\hat{w}$ қаншалықты $\bar{w}$ -ны дәл жақындатады? Егер барлық салмақтар шамамен біркелкі болса немесе [0, 1] - де жақсы бөлінсе, онда біз Чернофф-Хоффдинг бағасын осылай қолдана аламыз

$$\mathbf{Pr}[|\bar{w} - \hat{w}| \geq \varepsilon] \leq 2\exp(-2\varepsilon^2 k).$$

Осылайша, кем дегенде $1 - \delta$ ықтималдығымен біз $k = \frac{1}{2\varepsilon^2}\ln\frac{2}{\delta}$ үлгілерін пайдалану кезінде ε-ден аспайтын қателе ие боламыз.

Алайда, егер бізде бағалауға қатысты салмаққа байланыс болмаса, онда бұл нашар жуықтауды қамтамасыз етеді. Мысалы, егер $\bar{w} = 0{,}0001$, себебі салмақтың көпшілігі өте аз, онда ($\varepsilon = 0{,}01$)- жуықтау өте пайдалы болмауы мүмкін. Немесе сол сияқты, егер салмақтың көпшілігі 1-ге жақын болса, және демек $\bar{w} = 2$, бірақ $\Delta = 1000$ мәні бар бірнеше салмақтардың шашырауы болса, онда Чернофф-Хоффдинг шекарасы тек келесіні бекітеді

$$\mathbf{Pr}[|\bar{w} - \hat{w}| \geq \varepsilon] \leq 2\exp\left(\frac{-2\varepsilon^2 k}{\Delta^2}\right) = \delta.$$

Демек, бұл оның орнына бізге $k = \frac{\Delta^2}{2\varepsilon^2}\ln(2/\delta)$ қажет екенін білдіреді, бұл бұрынғыларға қарағанда Δ^2=1 000 000 есе көп үлгілер!

2.LSH үшін прототиптік тапсырмалар

1. Орналасқан жерді ескере отырып хэштеу

Бір өлшемді евклидтік деректерде бұл мәселелерді шешу салыстырмалы түрде оңай. Барлық нысандарды сұрыптап, оларды сұрыпталған ретпен сақтаудан бастаңыз. Онда көрші объектілер сұрыпталған тәртіпте көрші болады. Егер мұндай реттеу теңдестірілген екілік ағаштың пайда болуына әкелсе, онда сұраныс орындалған кезде жақын жатқан объектілерді логарифмдік орындалу уақыты ішінде табуға болады (яғни, log n-ге пропорционалды уақыт).

Әрі қарай, біз көп өлшемді векторлық объектілер үшін және жиынға негізделген, көріністердегі метрикалар үшін осы сұрақтарға жауап беру үшін "локальдылыққа сезімтал хэштеуді" енгіземіз. Негізгі идея- $\mathcal{B}$ объектілер тобы және $\mathbf{s} : \mathcal{B} \times \mathcal{B} \to [0, 1]$ ұқсастығы үшін кездейсоқ $\mathcal{H}$ хэш- функциялар тобын шамамен келесі қасиетпен анықтау.

Локальдылыққа сезімтал хэштер тобы: s ұқсастық функциясы үшін $\mathcal{H}$ локальдылыққа сезімтал, хэштер тобы хэш-функциялар жиынтығын білдіреді, сондықтан кез-келген екі $p, q \in \mathcal{B}$ нысандары үшін

$$\mathbf{Pr}_{h\in\mathcal{H}}[h(p) = h(q)] \approx \mathbf{s}(p, q).$$

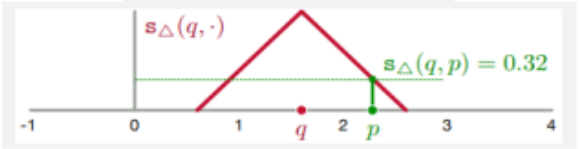
Яғни, кез келген $p, q \in \mathcal{B}$ үшін кездейсоқ таңдалған $h \in \mathcal{H}$ хэш функциясы осы екі объектінің ұқсастығына тең, ықтималдықпен соқтығысуына әкеледі.

Топ анықталғаннан кейін, осы топтан белгілі бір хэш-функцияны кездейсоқ таңдау пайдалы болады (мысалы, $h \in \mathcal{H}$ бұл таңдау ықтималдық үшін кездейсоқ шама болып табылады). Алайда, кейбір h функциясы таңдалғаннан кейін, бұл детерминирленген функция.

Мысал: Үшбұрыштар ұқсастығы үшін қарапайым LSH торы

Бір өлшемді $X \subset \mathbb{R}^1$ деректер жиынын және үшбұрыштың ұқсастығын қарастырайық

$$\mathbf{s}_\triangle(p, q) = \max\{0, 1 - |p - q|\}.$$



Бұл үшін қарапайым хэштер тобы-бұл кездейсоқ жылжытылған торлар жиынтығы, онда бір тор ұяшығындағы элементтер бірге хэштеледі. $\mathcal{H}_\triangle = \{h_\eta \mid \eta \in [0, 1)\}$ анықтаңыз, мұндағы $h_\eta(x) = \lceil x + \eta \rceil$.

Яғни, әрбір h_η кіріс деректерін бүтін санға түрлендіреді (хэш-блок индексін білдіреді), мұнда тор ұзындығы 1 сандардың тізбекті жиындарын (интервалдарын) анықтайды, олардың барлығы бірдей хэш-блокқа сәйкес келеді. η параметрі осы тор шекараларын кездейсоқ жылжытады. Осылайша, нүктелер жұбы бір тор ұяшығында бола ма, жоқ па, η кездейсоқ таңдаудан тәуелді болады және ұқсас нүктелер бір тор ұяшығында, демек, бір хэш -сегментінде болу ықтималдығы жоғары.

3.Марков тізбектері

1. Марков тізбектері

(V, P, q) Марков тізбектері V түйіндер жиынтығымен, *P* ықтималдық ауысу матрицасымен және *q* бастапқы күйімен анықталады. Біз *P*-ны қабырғалар жиынының матрицалық көрінісінен қалай индукциялауға болатынын көреміз, осылайша бұл құрылым графтарды түсінумен тығыз байланысты; енді біз оны жалпы контексте сипаттайтын боламыз.

Ауысу, көптеген пайдалы және жиі қажет контексттерде *q* талап етілмейді және осы талқылаудың бастапқы бөлігі *q*-дан тәуелділікті қалай жою керектігін көрсетуге бағытталған.

(*V, P, q*) Марков тізбегінің мағынасы - *V* шыңдары жиынтығы "айналасындағы қозғалысты" немесе "арқылы ағынды" түсіну.

q бастапқы күйі ықтималдықтардың шыңдар бойынша таралуын білдіреді. Мысалы, егер бұл процестің ментальды моделі графтың шыңдарын кездейсоқ кезіп жүруді білдірсе, онда *q* бастапқы күйі (яғни, атап айтқанда, 1 ықтималдығы бар $b \in V$ шыңында, біздің қазіргі мысалда):

$$q^T = [0\ 1\ 0\ 0\ 0\ 0\ 0\ 0].$$

Неғұрлым жалпы модель - бұл күйді анықтайтын бір шың емес, мүмкін шыңдар бойынша таралудың болуы. Онда, егер *a* күйінде болу ықтималдығы 10%, енгізілу ықтималдығы 30% және *f* күйінде болу ықтималдығы 60% болса, бұл

$$q^T = [0.1\ 0\ 0\ 0.3\ 0\ 0.6\ 0\ 0].$$

Жалпы алғанда, бізге $q \in \Delta^{|V|}$ бол қамтамасыз ету керек, яғни ол ықтималдықтың таралуын білдіреді, сондықтан

- әрбір $q[i] \geq 0$
- $\sum_i q[i] = 1$

Енді *P ықтималдық ауысу матрицасы* матрицаның бағандары бойынша қалыпқа келтірілген. Яғни, әрбір баған ықтималдықтың таралуын қанағаттандыруы керек; әрбір баған $P_j \in \Delta^{|V|}$, осылайша кіріс деректері теріс емес және 1 дейін қосындыланады. Әрбір *i*-ші баған, v_i шыңнан басталған жағдайда, келесі шыңның орналасу ықтималдығын білдіреді. Яғни, $P_{i,i'}$ жазбасы v_i шыңынан ықтималдықтың $P_{i,i'}$, келесі шыңның $v_{i'}$ екенін сипаттайды. *A* іргелес матрицасын қолдана отырып, біз барлық бағандарды $P_j = A_j / \| A_j \|_1$ етіп қалыпқа келтіру арқылы *P* шығара аламыз.

Мысал: Ықтималдық ауысу матрицасы

Жұмыс мысалының A іргелес матрицасы P ықтималдық ауысу матрицасын келесідей шығара алады

$$P = \begin{pmatrix} 0 & 1/2 & 1/3 & 1/3 & 0 & 0 & 0 & 0 \\ 1/3 & 0 & 0 & 1/3 & 0 & 0 & 0 & 0 \\ 1/3 & 0 & 0 & 1/3 & 1/3 & 0 & 0 & 0 \\ 1/3 & 1/2 & 1/3 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1/3 & 0 & 0 & 1/3 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/3 & 0 & 1/2 & 1 \\ 0 & 0 & 0 & 0 & 1/3 & 1/3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1/3 & 0 & 0 \end{pmatrix}.$$

Біз мұны граф түрінде де ұсына аламыз, мұнда бағытталған қабырғалар бір түйіннен екіншісіне өту ықтималдығын көрсетеді. Қабырғаның болмауы ауысудың нөлдік ықтималдығын білдіреді. Көріністің бұл түрі қазірдің өзінде өте ретсіз, сондықтан әлдеқайда үлкен графтарға дейін масштабталмайды.



Назар аударыңыз, бастапқы граф бағытталмаған болса да, бұл жаңа граф бағытталған. Мысалы, a-дан b -ге дейінгі (a, b) қабырға 1/3 ықтималдыққа ие, ал сол уақытта b -дан a-ға дейінгі (b, a) қабырға 1/2 ықтималдыққа ие болады. Немесе одан да драмалық түрде f-тен h-қа дейінгі (f, h) қабырға 1/3 ықтималдыққа ие, сол кезде h -тан f -ке дейінгі (h, f) қабырға 1 ықтималдыққа ие; яғни h шыңы әрқашан f-ке өтеді.

Енді берілген $q^T = [0\ 1\ 0\ 0\ 0\ 0\ 0\ 0]$ күйі келесі күйге "өтуі" мүмкін (біздің P мысалын қолдана отырып)

$$q_1 = Pq = \begin{bmatrix} \frac{1}{2} & 0 & 0 & \frac{1}{2} & 0 & 0 & 0 & 0 \end{bmatrix}^T.$$

Онда біз

$$q_2 = Pq_1 = PPq = P^2q = \begin{bmatrix} \frac{1}{6} & \frac{2}{6} & \frac{2}{6} & \frac{1}{6} & 0 & 0 & 0 & 0 \end{bmatrix}^T.$$

және

$$q_3 = Pq_2 = \begin{bmatrix} \frac{1}{3} & \frac{1}{9} & \frac{1}{9} & \frac{1}{3} & \frac{1}{9} & 0 & 0 & 0 \end{bmatrix}^T.$$

сияқты келесі күйге өте аламыз

Жалпы, біз $q_n = P^n q$ жаза аламыз, яғни q-дан бастап, q -дың сол жағында P-ге n рет "басу", ауысу матрицасы.

Бұл Андрей Марковтың құрметіне *"Марков" тізбегі* деп аталады, өйткені бұл Марков процесі. Бұл атау берілген процесс тек оның ағымдағы күйінен ғана тәуелді екенін және оның алдындағы ештеңеден тәуелді емес екенін білдіреді (егер ол ағымдағы күйінде жасырын кодталмаса)..

Бұл Марков тізбегі процесі туралы түсінудің екі жолы бар.

- Ол бір шыңнан басталатын нүктенің *кездейсоқ кезуін* сипаттайды, бұл q-дағы жалғыз 1 координатасына сәйкес келеді. Содан кейін әр қадамда ол сәйкес P бағанына сүйене отырып, қайда бару керектігін кездейсоқ шешеді, сонымен қатар P-ның j-ші бағаны j-ші шыңның өту ықтималдығын кодтайды. Ол дәл бір жаңа күйге өтеді. Содан кейін қайталанады.

№22 Емтихан билеті

1. Жақсартылған шоғырлану

Жақсартылған шоғырлану. Шоғырлануды жақсарту үшін әрбір $\frac{\Psi}{n\psi_j} \cdot w(a'_j)$ бағасының диапазонын талдау маңызды қадам болып табылады. Бізде бұл $w(a'_j) \in [0, \psi_j]$, болғандықтан, нәтижесінде келесіні аламыз

$$\frac{\Psi}{n\psi_j} \cdot w(a'_j) \in \frac{\Psi}{n\psi_j} \cdot [0, \psi_j] = [0, \frac{\Psi}{n}].$$

Енді Чернофф-Хоффдинг шектеулерін қолдана отырып, біз w_I -дің $\bar{w}$ -на қатысты ε-нен үлкен қатесі болуы ықтималдығының жоғарғы шегін белгілей аламыз.

$$\mathbf{Pr}[|\bar{w} - \hat{w}| \geq \varepsilon] \leq 2\exp\left(\frac{-2\varepsilon^2 k}{(\Psi/n)^2}\right) = \delta$$

ε мүмкін болатын қателікті және δ сәтсіздігінің ықтималдығын ескере отырып, біз қажетті іріктеу санын келесідей есептей аламыз

$$k = \frac{(\Psi/n)^2}{2\varepsilon^2} \ln(2/\delta).$$

Енді, біркелкі іріктеудегідей, Δ мүмкін болатын *максималды* мәннен квадраттық тәуелділіктің орнына, ол енді барлық Ψ / n мәндері үшін *орташа* жоғарғы шекарадан квадраттық түрде тәуелді болады. Басқаша айтқанда, маңыздылығы бойынша іріктеу арқылы біз $\max_i$ ψ_i максималды маңыздылығынан тәуелділіктен *Ψ/n орташа маңыздылығынан* тәуелділікке дейін іріктеудің күрделілігін төмендетеміз.

2. LSH күшейту үшін топтастыру

отырып (нені басқасын қолданбаса.), біз оның пақты мәнінде тым байыпты қарамауымыз керек.

1.3 LSH күшейту үшін топтастыру

Егер біз тек бір $h \in \mathcal{H}$ хэш функциясын қолдансақ, мұндағы $h : \mathcal{B} \to U$, онда біз әмбебап (универсум) хэш кестесін жасай аламыз $U = \{0, 1, 2, \ldots, u - 1\}$. Яғни, егер элемент $h(p) = j$ болса, онда біз оны ұзындығы u массивтегі j орнында сақталған, байланыстырылған L_j тізімінде сақтаймыз. содан кейін біз q сұрау элементін ескере отырып, $h(q) = j$, j -ге дейін хэштелген барлық элементтерге қол жеткізе аламыз, осы талапты қанағаттандыратын элементтер санына пропорционалды уақытта.

Бірақ ұқсас екі элементтің массивте бір жерге хэштелу ықтималдығын арттыру үшін, ал ұқсас емес элементтер -жоқ, бізде екі нұсқа бар: аюдың "ана" тәсілі және аюдың "әке" тәсілі. Аюдың әкесі тым қатал болады, ал аюдың анасы тым жомарт болады, бірақ оларды топтастыру деп аталатын тәсілмен бірге қолдануға болады-бұл "кішкентай" аюдың тәсілі және ол дұрыс.

Әке аюы қатал және егер тек $h_1, h_2, \ldots, h_b$ бірнеше хэш функциялары $h_i(p) = h_i(q)$ екендігін хабарламаса, p-р элементтері q-ге жақын емес дейді. Мұны $H(p) : \mathcal{B} \to U^b$ таспа хэшін құру арқылы хэш кестесімен тиімді басқаруға болады, яғни ол әрбір p объектісін b-өлшемді вектормен, U-дағы әрбір элементті салыстырады, мұндағы i-ші координат i-ші хэш функциясымен анықталады. Біз осы u^b мүмкін жазбалардың үстіне хэш кестесін қайтадан жасай аламыз (b кеңістігін пайдаланбау үшін деректер құрылымындағы стандартты әдістерді қолдана отырып). Әке аю тәсілінің проблемасы-бұл өте таңдаулы және кез-келген екі элементтің хэшпен байланыстырылған кестеде бір сегментте хэштелу ықтималдығын азайтады.

Аю анасы жомарт, сонымен қатар $h_1, h_2, \ldots, h_r$ бірнеше хэш функцияларын ескереді және екі ұқсас элемент туралы хабарлайды, егер олар қандай да бір хэш функциясында кездессе. P ішіндегіні сақтайтын r жеке хэш кестелерін сақтасақ, онда q-мен кездесетін элементтердің бірігуі туралы хабарлауға болады. Дегенмен, қазір ана аю тәсілінің проблемасы оның жеткілікті таңдамалы емес екендігінде, бұл кез келген екі элементтің бір себетке түсу ықтималдығын арттырады.

Топтастыру (аюдың баласының көзқарасы) оларды біріктіреді (ақыр соңында, аюдың баласы ата-анасының екеуіне де ұқсас). Біз байланысты H хэш- функцияларын жасаймыз, олардың әрқайсысы b хэш функцияларынан тұрады. Бұл жалпы $r \cdot b$ хэш функцияларын және олардың барлығымен хэштелуі керек сұранысты қажет етеді. Содан кейін, егер q кез-келген шектеулі хэш кестесіндегі кез-келген p-мен қиылысатын болса (барлық хэш функциялары кездесуі керек), біз оны ұқсас ретінде қайтарамыз.

3. Марковтың эргодикалық тізбектері

(V, P, q) Марков тізбектері V түйіндер жиынтығымен, *P* ықтималдық ауысу матрицасымен және *q* бастапқы күйімен анықталады. Біз *P*-ны қабырғалар жиынының матрицалық көрінісінен қалай индукциялауға болатынын көреміз, осылайша бұл құрылым графтарды түсінумен тығыз байланысты; енді біз оны жалпы контексте сипаттайтын боламыз.

Ауысу, көптеген пайдалы және жиі қажет контексттерде *q* талап етілмейді және осы талқылаудың бастапқы бөлігі *q*-дан тәуелділікті қалай жою керектігін көрсетуге бағытталған.

(*V, P, q*) Марков тізбегінің мағынасы - *V* шыңдары жиынтығы "айналасындағы қозғалысты" немесе "арқылы ағынды" түсіну.

q бастапқы күйі ықтималдықтардың шыңдар бойынша таралуын білдіреді. Мысалы, егер бұл процестің ментальды моделі графтың шыңдарын кездейсоқ кезіп жүруді білдірсе, онда *q* бастапқы күйі (яғни, атап айтқанда, 1 ықтималдығы бар $b \in V$ шыңында, біздің қазіргі мысалда):

$$q^T = [0\ 1\ 0\ 0\ 0\ 0\ 0\ 0].$$

Неғұрлым жалпы модель - бұл күйді анықтайтын бір шың емес, мүмкін шыңдар бойынша таралудың болуы. Онда, егер *a* күйінде болу ықтималдығы 10%, енгізілу ықтималдығы 30% және *f* күйінде болу ықтималдығы 60% болса, бұл

$$q^T = [0.1\ 0\ 0\ 0.3\ 0\ 0.6\ 0\ 0].$$

Жалпы алғанда, бізге $q \in \Delta^{|V|}$ бол қамтамасыз ету керек, яғни ол ықтималдықтың таралуын білдіреді, сондықтан

- әрбір $q[i] \geq 0$
- $\sum_i q[i] = 1$

Жалпы, біз $q_n = P^n q$ жаза аламыз, яғни *q*-дан бастап, *q* -дың сол жағында *P*-ге *n* рет "басу", ауысу матрицасы.

Бұл Андрей Марковтың құрметіне *"Марков" тізбегі* деп аталады, өйткені бұл Марков процесі. Бұл атау берілген процесс тек оның ағымдағы күйінен ғана тәуелді екенін және оның алдындағы ештеңеден тәуелді емес екенін білдіреді (егер ол ағымдағы күйінде жасырын кодталмаса)..

Бұл Марков тізбегі процесі туралы түсінудің екі жолы бар.

- Ол бір шыңнан басталатын нүктенің *кездейсоқ кезуін* сипаттайды, бұл q-дағы жалғыз 1 координатасына сәйкес келеді. Содан кейін әр қадамда ол сәйкес P бағанына сүйене отырып, қайда бару керектігін кездейсоқ шешеді, сонымен қатар P-ның j-ші бағаны j-ші шыңның өту ықтималдығын кодтайды. Ол дәл бір жаңа күйге өтеді. Содан кейін қайталанады.

- Ол *кездейсоқ кезу ықтималдығының таралуын* сипаттайды. Әрбір күйде біз оның қай жерде болуы мүмкін екенін ғана бақылаймыз: бұл *n* қадамнан кейін q_n. Балама ретінде біз P^n -ді қарастыра аламыз, онда кез-келген q_0 бастапқы күйі үшін $P^n q_0$ *n* қадамнан кейін q_0 -дің қай жерде болуы мүмкін екендігінің таралуын сипаттайды. Осылайша, $P^n_{j,i}$ (*j*-ші баған, *i*-ші жол) жазбасы *j*-ден басталатын нүктенің *n* қадамнан кейін *i* күйінде болу ықтималдығын сипаттайды.

№23 Емтихан билеті

1. Маңыздылық үлгісін жүзеге асыру

басқа қызметкерді таңдағанда, олардың жалақысының әсерін шамамен 4% - ға арттырамыз.

Іске асыру. Көптеген бағдарламалау тілдері үшін $u \sim \text{unif}(0, 1]$ біркелкі үлестірімі бар кездейсоқ сандарды құру үшін кірістірілген функциялардың болуы стандартты болып табылады. Бұл үлкен дискретті жиынтықтан элементті таңдау үшін оңай түрлендірілуі мүмкін. Егер жиынтықта k элементтер болса, онда $i = \lfloor uk \rfloor$ (k - ге көбейту және жоғарғы

шекті алу[3]) – бұл 1-ден k-ге дейінгі бүтін санның біркелкі таңдауы болып табылады және жиынтықтан i-ші элементті таңдауды білдіреді.

Бұл идеяны оның салмағына пропорционалды элементті таңдау үшін оңай жалпылауға болады. $W = \sum_{i=1}^{n} w(a_i)$. біздің мақсатымыз $w(a_i)/W$ ықтималдығымен a_i элементін таңдау болсын. Біз сондай-ақ $t_j = \sum_{i=1}^{j} w(a_i)/W$ ықтималдығын, яғни j немесе одан кіші индексі бар объектіні таңдау ықтималдығын анықтай аламыз. Әрбір a_j үшін t_j есептеп, $t_0 = 0$ орнатқаннан кейін, $u \sim \text{unif}(0, 1)$ біркелкі кездейсоқ мәні - бұл оның салмағына пропорционалды объектіні таңдау үшін қажеттінің бәрі. Біз жай ғана a_j элементін $t_{j-1} \leq u \leq t_j$ (дұрыс j индексін log n-ге пропорционалды уақыт ішінде табуға болады, егер бұл t_j теңдестірілген екілік ағашта сақталса) болатындай етіп қайтарамыз.

2. Бұрыштық қашықтық үшін LSH

1.4 Бұрыштық қашықтық үшін LSH

Жергіліктілікке сезімтал хэш - топтар бір өлшемді үшбұрыштың ықщамдалған ұқсастығы үшін ғана жасалмауы мүмкін. Мұнда біз $\mathbf{d}_{\text{ang}}$ бұрыштық қашықтығы мен $\mathbf{s}_{\text{ang}}$ ұқсастығы үшін осындай топты сипаттаймыз. Еске салайық, бұл функциялар $\mathbb{R}^d$ -гі бірлік вектор болып табылатын, a, b $\in \mathbb{S}^{d-1}$ векторларымен жұмыс істейді.

$\mathcal{H}_{\text{ang}}$ хэштер тобынан h_u хэші анықталды

$$\mathcal{H}_{\text{ang}} = \left\{ h_u(\cdot) = \text{sign}(\langle \cdot, u \rangle) \mid u \sim \text{Unif}(\mathbb{S}^{d-1}) \right\}$$

Мұны ашайық. Алдымен, $u \in \mathbb{S}^{d-1}$ біртекті кездейсоқ бірлік векторын таңдаңыз, яғни $\mathbb{R}$d-гі ($u \sim \text{Unif}(\mathbb{S}^{d-1})$) кез келген бірлік векторы бірдей ықтималдықпен таңдалады. Онда $h_u(p) = \text{sign}(\langle a, u \rangle)$, яғни a және u нүктелік көбейтіндісі оң болса, ол +1 қайтарады, ал теріс болса -1 қайтарады.

Біз кез–келген $a, b \in \mathbb{S}^{d-1}$ үшін $\mathbf{Pr}_{h_u \in \mathcal{H}_{\text{ang}}}[h_u(a) = h_u(b)] = \mathbf{s}_{\text{ang}}(a, b)/\pi$кезінде көрсетеміз. Осылайша, π -да масштабталғаннан кейін, осы ұқсастық жұбы мен хэштер тобы үшін күшейтуді талдау үшбұрыштың қарапайым ұқсастығымен мысалдағыдай.

3. Математикалық күтілім

4. **Математикалық күтілім**

Кездейсоқ шаманың күтілетін мәні X: $\Lambda \to \Omega$-бұл өте маңызды ұғым, мәні бойынша Ω өлшенген мәні, х ықтималдығымен өлшенеді. X дискретті кездейсоқ шамасы үшін ол, бейнеленетін таңдамалы кеңістіктегі ω барлық нәтижелерінің қосындысы немесе олардың $\omega \in \Omega$ мәнін олардың ықтималдығына көбейту ретінде анықталады

$$\mathbf{E}[X] = \sum_{\omega \in \Omega} (\omega \cdot \mathbf{Pr}[X = \omega]).$$

X үздіксіз кездейсоқ шамасы үшін

$$\mathbf{E}[X] = \int_{\omega \in \Omega} \omega \cdot f_X(\omega) \mathrm{d}\omega.$$

Математикалық күтілімнің сызықтығы: математикалық күтілімнің негізгі қасиеті-бұл сызықтық операция. Бұл дегеніміз, X және Y екі кездейсоқ шамалары үшін бізде $\mathbf{E}[X + Y] = \mathbf{E}[X] + \mathbf{E}[Y]$ бар. α скалярлық мәні үшін бізде $\mathbf{E}[\alpha X] = \alpha \mathbf{E}[X]$ бар.

Мысал: Математикалық күтілім

Әділ текшеде $\Omega = \{ \omega_1 = 1, \omega_2 = 2, \omega_3 = 3, \omega_4 = 4, \omega_5 = 5, \omega_6 = 6 \}$ үлгі кеңістігі бар және әр нәтиженің ықтималдығы $\mathbf{Pr}[D = w_i] = 1/6$ болады. Мұндай сүйекті лақтыру нәтижесінің D кездейсоқ шамасының күтілетін мәні

$$\mathbf{E}[D] = \sum_{\omega_i \in \Omega} \omega_i \cdot \mathbf{Pr}[D = \omega_i] = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = \frac{21}{6} = 3.5$$

Мысал: Математикалық күтілімнің сызықтығы

H-аяқ киімсіз метрдегі адам бойының кездейсоқ шамасы болсын. H үшін f_H pdf - қалыпты үлестіру, күтілетін мәні μ = 1,755 м және стандартты ауытқуы 0,1 м болсын. S-сантиметрдегі аяқ киімді (1 метр 100 сантиметрге тең) киген кезде қосылатын, кездейсоқ бой шамасы болсын, оның *pdf* келесі кестеде келтірілген:

$S=1$	$S=2$	$S=3$	$S=4$
0.1	0.1	0.5	0.3

Онда сантиметрмен аяқ киім киген адамның күтілетін бойы

$\mathbf{E}[100 \cdot H + S] = 100 \cdot \mathbf{E}[H] + \mathbf{E}[S] = 100 \cdot 1.755 + (0.1 \cdot 1 + 0.1 \cdot 2 + 0.5 \cdot 3 + 0.3 \cdot 4) = 175.5 + 3 = 178.5$

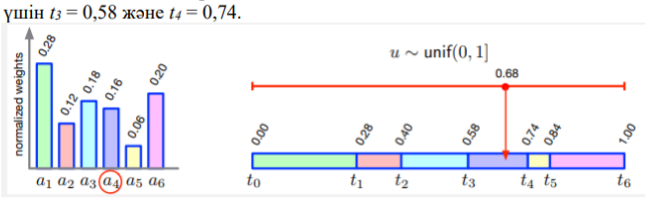
Математикалық күтудің сызықтығы $100 \cdot H + S$ өрнегін оның компоненттеріне қалай ыдыратуға және әрқайсысының математикалық күтуін жеке қабылдауға мүмкіндік бергеніне назар аударыңыз. Бұл трюк көптеген факторлары бар күрделі сценарийлерді талдауда өте тиімді.

№24 Емтихан билеті

1. Бірлікті бөлу геометриясы

Бірлікті бөлу геометриясы

Бұл суретте $w(a_i)/W$ қалыпты салмақтары бар 6 элемент сол жақтағы бағаналы диаграммада көрсетілген. Содан кейін бұл жолақтар оң жақтағы бірлік аралықпен тығыз орналастырылады; жолақтар 0,00-ден 1,00-ге дейін созылады. t_i мәндері i бірінші мәндерінің бірі таңдалу ықтималдығының жинақталуын белгілейді. Енді $u \sim \mathrm{unif}(0, 1]$ кездейсоқ шамасы кездейсоқ таңдалған кезде, ол осы "бірліктің бөлінуіне" сәйкес келеді және элементті таңдайды. Бұл жағдайда ол a_4 элементін таңдайды, өйткені u = 0,68, ал $t_3 < u \leq t_4$ үшін $t_3 = 0{,}58$ және $t_4 = 0{,}74$.



2. Евклидтік қашықтық үшін LSH

1.5 Евклидтік қашықтық үшін LSH

Евклидтік $\mathbf{d}_2$ қашықтыққа арналған LSH хэштер тобы бұрыштық қашықтық пен үшбұрышқа ұқсастық идеяларының үйлесімі болып табылады. Алайда, ықтималдық онша жақсы жұмыс істемейді, сондықтан бізге (γ, φ, α, β)-сезімталдық туралы жалпы түсінік қажет.

$\mathcal{H}_{L_2,\tau}$ хэштер тобы қажетті τ ұқсастық параметрін қажет етеді, ол үшбұрыштың ұқсастығын масштабтау кезінде жасырын болды, бірақ бұрыштық ұқсастықта жоқ. Жиынтық анықталды

$$\mathcal{H}_{L_2,\tau} = \left\{ h_{u,\eta}(\cdot) = \lceil \langle \cdot, u \rangle + \eta \rceil \mid u \sim \mathsf{Unif}(\mathbb{S}^{d-1}), \eta \sim \mathsf{Unif}[0, \tau] \right\}.$$

Яғни, ол кездейсоқ u бірлік векторына және кездейсоқ η ығысуына сүйенеді. $h_{u,\eta}(x) = \lceil \langle x, u \rangle + \eta \rceil$ хэштеу операциясы алдымен u бағытына проекцияланады, содан кейін сол бағытта η ығысады және бүтін санға дейін дөңгелектенеді. Жеткілікті үлкен t бүтін саны үшін (мысалы, егер n-нен көп емес деректер нүктелері болса, онда $t = n^3$ қолдана отырып), содан кейін $h_{u,\eta}(x) \mod t$ орнына, ол 0, 1, 2, . . . , $t - 1$ шекті аймағына бейнеленетіндей қолдану кең таралған.

$\mathcal{H}_{L_2,\tau}$ хэштер тобы ($\tau/2$, 2τ, 1/2, 1/3) - $\mathbf{d}_2$-ге қатысты сезімтал болып табылады.

3. Дисперсия

5. Дисперсия

X кездейсоқ шамасының *дисперсиясы* (ауытқуы) оның **E**[X] орташа мәніне қатысты қаншалықты таралуын сипаттайды. Бұл келесідей анықталады

$$\mathbf{Var}[X] = \mathbf{E}[(X - \mathbf{E}[X])^2] = \mathbf{E}[X^2] - \mathbf{E}[X]^2.$$

Жоғарыда келтірілген екі жалпы форманың эквиваленттілігі **E** [X] бекітілген скаляр болып табылатындығын пайдаланады:

$\mathbf{E}[(X - \mathbf{E}[X])^2] = \mathbf{E}[X^2 - 2X\mathbf{E}[X] + \mathbf{E}[X]^2] = \mathbf{E}[X^2] - 2\mathbf{E}[X]\mathbf{E}[X] + \mathbf{E}[X]^2 = \mathbf{E}[X^2] - \mathbf{E}[X]^2.$

$\alpha \in \mathbb{R}$ кез-келген скаляр үшін, онда $\mathbf{Var}[\alpha X] = \alpha^2 \mathbf{Var}[X]$.

Дисперсияда кездейсоқ шама немесе математикалық күту сияқты өлшем бірліктері жоқ екенін ескеріңіз, бұл квадраттағы өлшем бірлігі. Сонымен, біз $\sigma_X = \sqrt{\mathbf{Var}[X]}$. *стандартты ауытқуды* жиі талқылаймыз. **Var** [*X*] немесе σ_X төмен мәндерінің көпшілігі орташа мәнге жақын екенін көрсетеді, ал үлкен мән деректердің орташадан алысырақ болуы ықтимал екенін көрсетеді.

Мысал: Дисперсия

Аяқ киіммен қосылған биіктік үшін кездейсоқ *S* шамасын тағы бір рет қарастырайық:

$S=1$	$S=2$	$S=3$	$S=4$
0.1	0.1	0.5	0.3

Оның күтілетін мәні $\mathbf{E}[S] = 3$ (бекітілген скаляр) және оның ауытқуы

$$\mathbf{Var}[S] = 0.1 \cdot (1-3)^2 + 0.1 \cdot (2-3)^2 + 0.5 \cdot (3-3)^2 + 0.3 \cdot (4-3)^2$$
$$= 0.1 \cdot (-2)^2 + 0.1 \cdot (-1)^2 + 0 + 0.3(1)^2 = 0.4 + 0.1 + 0.3 = 0.8.$$

Онда стандартты ауытқу $\sigma_S = \sqrt{0,8} \approx 0,894$ тең.

X және *Y* екі кездейсоқ шамасының *ковариациясы* $\mathbf{Cov}[X, Y] = \mathbf{E}[(X - \mathbf{E}[X])(Y - \mathbf{E}[Y])]$.

№25 Емтихан билеті

1. Басымдықты іріктеумен алмастырусыз іріктеу

іріктемелерді алгоритмдік генерациялау кезінде белгілі үлестірімнен қайта орналастырусыз k элементтерін таңдау тиімді болуы мүмкін. Бұл талдауды біршама қиындатуы мүмкін болса да, Чернофф-Хоффдингтің бағалау нұсқалары тәуелсіз кездейсоқ айнымалылардың орнына ауыстырусыз кездейсоқ іріктемелерге арналған. Сонымен қатар, іс жүзінде шоғырлану және жуықтау сапасы көбінесе ауыстырусыз іріктемелерді қолданғанда жақсарады және бұл әсіресе салмақты іріктемелерді таңдауда дұрыс. Салмаққа пропорционалды деректерді іріктеу кезінде, егер жеткілікті үлкен салмақтары бар элементтер болса, онда бұл элементтерді әрқашан үлкен салмақпен таңдаған дұрыс. Төмен салмақтылар олардың салмағына пропорционалды болатын, белгілі бір ықтималдықпен таңдалуы керек, содан кейін маңыздылығы бойынша іріктеудегідей қайта өлшенуі керек. Басымдықты іріктеу деп аталатын әдіс осы қасиеттерді икемділікпен біріктіреді.

2. Jaccard қашықтығы үшін LSH түріндегі минималды мән

1.6 Jaccard қашықтығы үшін LSH түріндегі минималды мән

Біз келтіретін соңғы LSH мысалы жиындарда анықталған Жаккард қашықтығына қатысты. Бұл $\mathcal{H}_J$ хэштер тобы қайтадан жағымды қасиетке ие, ол $\mathbf{Pr}_{h_\sigma \in \mathcal{H}_J}[h_\sigma(A) = h_\sigma(B)] = \mathbf{s}_J(A, B)$, сондықтан алдыңғы күшейту талдауы тікелей қолданылады.

n өлшемді Ω аймағында анықталған жиындарды қарастырыңыз және Π_n -ді Ω ішіндегі барлық әр түрлі $[n] = \{1, 2, 3, \ldots, n\}$ бүтін сандарға ауыстырулардың жиыны ретінде анықтаймыз. Осылайша, $\omega \in \Omega$ және $\sigma \in \Pi_n$ әр элементі үшін кейбір $i \in [n]$ үшін $\sigma(\omega) = i$, ал тұрақты үшін $\omega \neq \omega'$ үшін $\sigma(\omega) \neq \sigma(\omega')$ бейнелейді. Іс жүзінде біз бұл $\neq$ шектеуді жеңілдете аламыз, оны төменде талқылаймыз. Содан кейін келесіні анықтаймыз

$$\mathcal{H}_J = \left\{ h_\sigma(A) = \min_{\omega \in A} \sigma(\omega) \mid \sigma \sim \mathsf{Unif}(\Pi_n) \right\}.$$

Яғни, hσ хэш функциясы A -ғы әрбір ω-ге σ қолданады, содан кейін олардың барлығының ең кіші мәнін қайтарады.Ең төменгі мәнді қайтаруға байланысты тәсілдің бұл түрі көбінесе *минималды* хэш деп аталады.

3. Бірлескен, шекті және шартты үлестіру

6. Бірлескен, шекті және шартты үлестірулер Енді ¶
біз осы тұжырымдамалардың кейбірін біреуден көпке кеңейтеміз кездейсоқ шама.
Екі кездейсоқ шаманы қарастырайық: X және-Y. Олардың бірлескен 2y=: [0,00], ал
үшін дискретті кездейсоқ шамалардың бұл ықтималдықпен анықталады¶

fxy(x,y)-Pr(X=x, Y=y) ¶

Бұл дискретті жағдайда домен [0, 1] және сондықтан 2xyexxy болатындай шектелген
fxy(x, y) = 1, мысалы, бірлескен үлгі кеңістігіндегі ықтималдықтардың қосындысы 1-ге
тең. Шекті pdf дискретті жағдайда анықталады ¶

$$f_X(x) = \sum_{y \in \Omega_Y} f_{X,Y}(x, y) = \sum_{y \in \Omega_Y} \mathbf{Pr}(X = x, Y = y).$$

¶

Маргинализация (оқшаулау) кездейсоқ шаманың әсерін жояды (жоғарыда көрсетілгендердегі Y анықтамалар бойынша).

Бұл үздіксіз жағдайда алдымен бірлескен және шекті ҚҚ-ны анықтау табиғирақ болады. Қашан = = R, бірлескен fxy(x, y) = Pr(X) арқылы анықталады < x, < y). Шекті мәндер анықталды fxy үшін cdf мәндері: Fx(x) = limy fxy(x, y) (y) = lim #fxx (x, y). Содан кейін үздіксіздер үшін кездейсоқ шамаларды енді анықтай аламыз $f_{X,Y}(x, y) = \frac{\mathrm{d}^2 F_{X,Y}(x,y)}{\mathrm{d}x\mathrm{d}y}$. Және содан кейін pdf үшін шектеу X·

$$f_X(x) = \int_{y=-\infty}^{\infty} f_{X,Y}(x, y)\mathrm{d}y.$$

(IR анықталған кезде) ¶

Енді кездейсоқ шамалар тәуелсіз болған жағдайда ғана айта аламыз
барлық хиу үшін fxy(x, y) = Fx(x) fy(y). ⍑

Сонда шартты үлестірім анықталады X берілген y үшін: (x-| y) = (x, y) / (y)
(fr(y) #-0 екенін ескере отырып).

№26 Емтихан билеті

1. Басымдықты іріктеу әдісі (3 лекция)

Басымдықты іріктеу:

1. w(ai) салмағымен ai ∈ A элементі үшін ui ~ unif(0, 1] генерациялаңыз. pi = w(ai)/ui

басымдығын орнатыңыз.

2. , (k + 1)-ші ең үлкен басымдық болсын делік.

3. Жаңа салмақтарды тағайындаңыз $w'(a_i) = \begin{cases} \max(w(a_i), \tau) & \text{if } \rho_i > \tau \\ 0 & \text{if } \rho_i \leq \tau \end{cases}$.

w': $A \to [0, \infty)$ жаңа салмақ функциясы тек нөлдік емес мәндері бар k элементтерін қамтиды, тек олар A' іріктемесінде сақталуы керек. Оның көптеген жағымды қасиеттері бар. Ең бастысы, $E[w'(a_i)] = w(a_i)$. Сонымен, кез-келген $S \subset A$ ішкі жиыны үшін біз тек $\sum_{a_i \in S \cap A'} w'(a_i)$ қолдана отырып, осы $\sum_{a_i \in S} w(a_i)$ ішкі жиындағы салмақтардың қосындысын бағалай аламыз және бұл дұрыс күтілетін мәнге ие болады. Сонымен, $w_P = \frac{1}{n} \sum_{i=1}^{n} w'(a_i)$ үшін маңыздылық іріктемесінің аналогы ретінде біз сондай-ақ $\mathbf{E}[w_P] = \bar{w}$. ие боламыз.

2. Қарапайым сызықтық регрессия

Біз сызықтық регрессияның қарапайым түрінен бастаймыз. Кіріс деректері (X, y) = {(x1,y1),(x2, y2), . . . ,(xn, yn)} n екі өлшемді деректер нүктелерінің жиынтығы. Соңғы мақсат тек x мәндерін қолдана отырып, y мәндерін болжау болады. Бұл жағдайда x - түсіндіруші айнымалы, ал y - тәуелді айнымалы. Үлкен X және кіші y әріптермен (X, y) белгілеуі кейінірек түсінікті болады. Бұл мәселе

әдетте x бөлігі көп өлшемді болған кезде жалпыланады, бірақ y бөлігі бір өлшемді болып қалады. Мұны істеу үшін біз жолды келесі берілген түрде "орналастырамыз"

$$y = l(x) = ax + b,$$

мұндағы a (көлбеу) және b (қиылысу) - осы сызықтың параметрлері. l жолы- осы кіріс деректері үшін біздің "модель".

3. Гаусс бойынша үлестіру

Гаусс бойынша үлестіру

Гаусс үлестірімі – бір өлшемді қалыпты үлестірімді жалпылайтын $G_d: R^d \to R$ d-вариациясы бар үлестіру. Симметриялық нұсқаның анықтамасы орташа мәнге $\mu \in R^d$ және σ^2 дисперсиясына байланысты. Кез келген вектор үшін $v \in R^d$–мен анықталады.

$$\mathcal{G}_d(v) = \frac{1}{\sigma^d \sqrt{(2\pi)^d}} \exp\left(-\frac{\|v-\mu\|^2}{2\sigma^2}\right),$$

мұндағы $\|v-\mu\|$ v мен μ арасындағы евклидтік қашықтық . Екі өлшемді жағдай үшін, мұндағы $v = (v_x, v_y)$ және $\mu = (\mu_x, \mu_y)$, содан кейін ол келесі түрге түрленеді.

$$\mathcal{G}_2(v) = \frac{1}{2\pi\sigma^2} \exp\left(\frac{-(v_x-\mu_x)^2 - (v_y-\mu_y)^2}{2\sigma^2}\right).$$

Гаусстың таралуының сиқырлы қасиеті - оның барлық шартты нұсқалары да Гаусс, бірақ өлшемі аз. Мысалы, екі өлшемді жағдайда $G_2(v_x \mid v_y = 1)$ бір өлшемді Гаусс үлестірімі болып табылады, ол дәл $N = G_1$ үлестірімі болып табылады. Гаусс теңдеуінің көптеген басқа маңызды қасиеттері бар, соның ішінде ол барлық негізгі түрлендірулерге инвариантты және орталық шекті теореманың шекаралары үшін шекті үлестіру болып табылады.

№27 Емтихан билеті

1. Векторлар мен матрицалар. Векторлар мен матрицалардың геометриясы(4-лекция)

1. Векторлар мен матрицалар

Деректерді талдау контекстінде сызықтық алгебраның маңызды бөлігі нақты сандардың векторлары мен матрицаларымен айналысады.

Бұл тұрғыда $v = (v_1, v_2, \ldots, v_d)$ векторы $\mathbb{R}^d$ - гі нүктеге тең. Әдепкі бойынша, вектор d сандардан тұратын баған болады (мұндағы d контекстке байланысты)

$$v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix},$$

бірақ кейбір жағдайларда вектор

$$v^T = [v_1\ v_2\ \ldots\ v_d].$$

жолын білдіреді деп есептейміз

Деректер құрылымы тұрғысынан бұл көріністерді массив ретінде сақтауға болады.

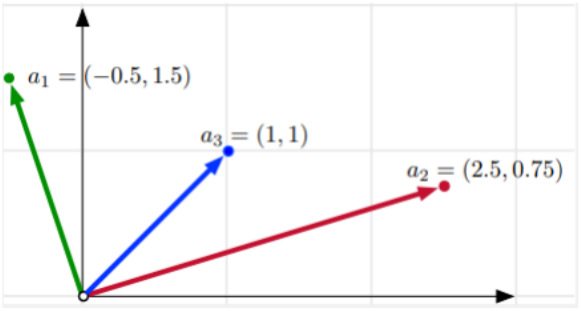
$n = d$ кезінде A матрицасы $a_1, a_2, \ldots, a_n$ жолдарының n векторларынан тұратын реттелген жиынтық болып табылады.

$$A = [a_1;\ a_2;\ \ldots;\ a_n] = \begin{bmatrix} - & a_1 & - \\ - & a_2 & - \\ & \vdots & \\ - & a_n & - \end{bmatrix} = \begin{bmatrix} A_{1,1} & A_{1,2} & \ldots & A_{1,d} \\ A_{2,1} & A_{2,2} & \ldots & A_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n,1} & A_{n,2} & \ldots & A_{n,d} \end{bmatrix},$$

мұндағы $a_i = [A_{i,1}, A_{i,2}, \ldots, A_{i,d}]$ вектор, ал $A_{i,j}$ - i -ші жолдағы және j -ші бағандағы матрица элементі.

Векторлар мен матрицалардың геометриясы

d ұзындықты v векторларын $\mathbb{R}^d$ -гі нүктелер түрінде бейнелеу ыңғайлы болады. Және кейіннен оның $a_1, \ldots, a_n$ жолдарының әрқайсысы бойынша $n \times d$ өлшемді A матрицасын $\mathbb{R}^d$ -гі әрбір нүкте түрінде ұсыну ыңғайлы болады. Онда "вектор" - бұл $\mathbf{0} = (0, 0, \ldots, 0)$ координаттар басынан бастап осы нүктеге дейінгі "көрсеткі" .



$d = 2$ өлшемдеріндегі $n = 3$ нүктесі бар бұл сурет 3×2 матрицалық көрініске тең

$$A = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} -0.5 & 1.5 \\ 2.5 & 0.75 \\ 1 & 1 \end{bmatrix}.$$

$(\cdot)^T$ транспозиция операциясы жолдар мен бағандардың рөлдерін v векторымен жоғарыда көрсетілгендей қарама-қарсы етіп өзгертеді:

Операция транспонирования $(\cdot)^T$ меняет роли строк и столбцов на противоположные, как показано выше с вектором v. Матрица үшін біз жаза аламыз::

$$A^T = \begin{bmatrix} | & | & & | \\ a_1 & a_2 & \ldots & a_n \\ | & | & & | \end{bmatrix} = \begin{bmatrix} A_{1,1} & A_{2,1} & \ldots & A_{n,1} \\ A_{1,2} & A_{2,2} & \ldots & A_{n,2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{1,d} & A_{2,d} & \ldots & A_{n,d} \end{bmatrix}.$$

2. Бірнеше түсіндірме айнымалылары бар сызықтық регрессия (8-лекция)

2. Бірнеше түсіндірме айнымалылары бар сызықтық регрессия

Сиқырлы түрде сызықтық алгебраны қолдана отырып, бәрі бірнеше түсіндірме айнымалыны қолдануға дейін кеңейеді. Енді $(X, y) = \{(x_1, y_1),(x_2, y_2), \ldots, (x_n, y_n)\}$ деректер жиынтығын қарастырайық, мұнда әрбір деректер нүктесі $x_i = (x_{i,1}, x_{i,2}, \ldots, x_{i,d}) \in \mathbb{R}^d$ және $y_i \in \mathbb{R}$ ие болады. Яғни, x_i координаттары ретінде d түсіндірме айнымалылары және шығыста бір тәуелді айнымалы бар. Енді біз осы айнымалылардың барлығын y_i айнымалысына қатысты бірыңғай (сызықтық) болжам жасау үшін бірден қолданғымыз келеді. Яғни біз модель жасағымыз келеді

$$\begin{aligned}\hat{y}_i = M_\alpha(x_i) = M_\alpha(x_{i,1}, x_{i,2}, \ldots, x_{i,d}) &= \alpha_0 + \sum_{j=1}^{d} \alpha_j x_{i,j} \\ &= \alpha_0 + \alpha_1 x_{i,1} + \alpha_2 x_{i,2} + \ldots + \alpha_d x_{i,d}. \\ &= \langle \alpha, (1, x_{i,1}, x_{i,2}, \ldots, x_{i,d}) \rangle = \langle \alpha, (1, x_i) \rangle.\end{aligned}$$

α_0 жоғарыдағы эквивалентті белгілеулерде b -ның қиылысу мақсатына қызмет етеді және барлық a_j қарапайым сызықтық регрессиядағы жалғыз a коэффициентін ауыстырады. Шынында да, біз бұл модельді $(d+1)$-өлшемді $\alpha = (\alpha_0, \alpha_1, \ldots, \alpha_d)$ және $(1, x_{i,1}, x_{i,2}, \ldots, x_{i,d}) = (1, x_i)$ векторлары арасындағы нүктелік көбейтінді ретінде жаза аламыз. Уәде етілгендей, сызықтық алгебраның сиқыры бізге M_α күрделі сызықтық моделін сипаттауға мүмкіндік берді. Әрі қарай, біз оны қалай шешуге болатынын қарастырамыз.

$x_i = (x_{i,1}, x_{i,2}, \ldots, x_{i,d})$ деректер нүктесін ескере отырып, $r_i = y_i - \hat{y}_i = y_i - M(x_i)$ қалдық мәнін қолдана отырып, біз өз $\hat{y}_i = M(x_i)$ болжамымызды қайтадан бағалай аламыз. Және n деректер нүктелерінің жиынтығын бағалау үшін қателіктердің квадраттарының қосындысы

$$\mathrm{SSE}(X, y, M) = \sum_{i=1}^{n} r_i^2 = \sum_{i=1}^{n} (y_i - M(x_i))^2.$$

ретінде қарастыру стандартты болып табылады.

Бұл қатені азайтатын коэффициенттерді алу үшін енді біз мұны өте қарапайым сызықтық алгебра арқылы жасай аламыз.

Алдымен біз $n \times (d+1)$ өлшемді $\tilde{X} = [\mathbf{1}, X_1, X_2, \ldots, X_d]$ деректер матрицасын құрамыз, мұнда бірінші 1-баған барлық [1; 1;. . . ; 1] бірліктер бағанының n-өлшемді векторы болып табылады. Келесі d бағандардың әрқайсысы - X_j бағандар векторы болып табылады, мұндағы $x_{i,j} = X_{i,j} - X_j$ -дің i-ші жазбасы және x_i деректер нүктесінің j -ші координатасын білдіреді. Онда y - барлық тәуелді айнымалылардан тұратын, n-өлшемді вектор-баған болсын. Енді біз $(d+1)$-өлшемді $\alpha = (\alpha_0, \alpha_1, \ldots, \alpha_d)$ бағанының векторын есептей аламыз

$$\alpha = (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T y.$$

Бізде 1 түсіндірме айнымалысы бар қарапайым жағдаймен салыстырайық. $(\tilde{X}^T \tilde{X})^{-1}$ мүшесі $\frac{1}{\|X\|^2}$ мүшесін ауыстырады. $\tilde{X}^T y$ - $\langle \bar{Y}, \bar{X} \rangle$ нүктелік көбейтіндісін ауыстырады. b қиылысы үшін бөлек шешудің қажеті жоқ, өйткені біз барлық бірліктерден тұратын $\tilde{X}$ -де жаңа баған жасадық. α_0 - b қиылысын ауыстырады; ол b -ның өз алдына жеке тұруына эквивалентті, $\tilde{X}$ -гі 1 мәніне көбейтіледі.

Көбінесе X және $\tilde{X}$ матрицалары бір-бірінің орнына қолданылады, сондықтан көптеген жағдайларда біз X-гі «˜» бас тартамыз, біз барлық x_i деректер нүктелерін бір өлшемге ұлғайтылған деп қарастыра аламыз (әрқашан бірінші координатта 1-мен) немесе біз модельді бастапқы X матрицасына орналастыра аламыз және α_0 орын ауыстыру параметрін елемеуге болады, ол онда әдепкі бойынша 0 тең. Әрбір x_i жай ғана бір өлшемге артық деп есептелетін, бірінші тәсіл жиі кездеседі, себебі ол орын ауыстыру параметрін автоматты түрде өңдейді.

3. Байес ережесі(1-лекция)

Байес ережесі деректерге негізделген "модельдерді" бағалау үшін оңтайландыру кезінде қажет болатын ықтималдық функцияларын құрудың негізгі құрамдас бөлігі болып табылады. Байес пайымдауы-бұл "ең оңтайлы" модельді іздеуден әлдеқайда кең өріс. Бұл бөлім тек таныстыратын жұмыс бағыты көптеген мүмкін модельдер туралы айтады және осы белгісіздікті ескере отырып болжам жасай алады.

Екі M және D оқиғаларын ескере отырып, Байес ережесінде

$$\mathbf{Pr}(M \mid D) = \frac{\mathbf{Pr}(D \mid M) \cdot \mathbf{Pr}(M)}{\mathbf{Pr}(D)}.$$

Механикалық түрде бұл кездейсоқ шамалардың кондиционерлеу бағытын (берілген M-де D) - ден (берілген D-де M) - ге аударудың алгебралық әдісін ұсынады. Бұл M және D тәуелсіздігі туралы ештеңе білдірмейді (әйтпесе бұл өте қызық емес). Мұны алу үшін біз қолданамыз

$$\mathbf{Pr}(M \cap D) = \mathbf{Pr}(M \mid D)\mathbf{Pr}(D)$$

$$\mathbf{Pr}(M \cap D) = \mathbf{Pr}(D \cap M) = \mathbf{Pr}(D \mid M)\mathbf{Pr}(M).$$

Оларды біріктіру арқылы біз Pr (M | D) Pr (D) = Pr (D | M) Pr (M) аламыз, одан Pr (M | D) шешу үшін Pr (D) деп бөлуге болады. Осылайша, Байес ережесі сөзсіз дұрыс; кез келген" жиі қарсы Байес " пікірталас осы ереженің ерекшелігі немесе дұрыстығы туралы емес, деректерді модельдеу және талдау жасау туралы.

№28 Емтихан билеті

1.Векторлар мен матрицалар. Қосу және көбейту(4-лекция)

1. Векторлар мен матрицалар

Деректерді талдау контекстінде сызықтық алгебраның маңызды бөлігі нақты сандардың векторлары мен матрицаларымен айналысады.

Бұл тұрғыда $v = (v_1, v_2, \ldots, v_d)$ векторы $\mathbb{R}^d$ - гі нүктеге тең. Әдепкі бойынша, вектор d сандардан тұратын баған болады (мұндағы d контекстке байланысты)

$$v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix},$$

бірақ кейбір жағдайларда вектор

$$v^T = [v_1\ v_2\ \ldots\ v_d].$$

жолын білдіреді деп есептейміз

Деректер құрылымы тұрғысынан бұл көріністерді массив ретінде сақтауға болады.

$n = d$ кезінде A матрицасы $a_1, a_2, \ldots, a_n$ жолдарының n векторларынан тұратын реттелген жиынтық болып табылады.

$$A = [a_1;\ a_2;\ \ldots;\ a_n] = \begin{bmatrix} - & a_1 & - \\ - & a_2 & - \\ & \vdots & \\ - & a_n & - \end{bmatrix} = \begin{bmatrix} A_{1,1} & A_{1,2} & \ldots & A_{1,d} \\ A_{2,1} & A_{2,2} & \ldots & A_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n,1} & A_{n,2} & \ldots & A_{n,d} \end{bmatrix},$$

мұндағы $a_i = [A_{i,1}, A_{i,2}, \ldots, A_{i,d}]$ вектор, ал $A_{i,j}$ - i -ші жолдағы және j -ші бағандағы матрица элементі.

Біз екі векторды немесе екі матрицаны олардың өлшемдері бірдей болған жағдайда ғана қоса аламыз. Келесі векторлар үшін

$x = (x_1, x_2, \ldots, x_d) \in \mathbb{R}^d$ және $y = (y_1, y_2, \ldots, y_d) \in \mathbb{R}^d$, вектор

$$z = x + y = (x_1 + y_1, x_2 + y_2, \ldots, x_d + y_d) \in \mathbb{R}^d.$$

Сол сияқты, $A, B \in \mathbb{R}^{n \times d}$ екі матрица үшін, $C = A + B$ анықталады, мұндағы $C_{i,j} = A_{i,j} + B_{i,j}$ барлық i, j үшін. Көбейту үшін тек бір өлшем бойынша туралау қажет. $A \in \mathbb{R}^{n \times d}$ және $B \in \mathbb{R}^{d \times m}$ екі матрицасы үшін біз жаңа $C = AB \in \mathbb{R}^{n \times m}$ матрицасын ала аламыз, мұндағы $C_{i,j}$ - i -ші жолдағы және j-ші бағандағы элемент

$$C_{i,j} = \sum_{k=1}^{d} A_{i,k} B_{k,j}.$$

A-ны B-ға көбейту үшін (мұндағы A, B-ның сол жағында орналасқан, тәртіп маңызды!), біз A-дағы d жолының өлшемін B-дегі d бағанының өлшеміне сәйкес келтіруді талап етеміз. Егер $n \neq m$ болса, онда BA көбейте алмаймыз. Келесіні есте сақтау керек:

• Матрицалық көбейту *ассоциативті* болып табылады $(AB)C = A(BC)$.

[redacted]

• Матрицалық көбейту *үлестірімді* болып табылады $A(B + C) = AB + AC$.
• Матрицалық көбейту *коммутативті* ***емес*** $AB \neq BA$.
Біз сондай-ақ A матрицасын α скалярына көбейте аламыз. Бұл жағдайда $\alpha A = A\alpha$ және жаңа B матрицасымен анықталады, мұндағы $B_{i,j} = \alpha A_{i,j}$.

2. Көпмүшелік регрессия (8-лекция)

3. Көпмүшелік регрессия

Кейде сызықтық қатынастар деректерде болатын шынайы заңдылықты, тіпті бір тәуелді x айнымалысымен де ұстау үшін жеткіліксіз болады. Оның орнына біз келесі пішіндегі модельді жасағымыз келеді:

$$\hat{y} = M_2(x) = \alpha_0 + \alpha_1 x + \alpha_2 x^2$$

немесе, жалпы алғанда, p дәрежелі қандай да бір көпмүше үшін

$$\hat{y} = M_p(x) = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \ldots + \alpha_p x^p = \alpha_0 + \sum_{i=1}^{p} \alpha_i x^i.$$

3.Марков теңсіздігі(2-лекция)

X кездейсоқ шама болсын, $X \geq 0$, яғни ол теріс мәндерді қабылдай алмайды. Онда кез-келген $\alpha > 0$ параметрі үшін

$$\mathbf{Pr}[X > \alpha] \leq \frac{\mathbf{E}[X]}{\alpha}.$$

Бұл $\varepsilon = \alpha - \mathbf{E}[X]$ және $\delta = \mathbf{E}[X] / \alpha$ бірге PAC шекарасы екенін ескеріңіз немесе біз бұл шекараны келесідей қайта өрнектей аламыз:

$$\mathbf{Pr}[X - \mathbf{E}[X] > \varepsilon] \leq \delta = \mathbf{E}[X]/(\varepsilon + \mathbf{E}[X]).$$

№29 Емтихан билеті

1. Вектор-векторлық көбейтінділер

Вектор-векторлық көбейтінділер. Векторлық-векторлық көбейтінділердің екі түрі бар және олардың анықтамалары матрицаны матрицаға көбейту анықтамасынан тікелей шығады (өйткені вектор матрица болып табылады, мұнда өлшемдердің бірі 1 - ге тең). Бірақ мұны ерекше атап өткен жөн.

Егер $x, y \in \mathbb{R}^d$ екі баған векторы берілсе, онда *ішкі көбейтінді* немесе *скалярлық (нүктелік) көбейтінді*

$$x^T y = x \cdot y = \langle x, y \rangle = [x_1\ x_2\ \dots\ x_d] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_d \end{bmatrix} = \sum_{i=1}^{d} x_i y_i,$$

түрінде жазылады, мұндағы x_i - x-тің i-ші элементі және y_i үшінде солай. Бұл мәтінде біз соңғы $\langle x, y \rangle$ белгілеуін қолданамыз, өйткені оны жолдық векторлар үшін де қолдануға болады, ал $x \cdot y$ қолданған кезде скалярлық көбейтумен шатастыру туындамайды. Вектордың жол немесе баған екендігі туралы мәселе көбінесе ерікті болып табылады, олар әдетте компьютерде жадта бірдей сақталады.

Бұл скалярлық көбейтінді операциясы жалғыз скалярлық мән беретініне назар аударыңыз. Және бұл сызықтық оператор. Демек, бұл кез-келген α скалярлық мәні және үш $x, y, z \in \mathbb{R}^d$ векторлары үшін біз келесіге ие болатындығымызды білдіреді

$$\langle \alpha x, y + z \rangle = \alpha \langle x, y + z \rangle = \alpha (\langle x, y \rangle + \langle x, z \rangle).$$

Бұл операция ассоциативті, үлестірімді (дистрибьютерлік) және коммутативті болып табылады.

2. Көпмүшелік регрессия жағдайында кросс-тексеру

4. Кросс-тексеру

Осылайша, біз p-ны көбірек арттырған сайын, деректер жақсырақ және жақсырақ сәйкес келетін сияқты. Жалғыз кемшілігі - $\tilde{X}_p$ матрицасында қажет бағандар саны, солай емес пе? Өкінішке орай, бұл дұрыс емес. Сонда қалай (және неге?) біз p дұрыс мәнін, көпмүшеге сәйкестік дәрежесін таңдаймыз ба?

(Өте қарапайым) статистикалық тәсіл (гипотезаны тексеру) деректер моделін таңдау (қандай да бір p көпмүшелік дәрежесі үшін ең жақсы сәйкестік қисығы және Гаусс шуын болжау), содан кейін деректердің осы модельдің қателігінен асып кету ықтималдығын есептеу болуы мүмкін. Бірақ көптеген әртүрлі көпмүшелер жақсы сәйкес келуі мүмкін бе?

Шын мәнінде, егер біз p − ны n-1 немесе одан үлкен етіп таңдасақ, онда қисық барлық нүктелерді *көпмүшеліктік интерполяциялайды*. Яғни, ол барлық нүктелерден өтеді, осылайша барлық нүктелерде 0-ге тең қалдық болады (цифрға дейін дәлдікпен). Бұл көптеген геометриялық модельдеу әдістерінің негізі (мысалы, CAD үшін), бірақ бұл деректерді модельдеуге жақсы әсер етпейді.

Мысал: Қарапайым көпмүшелік мысалы

9 нүктеден тұратын қарапайым деректер жиынтығын қарастырайық

x	1	2	3	4	5	6	7	8	9
y	4	6	8.2	9	9.5	11	11.5	12	11.2

Жалпылау және кросс-тексеру. Регрессиядағы біздің түпкі мақсатымыз-SSE емес, жалпылау (жаңа деректер негізінде қаншалықты жақсы болжаймыз)! Сызықты немесе қисықты сәйкестендіру үшін кейбір қателік өлшемін (SSE) пайдалану біз қалаған нәрсенің жақсы көрсеткіші болып табылады, бірақ көптеген жағдайларда (көпмүшелік регрессия жағдайындағыдай) оны теріс пайдалануға болады. Біздің модель жаңа деректерге қалай жалпыланатынын білгіміз келеді. Мұны жаңа деректерсіз қалай өлшейтін едік?

Шешім *кросс-тексеруден* тұрады. Қарапайым түрде біз өз деректерімізді ***кездейсоқ*** түрде оқыту (оның негізінде біз модель құрамыз) және тестілік (оның негізінде біз өз моделімізді бағалаймыз) деп бөлеміз. Тестілеу бізде жоқ болашақ деректермен қаншалықты жақсы жұмыс істейтінімізді бағалауға қызмет етеді.

- *Неліктен кездейсоқ?:* Себебі сіз бөлуді таңдаған кезде модельді басқаларына қарағанда кейбір бөліктермен жақсы жұмыс істеу үшін ауыстырғыңыз келмейді. Сонымен қатар, біз деректер элементтері кейбір негізгі дистрибутивтен iid-ге (*Identically and Independently Distributed - бірдей және тәуелсіз таратылған*) ие болады деп болжайтындықтан, егер сіз оларды кездейсоқ таңдаған болсаңыз, онда тестілік деректер де iid болып табылады.
- *Тест деректері қаншалықты үлкен болуы керек?:* Бұл деректер жиынтығына байланысты. Жағдайлардың 10%, сондай-ақ 33% жиі кездеседі.

(X, y) деректердің толық жиынтығы болсын (n деректер жолымен) және біз оны сәйкесінше n_{train} және n_{test} жолдарымен (X_{train}, y_{train}) және (X_{test}, y_{test}) деректер жиынтығына бөлеміз. $n = n_{\text{train}} + n_{\text{test}}$ көмегімен. Әрі қарай, біз оқыту деректері бар модель құрамыз, мысалы,

$$\alpha = (X_{\text{train}}^T X_{\text{train}})^{-1} X_{\text{train}}^T y_{\text{train}}.$$

Содан кейін біз M_α моделін X_{test} сынақ деректері бойынша бағалаймыз, көбінесе SSE(X_{test}, y_{test}, M_α) келесідей қолдана отырып

$$\text{SSE}(X_{\text{test}}, y_{\text{test}}, M_\alpha) = \sum_{(x_i, y_i) \in (X_{\text{test}}, y_{\text{test}})} (y_i - M_\alpha(x_i))^2 = \sum_{(x_i, y_i) \in (X_{\text{test}}, y_{\text{test}})} (y_i - \langle (1; x_i), \alpha \rangle)^2.$$

3. Чебышев теңсіздігі

Чебышев теңсіздігі. Енді X кездейсоқ шама болсын, онда біз **Var**[X] және **E**[X] білеміз. Онда кез-келген ε > 0 параметрі үшін

$$\mathbf{Pr}[|X - \mathbf{E}[X]| \geq \varepsilon] \leq \frac{\mathbf{Var}[X]}{\varepsilon^2}.$$

Тағы да, бұл δ = **Var** [X]/ε^2 бірге РАС шекарасы екені анық. Бұл шекара әдетте Марковтан гөрі күшті өйткені δ сызықтық емес, ε бойынша квадраттық түрде төмендейді.

Мысал: Чебышев пен кофенің теңсіздігі

Тағы да, C - деректер университетінің оқытушылары бір апта ішінде ішетін кофе литрінің саны үшін кездейсоқ айнымалы болсын (**E**[C = 20]). Егер біз дисперсияның тым үлкен емес екенін білсек, атап айтқанда **Var**[C] = 9 (литр квадрат), онда жақсартылған шекараны алу үшін Чебышев теңсіздігін қолдануға болады.

$$\mathbf{Pr}[C \geq 50] \leq \mathbf{Pr}[|C - \mathbf{E}[C]| \geq 30] \leq \frac{\mathbf{Var}[C]}{30^2} = \frac{9}{900} = 0.01$$

Яғни, (**E**[C] = 20) маткүтілім және (**Var**[C] = 9) дисперсия көмегімен біз 50 л-ден асу ықтималдығын 0,01 ықтималдығына дейін азайта аламыз.

Бірінші теңсіздікте біз бір жақты C ≥ 50 өрнегінен екі жақты өрнекке ауысатынымызды ескеріңіз |C-E[C]| ≥ 30 өрнегі (яғни C-**E**[C] ≥ 30 немесе **E**[C] - C ≥ 30). Бұл біршама ысырапшылдық, сонымен қатар Чебышев теңсіздігінің қатаң біржақты нұсқалары бар, біз оларды ықшамдылық мақсатында осында талқыламаймыз.

Естеріңізге сала кетейік, кездейсоқ шаманың $\bar{X} = (X_1 + X_2 + \ldots + X_n)/n$ орташа мәні үшін, мұндағы X_i - iid, және σ^2 дисперсияға ие, онда **Var**[$\bar{X}$] = σ^2/n. Сондықтан,

$$\mathbf{Pr}[|\bar{X} - \mathbf{E}[X_i]| \geq \varepsilon] \leq \frac{\sigma^2}{n\varepsilon^2}.$$

Енді бізде ε және δ кіріс параметрлері, қажетті рұқсат етілген қателік және сәтсіздік ықтималдығы бар екенін қарастырайық. Егер біз белгісіз f үшін $X_i \sim f$ (iid) құра алсақ (белгілі күтілетін мәнмен және σ дисперсиясымен), онда n қаншалықты үлкен болуы керектігін шеше аламыз: $n = \sigma^2/(\varepsilon^2\delta)$.

Себебі iid $X_1, X_2, \ldots, X_n$ кездейсоқ шамалары үшін **E** [$\bar{X}$] = **E** [X_i] болғандықтан, онда n деректер көлемін ұлғайту кезінде шоғырланудың жақсарғанын көрсететін Марков теңсіздігі үшін ұқсас мағыналы-ажыратылатын кеңейту жоқ.

АКТИВ
Чтобы а
"Парам

№30 Емтихан билеті

1. Матрицалық-векторлық көбейтінділер(4 лекция)

Вектор-векторлық көбейтінділер. Векторлық-векторлық көбейтінділердің екі түрі бар және олардың анықтамалары матрицаны матрицаға көбейту анықтамасынан тікелей шығады (өйткені вектор матрица болып табылады, мұнда өлшемдердің бірі 1 - ге тең). Бірақ мұны ерекше атап өткен жөн.

Егер $x, y \in \mathbb{R}^d$ екі баған векторы берілсе, онда *ішкі көбейтінді* немесе *скалярлық (нүктелік) көбейтінді*

$$x^T y = x \cdot y = \langle x, y \rangle = [x_1\ x_2\ \ldots\ x_d] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_d \end{bmatrix} = \sum_{i=1}^{d} x_i y_i,$$

түрінде жазылады, мұндағы x_i - x-тің i-ші элементі және y_i үшінде солай. Бұл мәтінде біз соңғы $\langle x, y \rangle$ белгілеуін қолданамыз, өйткені оны жолдық векторлар үшін де қолдануға болады, ал $x \cdot y$ қолданған кезде скалярлық көбейтумен шатастыру туындамайды. Вектордың жол немесе баған екендігі туралы мәселе көбінесе ерікті болып табылады, олар әдетте компьютерде жадта бірдей сақталады.

Бұл скалярлық көбейтінді операциясы жалғыз скалярлық мән беретініне назар аударыңыз. Және бұл сызықтық оператор. Демек, бұл кез-келген α скалярлық мәні және үш $x, y, z \in \mathbb{R}^d$ векторлары үшін біз келесіге ие болатындығымызды білдіреді

$$\langle \alpha x, y + z \rangle = \alpha \langle x, y + z \rangle = \alpha (\langle x, y \rangle + \langle x, z \rangle).$$

Бұл операция ассоциативті, үлестірімді (дистрибьютерлік) және коммутативті болып табылады.

2. Тихоновтың жотаның (қабырғаның) регрессиясы үшін регуляризациясы (9 лекция)

1. Тихоновтың жоталық (қабырға) регрессиясы үшін регуляризациясы

Алдымен біз Тихоновтың регуляризациясын енгіземіз, бұл *жоталық регрессия* деп аталатын параметрленген сызықтық регрессияға әкеледі. *n* деректер нүктелері бар (*X, y*) деректер жиынтығын тағы бір рет қарастырайық. Енді

$$\mathsf{SSE}(X, y, M_\alpha) = \sum_{i=1}^{n} (y_i - M_\alpha(x_i))^2 = \|X\alpha - y\|_2^2$$

α минимизациясының орнына $s > 0$ параметрі үшін жаңа шығындар функциясын енгіземіз

$$W_\circ(X, y, \alpha, s) = \frac{1}{n}\|X\alpha - y\|_2^2 + s\|\alpha\|_2^2.$$

Бұл шығындар функциясы алдыңғыға ұқсас, тек ол $+ s\|\alpha\|_2^2$ *реттеу мүшесін* қосады. Бұл мүше α бағытына ығысуды қосады, атап айтқанда, ол α-ны кішірейтеді; егер $\|X\alpha_1 - y\|_2^2 = \|X\alpha_2 - y\|_2^2$ болатындай α_1 және α_2 екі векторы болса, онда бұл шығындар функциясы нормасы азды артық көреді. Шын мәнінде, бұл $\|X\alpha - y\|_2^2$ ең кіші мәндеріне сәйкес келмейтін кейбір α векторларына (модельдерді білдіретін) артықшылық береді, өйткені олар оны одан да кіші $s\|\alpha\|_2^2$ мүшесімен өтейді. Шынында да, бұл *s* параметрі неғұрлым үлкен болса, оның деректермен сәйкестігімен салыстырғанда α шағын нормасына соғұрлым артықшылық беріледі.

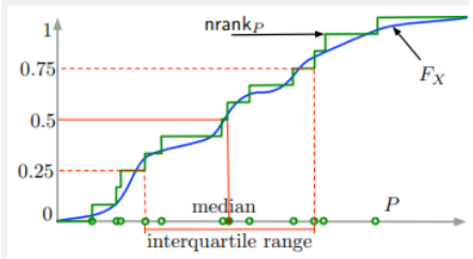
3. Квантильдік бағалау (2 лекция)

Квантильная оценка. Важным примером использования неравенств концентрации и границы объединения является оценка распределений. Для случайной величины *X,* пусть f_X опишет ее pdf, а F_X - ее cdf (Cumulative Distribution Function). Предположим, теперь мы можем извлечь выборки iid P = $\{p_1, p_2, \ldots, p_n\}$ из f_X, затем мы можем использовать эти *n* точек данных для оценки cdf F_X. Чтобы понять это приближение, напомним, что $F_X(t)$ - это вероятность того, что случайная величина *X* примет значение не более *t*. Для любого выбора *t* мы можем оценить это из *P* как $\text{nrank}_P(t) = |\{p_i \in P \mid p_i \le t\}|/\text{n}$; т.е. как долю выборок со значением не более *t*.

Величина $\text{nrank}_P(t)$ является *нормализованным рангом P* при значении *t,* а значение *t*, для которого $\text{nrank}_P(t) \le \varphi < \text{nrank}_P(t + \eta)$, для любого $\eta > 0$, известно как *φ-квантиль P*. Например, когда $\text{nrank}_P(t) = 0{,}5$, это 0,5-квантиль и, следовательно, *медиана* набора данных. И интервал $[t_1, t_2]$, такой, что t_1 является квантилем 0,25, а t_2 - квантилем 0,75, известен как *межквартильный диапазон*. Аналогичным образом мы можем определить *φ*-квантиль (и, следовательно, медиану и межквартильный диапазон) для распределения f_X как значение t, такое, что $F_X(t) = \varphi$.

Пример: CDF и нормализованный ранг

На следующем рисунке показан cdf F_X (синим цветом) и его аппроксимация с помощью нормализованного ранга nrankp для набора точек выборки *P* (зеленым цветом). Медиана *P* и ее межквартильный диапазон отмечены (красным цветом).



Для заданного значения t мы можем количественно оценить, насколько хорошо $\text{nrank}_P(t)$ аппроксимирует $F_X(t)$, используя границу Чернoффа-Хоффдинга. Для заданного t, для каждой выборки p_i, опишите случайную величину Y_i, которая равна 1, если $p_i \le t$, и 0 в противном случае.

Заметим, что $\mathbf{E}[Y_i] = F_X(t)$, поскольку это именно вероятность того, что случайная величина $X_i \sim f_x$ (представляющая точку данных p_i, еще не реализованная) меньше t. Более того, случайная величина для

Дәріс 2.docx

$\text{nrank}_P(t)$ в будущей выборке iid P точно равна $\bar{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i$. Следовательно, мы можем предоставить границу PAC для вероятности (δ) достижения ошибки, превышающей ε, для любого заданного t, как

$$\mathbf{Pr}[|\bar{Y} - F_X(t)| \ge \varepsilon] \le 2\exp\left(\frac{-2\varepsilon^2 n}{1^2}\right) = \delta.$$

Если у нас есть желаемая ошибка ε (например, $\varepsilon = 0{,}05$) и вероятность отказа δ (например, $\delta = 0{,}01$), мы можем решить, сколько требуется выборок: эти значения удовлетворяются

$$n \ge \frac{1}{2\varepsilon^2}\ln\frac{2}{\delta}.$$

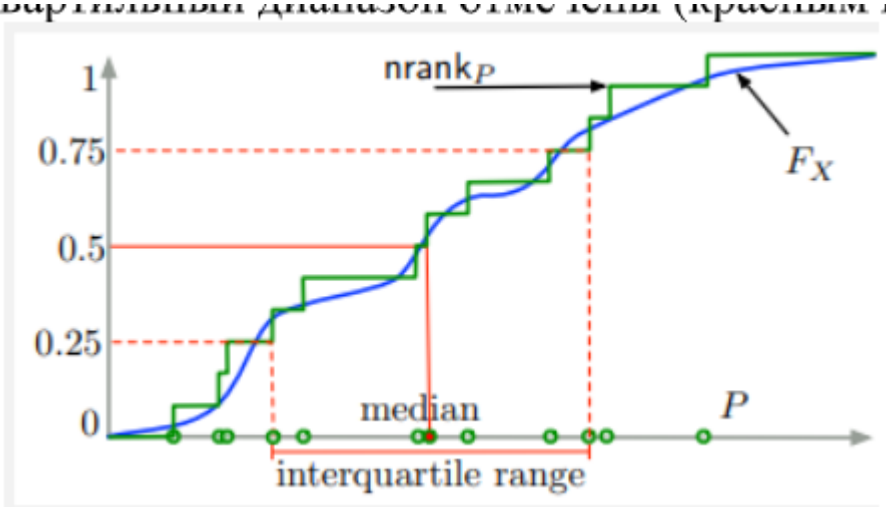
КАЗАКША:

Квантильді бағалау. Концентрат пен шекара теңсіздіктерін қолданудың маңызды мысалы нысан анықтаманы бағалауды білдіреді. X шамасы үшін f X оның pdf-ін, ал F X-ті сипаттасын - оның cdf (Cumulative Distribution Function). Мысалы үлгілерін шығара аламыз делік Iid P = {p1, p2 . . . , . . . , . . . , . . . , . . . , . . . , . . . , . . . , . . . , p n } pfx, біз осы n деректер тогын CDF F X бағалау үшін пайдалана аламыз . Мұны түсіну үшін қолданба, мысалы, F X (t) - бұл кездейсоқ шама x мәнін қабылдамайтынына сенімділік кез-келген t таңдауы үшін біз оны P-ден rank P (t) = / {p i = P / p i = t} / / n ретінде бағалай аламыз; яғни үлес ретінде білімі бар таңдау T-ден аспайды.

P (t) дәрежесінің N шамасы t мәніндегі қалыпқа келтірілген p дәрежесі, ал t мәні кімге арналған nrank P (t) ≤ φ < nrank P (T + η), үлкенірек үшін, η > 0, анық, φ-квант P. мысал, қашан nrank P (t) =0,5, вт 0,5-квантиль және сәйкесінше деректер жиынының медианасы. Және [t1 , t2] енгізді, сондықтан T1 болып табылады квантилі 0,25, ал t2 квантилі 0,75 квартиль аралық диапазон деп аталады. Сол сияқты біз φ-квантильді (демек, медианаңы және квартиларалық диапазонды) анықтай аламыз f X үлестірімі t мәні ретінде де, F X (t) = φ.

Мысал: CDF және қалыпқа келтірілген дәреже

Келесі суретте CDF F X (көк түспен) және оның жуықтауы көрсетілген P іріктеу нүктелерінің жиынтығы үшін nrnp нормаланған дәрежесі (жасыл). Медиана P және оның квартиларалық диапазон белгіленген (қызыл түспен).



Берілген t мәні үшін біз nrank P (t)қаншалықты жақсы екенін анықтай аламыз Чернофф-Хоффдинг шекарасын пайдаланып F X (t) жуықтайды. Берілген t үшін, әр үлгі үшін p i , егер pi = t болса, 1-ге тең болатын Y i кездейсоқ шамасын сипаттаңыз, әйтпесе 0. E[Y i] = F X (t) екенін ескеріңіз, өйткені бұл кездейсоқ шаманың XI = fX болу ықтималдығы (P I деректер нүктесін білдіретін , әлі іске асырылмаған) T-ден аз.
болашақ iid p үлгісіндегі rank P (t) дәл тең . Сондықтан біз қамтамасыз ете аламыз кез келген берілген t үшін ε-ден асатын қатеге жету ықтималдығы (δ) үшін PAC шекарасы

$$\mathbf{Pr}[|\bar{Y} - F_X(t)| \geq \varepsilon] \leq 2\exp\left(\frac{-2\varepsilon^2 n}{1^2}\right) = \delta.$$

Егер бізде қажетті ε қатесі болса (мысалы, ε = 0,05) және δ сәтсіздік ықтималдығы (мысалы, δ =0,01), біз қанша үлгі қажет екенін шеше аламыз: бұл мәндер қанағаттандырылады

$$n \geq \frac{1}{2\varepsilon^2} \ln \frac{2}{\delta}.$$